



دانشگاه صنعتی شریف

دانشکده مهندسی برق

پروژه درس یادگیری ماشین

استاد درس: دکتر سجاد امینی

تشخیص ناهنجاری مارکوف پنهان: از OC-SVM تا مدل‌های دنباله‌ای ساختاریافته

مصیب عاقلی (۴۰۲۱۰۲۰۷۹)

حامد باطانی (۴۰۲۱۰۱۳۳۹)

پاسخ به سوالات تئوری - بخش ۲

سوال تئوری ۱

مسئله: یک مثال از آنومالی نقطه‌ای (Point Anomaly) و یک مثال از آنومالی دنباله‌ای (Sequence Anomaly) ارائه دهید. توضیح دهید چرا آنومالی دنباله‌ای با بررسی مستقل هر مشاهده قابل تشخیص نیست.

پاسخ:

۱. مثال آنومالی نقطه‌ای (Point Anomaly): زمانی رخ می‌دهد که یک تک‌مشاهده به تنهایی خارج از محدوده کلی یا توزیع معمول داده‌های نرمال قرار گیرد.

• مثال: سنسور لرزش یک توربین بادی را در نظر بگیرید که دامنه نوسان عادی آن بین 0 تا 5mm/s است. اگر سنسور ناگهان مقدار 25mm/s را ثبت کند، این تک‌مشاهده به خودی خود یک آنومالی نقطه‌ای محسوب می‌شود.

۲. مثال آنومالی دنباله‌ای (Sequence / Collective Anomaly): زمانی رخ می‌دهد که تک‌تک داده‌ها به تنهایی در محدوده مجاز قرار دارند، اما ترتیب، الگوی زمانی یا نرخ تغییرات آن‌ها غیرعادی است.

• مثال: سنسور دمای یک تجهیز صنعتی را در نظر بگیرید که دمای عادی آن بین 60°C تا 85°C مجاز است. دنباله زمانی زیر در بازه 3 ثانیه:

$$60^{\circ}\text{C} \longrightarrow 85^{\circ}\text{C} \longrightarrow 60^{\circ}\text{C}$$

این جهش ناگهانی و بازگشت سریع یک آنومالی دنباله‌ای است.

۳. علت عدم تشخیص با نگاه مستقل (i.i.d.): اگر مدلی هر مشاهده X_t را به صورت مستقل بررسی کند، تنها توزیع حاشیه‌ای داده‌ها $P(X_t)$ را ارزیابی می‌کند:

- مقدار 60°C نرمال است.
- مقدار 85°C نرمال است.
- مقدار 60°C نرمال است.

از نظر فیزیکی، بدنه سیستم نمی‌تواند در عرض ۱ ثانیه 25°C گرم و ثانیه بعد خنک شود. مدل‌های مستقل به دلیل عدم مدل‌سازی احتمالات شرطی گذار $P(X_t | X_{t-1})$ ، قادر به تشخیص ناممکن بودن این انتقال (Transition) نیستند.

سوال تئوری ۲

مسئله: چرا تشخیص آنومالی (Anomaly Detection) زمانی که نمونه‌های برچسب‌دار آنومال در دسترس نیستند یا غیرقابل اعتماد هستند، نسبت به دسته‌بندی دوتایی معمولی (Ordinary Binary Classification) مسئله دشوارتر و پیچیده‌تری است؟

پاسخ:

۱. عدم وجود مرز تفکیک‌کننده دوطرفه (Lack of Two-Sided Boundary): در دسته‌بندی دوتایی معمولی، الگوریتم از هر دو کلاس نمونه‌های برچسب‌دار دریافت کرده و مرز تصمیمی می‌سازد که دو فضا را از هم جدا کند. اما در تشخیص آنومالی (One-Class یا تک کلاسی)، داده‌های آنومال غایب یا بسیار نایاب هستند؛ در نتیجه مدل باید صرفاً بر اساس داده‌های نرمال، کل محدوده رفتار عادی را محصور کند بدون اینکه بدانند انحراف‌ها در چه جهاتی رخ خواهند داد.

۲. ماهیت نامحدود و ناشناخته آنومالی‌ها (Unbounded and Heterogeneous Anomalies): کلاس «نرمال» معمولاً الگویی مشخص و فشرده دارد، اما انحراف و آنومالی می‌تواند به بی‌نهایت شکل متفاوتی ظاهر شود. بنابراین نمی‌توان توزیع احتمالاتی مشخصی برای کلاس آنومال تعریف کرد.

۳. خطر آلودگی داده‌های آموزش (Data Contamination): در حالت واقعی، مجموعه آموزش ممکن است حاوی درصد کوچکی نمونه آنومال بدون برچسب باشد که اگر مدل فرض کند تمام داده‌ها پاک هستند، این انحرافات را به عنوان رفتار عادی یاد می‌گیرد.

سوال تئوری ۳

مسئله: فرض کنید $\nu = 0.05$ باشد. این مقدار چه چیزی را درباره میزان جرم احتمالی (Probability Mass) که ردیاب ایده‌آل مجاز است خارج از ناحیه اسمی (Nominal Region) قرار دهد، بیان می‌کند؟

پاسخ:

بر اساس دیدگاه مجموعه‌های سطح چگالی (Density Level Sets)، ناحیه اسمی ایده‌آل به صورت زیر تعریف می‌شود:

$$L_\nu = \{x \in \mathcal{X} : p(x) \geq b_\nu\}$$

که در آن آستانه b_ν به گونه‌ای انتخاب می‌شود که:

$$P(X \notin L_\nu) = \nu$$

بنابراین اگر $\nu = 0.05$ باشد:

۱. جرم احتمالی خارج از ناحیه اسمی: ردیاب ایده‌آل دقیقاً 5% از کل جرم احتمالی توزیع اسمی (نرمال) P را خارج از ناحیه اسمی $L_{0.05}$ قرار می‌دهد:

$$P(X \notin L_{0.05}) = 0.05 \quad (5\%)$$

۲. جرم احتمالی داخل ناحیه اسمی: در مقابل، 95% از جرم احتمالی توزیع داده‌های نرمال در داخل ناحیه اسمی $L_{0.05}$ محصور می‌شود:

$$P(X \in L_{0.05}) = 1 - \nu = 0.95 \quad (95\%)$$

۳. تفسیر مفهومی: این بدان معناست که مدل ایده‌آل اجازه دارد تا حداکثر 5% از داده‌های اسمی را که کمترین چگالی احتمالاتی را دارند (کم‌احتمال‌ترین داده‌های نرمال یا پرت‌های احتمالی)، خارج از محدوده قبول قرار دهد.

پاسخ به سوالات تئوری - بخش ۳

سوال تئوری ۴

مسئله: چرا روش OC-SVM یک روش «تک کلاسی» (One-Class) نامیده می‌شود؟ تفاوت محیط آموزش آن را با دسته‌بندی دوتایی معمولی (Ordinary Binary Classification) توضیح دهید.

پاسخ:

۱. علت نام گذاری به عنوان «تک کلاسی» (One-Class): الگوریتم OC-SVM تنها با استفاده از داده‌های متعلق به یک کلاس (کلاس داده‌های نرمال یا اسمی) آموزش می‌بیند. در فاز آموزش، این مدل هیچ گونه دسترسی به نمونه‌های برچسب دار آنومال ندارد و نیازی به حضور داده‌های کلاس آنومالی برای فرایند یادگیری ندارد.

۲. تفاوت با دسته‌بندی دوتایی معمولی (Binary Classification):

- دسته‌بندی دوتایی معمولی: الگوریتم آموزش، داده‌های برچسب دار هر دو کلاس (مثبت و منفی) را دریافت کرده و سعی می‌کند مرز تصمیمی (Decision Boundary) بسازد که این دو کلاس مجزا را از هم تفکیک کند.
- مدل سازی تک کلاسی (OC-SVM): به دلیل غیاب کلاس آنومال، مدل تلاش می‌کند یک مرز محصورکننده دور داده‌های آموزش نرمال بسازد (با جدا کردن داده‌های نگاشت شده از مبدأ احداث در فضای ویژگی). در زمان ارزیابی، هر داده‌ای که خارج از این ناحیه محصور شده قرار گیرد، به عنوان آنومالی شناسایی می‌شود.

سوال تئوری ۵

مسئله: چرا با وجود این که پروژه در بخش های بعدی به بررسی مدل های آگاه از ترتیب و ساختار دنباله ای (Sequence-Aware) می پردازد، مدل OC-SVM همچنان یک بیس لاین (Baseline) معنادار و با اهمیت برای این پروژه محسوب می شود؟

پاسخ:

استفاده از OC-SVM به عنوان مدل بیس لاین به سه دلیل کلیدی معنادار و ضروری است:

۱. استاندارد مرجع در یادگیری ماشین (Standard Benchmark): مدل OC-SVM رایج ترین و استانداردترین روش برپایه کرنل برای تشخیص اتومالی تک کلاسی در ادبیات یادگیری ماشین است. هر زمان که مدل جدیدی (مانند HMAD) برای یک مسئله ارائه می شود، ارزیابی عملکرد آن در مقایسه با روش های کلاسیک و اثبات شده اولین گام علمی است.
۲. سنجش ارزش افزوده مدل سازی زمانی (Quantifying the Value of Temporal Structure): مدل OC-SVM داده ها را به صورت بردارهای ویژگی با طول ثابت (مانند خلاصه آماری یا الحاق مقادیر) فرآوری می کند و ترتیب زمانی را نادیده می گیرد. مقایسه مستقیم OC-SVM با HMAD به ما اجازه می دهد دقیقاً ارزیابی کنیم که **مدل سازی صریح ساختار زمانی، احتمالات گذار و حالات پنهان چقدر به بهبود تشخیص اتومالی کمک کرده است** و آیا پیچیدگی محاسباتی مدل های دنباله ای توجیه پذیر است یا خیر.
۳. ارزیابی نوع اتومالی ها: اگر اتومالی های موجود در داده ها از نوع تغییرات کلی آماری (مانند تغییر شدید در میانگین یا انحراف معیار کل دنباله) باشند، OC-SVM روی ویژگی های خلاصه شده عملکرد بسیار خوبی نشان می دهد. وجود این بیس لاین مشخص می کند که آیا انحرافات داده ها ساختاری و ترتیبی هستند یا صرفاً با ویژگی های آماری ساده نیز قابل تشخیص می باشند.

سوال تئوری ۶

مسئله: مفهوم هندسی جدا کردن داده های آموزش نگاشت شده از مبدأ احداث (Origin) در فضای ویژگی OC-SVM چیست؟

پاسخ:

مفهوم هندسی جدا کردن داده ها از مبدأ احداث در فضای ویژگی H به شرح زیر است:

۱. فرض مبدأ به عنوان نقطه مرجع غیرنرمال: در فضای ویژگی H ، مبدأ احداث (0) به عنوان نماینده فضای خالی یا رفتار غیرنرمال در نظر گرفته می شود. هدف مدل این است که داده های نرمال را در یک سمت ابرصفحه و مبدأ را در سمت دیگر آن قرار دهد.

۲. ساخت ابرصفحه جداکننده با حداکثر حاشیه: ابرصفحه $\langle w, \phi(x) \rangle = \rho$ طوری تنظیم می‌شود که داده‌های نرمال آموزش را از مبدأ دور نگه دارد و فاصله (حاشیه یا Margin) بین مبدأ و نزدیک‌ترین داده‌های نرمال را بیشینه کند $(\frac{\rho}{\|w\|})$.

۳. تفسیر هندسی با کرنل RBF (محصور کردن داده‌ها): هنگام استفاده از کرنل RBF، طول بردار تمام داده‌های نگاشت شده برابر با ۱ است $(\|\phi(x)\|^2 = k(x, x) = 1)$ ؛ یعنی تمام نقاط روی سطح یک ابرکره واحد در فضای ویژگی قرار می‌گیرند. در این حالت، جدا کردن داده‌ها از مبدأ توسط یک ابرصفحه، دقیقاً معادل $**$ یافتن کوچک‌ترین و فشرده‌ترین کلاهک کروی (Spherical Cap) یا ابرکره $**$ دور داده‌های آموزش نرمال است. هر داده‌ای که داخل این ناحیه محصور شده باشد نرمال و هر داده‌ای خارج از آن (نزدیک‌تر به مبدأ) آنومالی تلقی می‌شود.

سوال تئوری ۷

مسئله: چرا متغیرهای کمکی $(\xi_i \text{ Slack Variables})$ در تابع هدف OC-SVM مورد نیاز هستند؟ پاسخ خود را با داده‌های آموزشی آلوده یا نویزدار ارتباط دهید.

پاسخ:

متغیرهای کمکی $\xi_i \geq 0$ به دلایل زیر در تابع هدف OC-SVM نقش حیاتی ایفا می‌کنند:

۱. ایجاد مرز نرم (Soft Margin): در فرمول‌بندی OC-SVM، قید مربوط به هر نمونه به صورت $\langle w, \phi(x_i) \rangle \geq \rho - \xi_i$ نوشته می‌شود. متغیر ξ_i میزان میزان نقض مرز توسط نمونه x_i را اندازه‌گیری می‌کند. بدون این متغیرها $(\xi_i = 0)$ ، مدل مجبور به ساخت یک «مرز سخت» (Hard Margin) می‌شود که در آن هیچ نمونه‌ای اجازه ندارد خارج از ناحیه امنی قرار گیرد.

۲. جلوگیری از بیش‌برازش به نویز و داده‌های آلوده (Robustness to Contaminated Data): در کاربردهای واقعی، مجموعه داده‌های آموزش معمولاً کاملاً پاک نیستند و ممکن است حاوی خطای اندازه‌گیری، نویز یا درصد کوچکی آلودگی (Contamination) با نمونه‌های آنومال بدون برچسب باشند. بدون متغیرهای اسلک، حضور حتی یک داده پرت یا آلوده باعث تغییر شدید و پیچیده شدن مرز تصمیم می‌شود تا آن یک نقطه را نیز در بر بگیرد؛ این موضوع منجر به بیش‌برازش (Overfitting) شدید به نویز می‌شود.

۳. ایجاد موازنه در تابع هدف (Trade-off Control): متغیرهای اسلک با ضریب $\frac{1}{\nu n}$ در تابع هدف قرار می‌گیرند:

$$\min_{w, \rho, \xi} \frac{1}{2} \|w\|^2 - \rho + \frac{1}{\nu n} \sum_{i=1}^n \xi_i$$

این عبارت به مدل اجازه می‌دهد تعادلی منطقی بین «ساده نگه داشتن مرز» و «پذیرش میزان مشخصی خطا برای داده‌های نویزدار یا پرت» ایجاد کند.

سوال تئوری ۸

مسئله: نقش پارامتر ν را در OC-SVM توضیح دهید. اگر ν بسیار کوچک تر یا بسیار بزرگ تر از میزان واقعی آلودگی (True Contamination Level) انتخاب شود، چه اتفاقی می افتد؟ پاسخ:

۱. نقش پارامتر ν در OC-SVM: پارامتر $\nu \in (0, 1]$ یکی از مهم ترین ابرپارامترهای OC-SVM است که توازن بین محصور کردن داده های آموزش و اجازه دادن به حضور داده های پرت را کنترل می کند [cite: ۱۶۹، ۱۷۳]. نقش های تئوری و عملی این پارامتر عبارتند از:
 - حد بالایی داده های پرت (Upper Bound on Outliers): ν حد بالایی برای کسر داده های آموزشی است که اجازه دارند خارج از مرز اسمی قرار گیرند [cite: ۱۷۱].
 - حد پایینی بردارهای پشتیبان (Lower Bound on Support Vectors): ν حد پایینی برای کسر بردارهای پشتیبان (Support Vectors) تعیین می کند [cite: ۱۷۱].
 - مفهوم کاربردی: ν میزان آلودگی مورد انتظار (Expected Contamination Level) در داده های آموزش را نشان می دهد [cite: ۱۷۳، ۱۷۴].

۲. اگر ν بسیار کوچک تر از میزان واقعی آلودگی باشد ($\nu \ll \text{Contamination}$):

- مدل کمترین تمایل را برای رد کردن داده ها نشان داده و سعی می کند تقریباً همه داده ها را در ناحیه نرمال جای دهد [cite: ۱۶۹].
- نتیجه: مرز تصمیم بیش از حد «گشاد» و فراگیر می شود. در فاز تست، مدل نمی تواند آنومالی های واقعی را شناسایی کند و آن ها را به عنوان داده نرمال می پذیرد (افزایش نرخ False Negatives و کاهش Recall).

۳. اگر ν بسیار بزرگ تر از میزان واقعی آلودگی باشد ($\nu \gg \text{Contamination}$):

- مدل بسیار سخت گیرانه عمل کرده و درصد زیادی از داده های آموزشی را به عنوان outlier رد می کند [cite: ۱۷۰].
- نتیجه: مرز تصمیم بیش از حد «تنگ» و فشرده می شود. در فاز تست، بخش زیادی از داده های نرمال و سالم به اشتباه به عنوان آنومالی شناسایی می شوند (افزایش نرخ False Positives و کاهش Precision).

سوال تئوری ۹

مسئله: چرا تبدیل یک دنباله زمانی به یک بردار ویژگی با طول ثابت (Fixed-Length Vector) لزوماً به معنای مدل سازی درست و مناسب وابستگی های زمانی (Temporal Dependency) نیست؟ پاسخ:

تبدیل یک دنباله به بردار ثابت (مانند خلاصه سازی آماری، پنجره بندی یا الحاق مستقیم) به دلایل زیر نمی تواند وابستگی های زمانی پیچیده را به طور کامل مدل سازی کند:

۱. از بین رفتن ترتیب زمانی در خلاصه‌های آماری (Loss of Sequential Order): روش‌های خلاصه آماری (مانند میانگین، انحراف معیار، min و max بعد زمان را کاملاً حذف می‌کنند [cite: ۸۶۵، ۱۱۴۰، ۱۱۴۲]. دو دنباله با ترتیب‌های کاملاً متفاوت (مثلاً یک سیگنال مرتب $1 \rightarrow 2 \rightarrow 3 \rightarrow 4$ در برابر سیگنال کاملاً تصادفی $1 \rightarrow 3 \rightarrow 2 \rightarrow 4$) بردارهای ویژگی خلاصه شده کاملاً یکسانی تولید می‌کنند [cite: ۱۰۰۸، ۱۰۰۹، ۱۰۱۰]. در نتیجه مدل از تشخیص آنومالی‌های ترتیبی ناتوان خواهد بود [cite: ۸۷۰، ۱۰۰۷، ۱۰۱۲].

۲. صلب بودن و عدم ناوردایی نسبت به انتقال زمانی در الحاق (Lack of Translation Invariance): در روش الحاق مستقیم (Flattening)، هر تایم‌استپ به یک بعد مستقل از بردار تبدیل می‌شود [cite: ۸۶۳، ۱۱۳۵]. این روش نسبت به جابه‌جایی یا شیفت زمانی حساس است؛ یعنی اگر یک الگوی رفتار نرمال تنها چند تایم‌استپ به چپ یا راست منتقل شود، بردار حاصل کاملاً متفاوت به نظر رسیده و به اشتباه آنومالی تشخیص داده می‌شود [cite: ۱۱۳۸].

۳. عدم مدل‌سازی احتمالات شرطی و حالات پنهان (No Latent Dynamics): نمایش‌های برداری ثابت، فرض مستقل بودن ابعاد بردار ویژگی را برقرار می‌سازند و توانایی مدل‌سازی احتمالات شرطی گذار $P(X_t | X_{t-1})$ یا حالات پنهان سیستم (Latent States) را ندارند [cite: ۸۲۸، ۸۹۷، ۸۹۹]. بسیاری از آنومالی‌ها نه به خاطر مقدار تک‌تک مشاهدات، بلکه به دلیل وقوع انتقال غیرممکن بین حالات رخ می‌دهند که بردارهای ثابت قادر به ثبت این ساختار نیستند [cite: ۷۵۹، ۷۸۶، ۹۰۵].

پاسخ به سوال شبیه‌سازی ۱

مسئله: پیاده‌سازی خط پایه OC-SVM روی مجموعه داده انتخابی و گزارش بازنمایی، پیش‌پردازش و معیارها. پاسخ: مجموعه داده واقعی ECG5000 از آرشیو UCR/TSML انتخاب شد. هر نمونه یک ضربان قلب تک کاناله با ۱۴۰ مشاهده مرتب است. تنها ۲۹۲ ضربان کلاس ۱ (نرمال) از بخش رسمی آموزش برای برآزش مدل استفاده شد و کل بخش رسمی آزمون، شامل ۲۶۲۷ ضربان نرمال و ۱۸۷۳ ضربان غیرنرمال، بدون حذف یا جابه‌جایی نگه داشته شد.

جدول ۱: پیکربندی و نتیجه خط پایه OC-SVM روی ECG5000

مجموعه داده	ECG5000، یک ضربان با طول ۱۴۰
آموزش تک کلاسه	۲۹۲ ضربان نرمال، ۴۰۸۸۰ تایم‌استپ
آزمون ثابت	۴۵۰۰ ضربان: ۲۶۲۷ نرمال و ۱۸۷۳ آنومال
بازنمایی	موج پهن شده $\phi_{\text{flat}}(x) \in \mathbb{R}^{140}$
پیش‌پردازش	StandardScaler، برآزش شده فقط روی آموزش نرمال
مدل	کرنل RBF، $\gamma = \text{scale}$ ، $\nu = 0.1$
ROC-AUC	0.9840
Precision / Recall / F1	0.8314/0.9979/0.9071

نتیجه نشان می‌دهد مورفولوژی مکانی ضربان‌های هم‌تراز اطلاعات قوی دارد. آستانه سخت همان مرز استاندارد $f(x) = 0$ است و هیچ پارامتری نمونه‌ای با مشاهده نتایج آزمون تغییر داده نشده است.

جزئیات پیاده‌سازی و کنترل صحت:

۱. هر سطر فایل آرشیو به عنوان یک دنباله مستقل در نظر گرفته شد؛ ستون نخست برچسب کلاس و ۱۴۰ ستون بعدی مشاهدات مرتب زمانی هستند. بنابراین هیچ پنجره‌بندی دلخواهی روی یک سیگنال بلند انجام نشده است.

۲. بردار ویژگی پهن شده با حفظ ترتیب کامل نمونه‌ها ساخته شد. مقیاس‌ساز تنها با ماتریس 292×140 آموزش نرمال‌برازش شد و سپس بدون بازبرازش روی ۴۵۰۰ ضربان آزمون اعمال گردید.

۳. قرارداد امتیاز به صورت $s(x) = -f(x)$ تعریف شد تا مقدار بزرگ‌تر همواره به معنای آنومالی بیشتر باشد. معیار ROC-AUC از امتیاز پیوسته و معیارهای Precision، Recall و F1 از مرز استاندارد $f(x) = 0$ محاسبه شدند.

تفسیر نتیجه: مقدار Recall برابر 0.9979 نشان می‌دهد تقریباً همه ضربان‌های غیرنرمال شناسایی شده‌اند، اما Precision برابر 0.8314 وجود تعدادی مثبت کاذب را نشان می‌دهد. از این رو گزارش صرفاً به ROC-AUC اکتفا نمی‌کند و کیفیت آستانه عملیاتی نیز جداگانه بیان می‌شود. این نتیجه روی کل بخش رسمی آزمون گزارش شده و هیچ نمونه دشواری پس از مشاهده خروجی نگار گذاشته نشده است.

پاسخ به سوال شبیه‌سازی ۲

سه بازنمایی از پیش تعیین شده روی همان آزمون رسمی مقایسه شدند. خلاصه کلی فقط توزیع حاشیه‌ای را نگه می‌دارد، موج پهن شده هم ترازی کامل ضربان را حفظ می‌کند و خلاصه پنجره‌ای مصالحه‌ای میان این دو است.

جدول ۲: مقایسه بازنمایی‌های ثابت برای OC-SVM

F1	Recall	Precision	ROC-AUC	بعد	بازنمایی
۰٫۹۰۷۱	۰٫۹۹۷۹	۰٫۸۳۱۴	۰٫۹۸۴۰	۱۴۰	Flattened
۰٫۸۶۶۱	۰٫۹۲۷۴	۰٫۸۱۲۴	۰٫۹۵۱۸	۵	Global Summary
۰٫۹۰۷۵	۰٫۹۹۸۴	۰٫۸۳۱۹	۰٫۹۸۲۳	۲۰	Window Summary

بازنمایی پهن شده از نظر ROC-AUC بهترین بود، زیرا ضربان‌ها در آرشیو به طول یکسان درونیابی و هم‌تراز شده‌اند و مکان قله‌ها و شکل موج اهمیت تشخیصی دارد. خلاصه پنجره‌ای تقریباً همان کیفیت را با بعد کمتر فراهم کرد؛ خلاصه کلی به علت حذف ترتیب ضعیف‌تر بود.

تعریف دقیق بازنمایی‌ها:

• پهن شده: $\phi_{\text{flat}}(x) = [x_1, \dots, x_{140}]^T \in \mathbb{R}^{140}$ ؛ این نمایش مکان مطلق هر نمونه و شکل کامل ضربان را حفظ می‌کند.

• خلاصه کلی: $\phi_{\text{summary}}(x) = [\mu, \sigma, \min, \max, \text{median}]^T \in \mathbb{R}^5$ ؛ این نمایش نسبت به جابه‌جایی زمانی ناورداست، اما ترتیب را حذف می‌کند.

• خلاصه پنجره‌ای: دنباله به ۱۰ پنجره متوالی ۱۴ نمونه‌ای تقسیم و میانگین و انحراف معیار هر پنجره به بردار ۲۰ بعدی تبدیل شد.

افت ROC-AUC خلاصه کلی از 0.9840 به 0.9518 شاهد تجربی اهمیت ترتیب است. در مقابل، خلاصه پنجره‌ای با تنها ۲۰ ویژگی به 0.9823 رسید؛ بنابراین بخش بزرگی از اطلاعات مفید در الگوی محلی و ترتیب پنجره‌ها قرار دارد. برتری جزئی Window Summary در F1 نیز ناشی از تفاوت نقطه کار آستانه صفر است و با برتری پهن شده در رتبه‌بندی پیوسته تناقض ندارد.

پاسخ به سوال شبیه‌سازی ۳ (Simulation ۳ Question ۳)

تحلیل حساسیت از پیش تعیین شده برای $\nu \in \{0.01, 0.05, 0.10, 0.20\}$ با بازنگری پهن شده انجام شد. این تحلیل برای انتخاب پسینی پارامتر استفاده نشد و پیکربندی اصلی همچنان $\nu = 0.1$ باقی ماند.

جدول ۳: حساسیت خط پایه به پارامتر ν

ν	ROC-AUC	Precision	Recall	F1
۰٫۰۱	۰٫۹۸۴۲	۰٫۸۳۱۸	۰٫۹۹۷۹	۰٫۹۰۷۳
۰٫۰۵	۰٫۹۸۴۳	۰٫۸۳۲۱	۰٫۹۹۷۹	۰٫۹۰۷۵
۰٫۱۰	۰٫۹۸۴۰	۰٫۸۳۱۴	۰٫۹۹۷۹	۰٫۹۰۷۱
۰٫۲۰	۰٫۹۸۰۱	۰٫۷۹۷۷	۰٫۹۹۷۹	۰٫۸۸۶۶

رتبه‌بندی پیوسته تا $\nu = 0.1$ پایدار است؛ افزایش ν به ۰٫۲۰ تعداد بیشتری از نمونه‌ها را خارج از مرز قرار می‌دهد و در مرز صفر دقت و F1 را کاهش می‌دهد.

تحلیل نقش ν :

۱. در OC-SVM، ν هم کران بالایی بر سهم خطاهای آموزشی و هم کران پایینی بر سهم بردارهای پشتیبان ایجاد می‌کند؛ بنابراین افزایش آن مرز پذیرش نرمال را محدودتر می‌سازد.

۲. نزدیکی مقادیر ROC-AUC برای $\nu \leq 0.1$ نشان می‌دهد ترتیب امتیازهای آنومالی نسبتاً پایدار است. تغییر محسوس‌تر Precision و F1 در $\nu = 0.20$ عمدتاً از جابه‌جایی مرز تصمیم ناشی می‌شود.

۳. این جدول تحلیل حساسیت است، نه جست‌وجوی ابرپارامتر روی آزمون. مقدار اصلی $\nu = 0.1$ پیش از مشاهده نتایج ثابت شد و بهترین سطر جدول به عنوان تنظیم جدید انتخاب نشد.

گزارش جامع بیس‌لاین

۱. خلاصه پیکربندی و نتایج تجربی baseline

خط پایه نهایی با موج کامل ۱۴۰ بعدی، استانداردسازی صرفاً بر آموزش نرمال، کرنل RBF و $\nu = 0.1$ به $\text{ROC-AUC} = 98.40\%$ و $\text{F1} = 90.71\%$ رسید. زمان برازش و امتیازدهی کل آزمون حدود ۰٫۰۶ ثانیه بود.

۲. تحلیل محدودیت اصلی OC-SVM در داده‌های دنباله‌ای

این موفقیت به هم‌ترازی ضربان‌های ECG5000 وابسته است. بردار پهن شده گذار صریح یا حالت پنهان ندارد و در داده‌های با طول متغیر، تغییر فاز شدید یا ناهم‌ترازی می‌تواند شکننده باشد. افت ROC-AUC خلاصه کلی به ۰٫۹۵۱۸ نیز نشان داد حذف ترتیب بخشی از اطلاعات مورفولوژیک را از بین می‌برد.

۳. انگیزه ورود به مدل آگاه از ساختار دنباله‌ای (HMAD)

HMAD با مسیر ویتربی و ویژگی‌های گذار/انتشار، نمایش فشرده و قابل‌تفسیرتری از ساختار ضربان می‌سازد. هدف مقایسه این است که مشخص شود این فشرده‌سازی روی داده واقعی چه مزیت یا هزینه‌ای نسبت به بردار خام هم‌تراز دارد، نه آنکه برتری HMAD از پیش فرض شود.

جدول ۴: جمع‌بندی نقاط قوت و محدودیت‌های خط پایه روی داده دنباله‌ای

محور	نقطه قوت	محدودیت
بازنمایی پهن شده	حفظ کامل مورفولوژی و مکان قله‌های ضربان هم‌تراز	حساسیت به تغییر فاز، طول متغیر و ناهم‌ترازی
خلاصه آماری	بعد کم، سرعت بالا و ناوردایی نسبت به جابه‌جایی	حذف ترتیب، گذارها و ساختار محلی
کرنل RBF	مدل کردن مرز غیرخطی داده نرمال	تفسیرپذیری کمتر و وابستگی به مقیاس ویژگی‌ها
آموزش تک کلاسه	عدم نیاز به نمونه آنومال در آموزش	حساسیت مرز سخت به مثبت‌های کاذب

جمع‌بندی بیس‌لاین: خط پایه در این دیتاست ضعیف یا صوری نیست؛ زیرا روی تمام آزمون رسمی و با پیش‌پردازش بدون تسریب ارزیابی شده است. در عین حال، نتیجه آن به شرایط مطلوب، ECG۵۰۰۰ یعنی طول ثابت و هم‌ترازی ضربان‌ها، وابسته است. همین نکته انگیزه علمی مقایسه با نمایش ساختاری را ایجاد می‌کند: اگر مسیر حالت پنهان بتواند گذارهای مهم را با بعد کمتر حفظ کند، باید در برابر حذف یا جابه‌جایی ساختار مقاوم‌تر باشد؛ و اگر نتواند، کاهش بعد ممکن است اطلاعات مورفولوژیک ضروری را از بین ببرد.

سوال تئوری ۱۰

مسئله: توضیح دهید چرا مدلی که صرفاً به مشاهدات تک‌به‌تک و مستقل نگاه می‌کند ممکن است در تشخیص «آنومالی دنباله‌ای» (Sequence Anomaly) ناکام بماند. یک مثال بزنید که در آن هریک از مشاهدات به تنهایی نرمال باشند، اما ترتیب آن‌ها غیرعادی و مشکوک باشد.

پاسخ:

۱. علت شکست مدل‌های مبتنی بر فرض i.i.d.: اکثر مدل‌های کلاسیک فرض می‌کنند که داده‌ها مستقل و دارای توزیع یکسان (i.i.d.) هستند؛ در نتیجه احتمال مشترک یک دنباله $X = (X_1, X_2, \dots, X_T)$ را به صورت حاصل ضرب احتمال تک‌تک مشاهدات مدل‌سازی می‌کنند:

$$P(X_1 = x_1, \dots, X_T = x_T) = \prod_{t=1}^T P(X_t = x_t)$$

این فرمول‌بندی صرفاً **احتمال حاشیه‌ای** (Marginal Probability) وقوع هر مشاهده را می‌سنجد و **احتمالات گذار شرطی** (Transition Probabilities) $P(X_t | X_{t-1})$ بین مشاهدات متوالی را کاملاً نادیده می‌گیرد. در آنومالی‌های دنباله‌ای، تک‌تک مقادیر از نظر حاشیه‌ای کاملاً محتمل و نرمال هستند، اما قرار گرفتن آن‌ها پشت سر هم دارای احتمال وقوع بسیار پایینی در رفتار اسمی سیستم است.

۲. مثال کاربردی (سنسور دمای تجهیزات صنعتی):

• توصیف مشاهدات: فرض کنید دمای یک گیربکس توربین بادی معمولاً حول 60°C است، اما در شرایط بار سنگین رسیدن دما به 85°C نیز کاملاً عادی و ممکن است.

- بررسی تک به تک: مقادیر 60°C و 85°C به تنهایی دارای احتمال حاشیه‌ای بالا بوده و توسط مدل ایستایی (Static Model) آنومالی تشخیص داده نمی‌شوند.
- بررسی ترتیب (دنباله مشکوک): دنباله زمانی سریع $60^{\circ}\text{C} \rightarrow 85^{\circ}\text{C} \rightarrow 60^{\circ}\text{C}$ در طی ۳ تایم‌استپ متوالی از نظر فیزیکی غیرممکن یا بسیار مشکوک است؛ زیرا سیستم مکانیکی نمی‌تواند با این سرعت داغ شده و مجدداً خنک شود. آنومالی در اینجا دقیقاً در ****الگوی گذار**** (Transition Pattern) نهفته است، نه در مقادیر لحظه‌ای.

سوال تئوری ۱۱

مسئله: برای مثال لاگ‌های سرور، توضیح دهید چرا دنباله $\text{Scan Port} \rightarrow \text{Login} \rightarrow \text{Download Data}$ می‌تواند تحت یک مدل گذار اسمی (Nominal Transition Model) احتمال بسیار پایینی داشته باشد، حتی اگر هر رویداد به تنهایی احتمال حاشیه‌ای (Marginal Probability) بالایی داشته باشد.

پاسخ:

۱. تجزیه احتمال مشترک دنباله (Chain Rule / Markov Property): احتمال کل رخ داد دنباله $S = (s_1, s_2, s_3)$ با فرض مارکوف به صورت حاصل ضرب احتمال اولیه و احتمالات گذار شرطی محاسبه می‌شود:

$$P(\text{Scan Port}, \text{Login}, \text{Download Data}) = P(\text{Scan Port}) \cdot P(\text{Login} | \text{Scan Port}) \cdot P(\text{Download Data} | \text{Login})$$

۲. علت بالا بودن احتمال حاشیه‌ای (Marginal Probability): در یک سرور عملیاتی، هریک از این سه رویداد به تنهایی در سطح سیستم بسیار رایج بوده و فراوانی بالایی دارند:

- $P(\text{Scan Port})$ بالا است، زیرا اسکن‌های خودکار پورت یا پویش‌های دوره‌ای شبکه مکرراً رخ می‌دهند.
- $P(\text{Login})$ بالا است، زیرا کاربران و مدیران سیستم روزانه بارها وارد سیستم می‌شوند.
- $P(\text{Download Data})$ بالا است، زیرا دریافت و انتقال فایل یک فعالیت کاری روزمره است.

بنابراین مدلی که فقط احتمال حاشیه‌ای $P(X_t)$ را می‌سنجد، تک‌تک این رویدادها را کاملاً طبیعی و غیرآنومال تشخیص می‌دهد.

۳. علت پایین بودن احتمال گذار در رفتار اسمی (Nominal Transition Probability): در الگوی رفتار عادی و اسمی سرور، یک کاربر واقعی و قانونی بلافاصله پس از اسکن پورت اقدام به ورود نمی‌کند (اسکن پورت رفتار ابزارهای نفوذ یا مهاجمان است). بنابراین احتمال شرطی گذار برابر است با:

$$P(\text{Login} | \text{Scan Port}) \approx 0$$

وجود همین یک گذار ناممکن یا بسیار کم‌احتمال باعث می‌شود که حاصل ضرب کل احتمال دنباله $P(S)$ نزدیک به صفر شود.

۰۴. نتیجه‌گیری: مدل‌های آگاه از گذار (Transition-Aware Models) با ارزیابی احتمالات شرطی $P(s_t | s_{t-1})$ به جای احتمالات تک‌به‌تک $P(s_t)$ ، متوجه می‌شوند که اگرچه تمام رویدادها به تنهایی نرمال هستند، اما **ترتیب قرارگیری آن‌ها** یک آنومالی دنباله‌ای (Sequence Anomaly) و مشکوک به حمله است.

سوال تئوری ۱۲

مسئله: یک زنجیره مارکوف با دو حالت $1 = \text{normal}$ (نرمال) و $2 = \text{high-load}$ (بار سنگین) را در نظر بگیرید. بزرگ بودن مقدار A_{11} به چه معناست؟ بزرگ بودن مقدار A_{12} به چه معناست؟

پاسخ:

در یک زنجیره مارکوف، درایه‌های ماتریس گذار A احتمال انتقال بین حالات در دو تایم‌استپ متوالی را به صورت $A_{ij} = P(z_t = j | z_{t-1} = i)$ تعریف می‌کنند. با توجه به اینکه هر سطر ماتریس گذار یک توزیع احتمال است ($A_{11} + A_{12} = 1$):

۱. معنای بزرگ بودن مقدار A_{11} : مقدار $A_{11} = P(z_t = 1 | z_{t-1} = 1)$ نشان‌دهنده احتمال ماندن در حالت نرمال در گام بعدی، به شرط قرار داشتن در حالت نرمال در گام فعلی است (Self-transition Probability).

- بزرگ بودن A_{11} (نزدیک به ۱) نشان‌دهنده **پایداری و ماندگاری بالا** (High Persistence/Inertia) سیستم در حالت نرمال است.
- به این معنا که سیستم مایل است برای فواصل زمانی طولانی و متوالی در شرایط عادی کار کند و تغییرات ناگهانی در آن نادر است.

۲. معنای بزرگ بودن مقدار A_{12} : مقدار $A_{12} = P(z_t = 2 | z_{t-1} = 1)$ نشان‌دهنده احتمال گذار از حالت نرمال به حالت بار سنگین (high-load) در گام بعدی است.

- بزرگ بودن A_{12} به این معناست که سیستم پس از قرار گرفتن در وضعیت نرمال، **حساسیت بالا یا تمایل زیادی به جهش سریع** به حالت پر بار دارد.
- این امر نشان‌دهنده نوسانات مکرر، تغییرات سریع فاز کاری یا رفتارهای دینامیکی پرتناوب در سیستم است.

پاسخ به سوال شبیه‌سازی ۴

مسئله: پیاده‌سازی تابعی در پایتون جهت محاسبه لگاریتم احتمال یک دنباله حالت $z = (z_1, \dots, z_T)$ تحت توزیع اولیه π و ماتریس گذار A :

$$\log P(z | \pi, A) = \log \pi_{z_1} + \sum_{t=2}^T \log A_{z_{t-1}, z_t}$$

۰۱. خروجی شبیه‌سازی و راست‌آزمایی عددی (Numerical Verification):
جهت صحت‌سنجی تابع پیاده‌سازی‌شده، یک مثال نمونه با مشخصات زیر اجرا گردید:

• توزیع اولیه: $\pi = [0.8, 0.2]$

• ماتریس گذار: $A = \begin{bmatrix} 0.9 & 0.1 \\ 0.3 & 0.7 \end{bmatrix}$

• دنباله حالت نمونه $(T = 5)$: $z = (1, 1, 2, 2, 1)$

محاسبه دستی و گام‌به‌گام لگاریتم احتمالات مطابق با فرمول مسئله به شرح زیر است:

$$\log P(z | \pi, A) = \log(0.8) + \log(0.9) + \log(0.1) + \log(0.7) + \log(0.3) = -4.1917$$

جدول ۵: گزارش خروجی تابع پایتون برای سوال شبیه‌سازی ۴

مقدار	ورودی / پارامتر
5	طول دنباله (T)
$[0.8, 0.2]$	توزیع حالت اولیه (π)
-4.1917	خروجی تابع پایتون (Log-probability)

۰۲. تحلیل پایداری عددی (Numerical Underflow): در محاسبه احتمال مستقیم $P(z) = 0.8 \times 0.9 \times 0.1 \times 0.7 \times 0.3 = 0.01512$ حاصل ضرب مقادیر احتمال برای دنباله‌های طولانی $(T \gg 1)$ به سرعت به صفر نزدیک شده و باعث خطای سرریز عددی (Underflow) در حافظه رایانه می‌شود. محاسبه هم‌ارز در فضای لگاریتمی $(\log P)$ با تبدیل ضرب‌ها به جمع، پایداری و دقت عددی الگوریتم را تضمین می‌کند.

سوال تئوری ۱۳

مسئله: تفاوت بین یک زنجیره مارکوف (Markov Chain) و یک مدل مارکوف پنهان (Hidden Markov Model) چیست؟ در پاسخ خود، تفاوت بین حالات پنهان (z_t) و مشاهدات (x_t) را مشخص کنید.

پاسخ:

۰۱. تفاوت در مشاهده‌پذیری حالات (Observability):

- زنجیره مارکوف (Markov Chain): حالات سیستم به صورت مستقیم قابل مشاهده هستند. به عبارت دیگر، خود سیگنال ورودی همان دنباله حالات است $(x_t = z_t)$ و هیچ متغیر پنهانی در مدل وجود ندارد.
- مدل مارکوف پنهان (HMM): وضعیت واقعی و ساختاری سیستم پنهان (Latent/Unobserved) است و ما صرفاً مشاهداتی (x_t) را دریافت می‌کنیم که به صورت تصادفی از این حالات پنهان تولید شده‌اند.

۰۲. تفکیک حالات پنهان (z_t) و مشاهدات (x_t) :

- حالت پنهان ($z_t \in \{1, \dots, K\}$): وضعیت متغیر داخلی یا مد کاری سیستم در زمان t است (مانند حالت «کارکرد عادی» یا «بار سنگین»). زنجیره حالات پنهان بر اساس فرایند مارکوف مرتبه اول با توزیع اولیه $\pi_i = P(z_1 = i)$ و ماتریس گذار $A_{ij} = P(z_t = j \mid z_{t-1} = i)$ تحول می‌یابد.
- مشاهده (x_t): مقدار اندازه‌گیری شده و واقعی در زمان t است (مانند عدد سنسور دما یا لاگ سیستم). هر مشاهده x_t صرفاً بر اساس حالت پنهان هم‌زمان خود (z_t) و طبق توزیع انتشار (Emission Model) تولید می‌شود:

$$P(x_t \mid z_t = i) = \mathcal{N}(x_t; \mu_i, \sigma_i^2) \quad (\text{در حالت توزیع گوسی})$$

۳. مقایسه تجزیه احتمال مشترک (Joint Probability Factorization):

- در زنجیره مارکوف:

$$P(z_1, \dots, z_T) = P(z_1) \prod_{t=2}^T P(z_t \mid z_{t-1})$$

- در مدل HMM:

$$P(x, z) = P(z_1) P(x_1 \mid z_1) \prod_{t=2}^T P(z_t \mid z_{t-1}) P(x_t \mid z_t)$$

جدول ۶: خلاصه تفاوت‌های زنجیره مارکوف و HMM

ویژگی	زنجیره مارکوف (Markov Chain)	مدل مارکوف پنهان (HMM)
حالات سیستم (z_t)	مستقیماً قابل مشاهده	پنهان و غیرقابل مشاهده مستقیم
مشاهدات (x_t)	همان حالات هستند ($x_t = z_t$)	متغیرهای متناظر تولید شده از z_t
پارامترهای مدل	$\lambda = (\pi, A)$	$\lambda = (\pi, A, B)$ (شامل مدل انتشار)

سوال تئوری ۱۴

مسئله: در مدل HMM با انتشار گوسی (Gaussian-emission HMM) استفاده شده در این پروژه، هر حالت پنهان i دارای پارامترهای μ_i و σ_i^2 است. این پارامترها نشان‌دهنده چه مفاهیمی هستند؟

پاسخ:

در مدل HMM با مشاهدات پیوسته، چگالی احتمال انتشار (Emission Density) برای هر حالت پنهان $z_t = i$ با یک توزیع نرمال (گوسی) مدل‌سازی می‌شود:

$$P(x_t \mid z_t = i) = \mathcal{N}(x_t; \mu_i, \sigma_i^2) = \frac{1}{\sqrt{2\pi\sigma_i^2}} \exp\left(-\frac{(x_t - \mu_i)^2}{2\sigma_i^2}\right)$$

مفهوم این پارامترها به شرح زیر است:

۱. میانگین (Mean / Expected Value - μ_i):

• تعریف ریاضی: امید ریاضی مشاهدات پیوسته x_t به شرط قرار داشتن سیستم در حالت پنهان i ($\mu_i = \mathbb{E}[x_t | z_t = i]$).

• مفهوم کاربردی: مقدار نامی (Nominal Value) یا مرکز تمرکز مشاهدات در آن حالت پنهان است. برای مثال، اگر حالت $i = 1$ نشان‌دهنده وضعیت «کارکرد عادی سنسور» باشد، $\mu_1 = 60^\circ\text{C}$ میانگین دمای تولیدی در این وضعیت است.

۲. واریانس (σ_i^2 - Variance / Dispersion):

• تعریف ریاضی: میزان پراکندگی و عدم قطعیت مشاهدات x_t حول میانگین μ_i در حالت پنهان i ($\sigma_i^2 = \text{Var}(x_t | z_t = i)$).

• مفهوم کاربردی: میزان نویز سیستم یا دامنه نوسانات طبیعی مشاهدات در آن حالت را نشان می‌دهد. واریانس کوچک‌تر به معنای ثبات بالای مشاهده و واریانس بزرگ‌تر به معنای نوسان و پراکندگی بیشتر داده‌ها در آن مد کاری است.

نتیجه‌گیری: جفت پارامترهای (μ_i, σ_i^2) به مدل HMM اجازه می‌دهند تا سیگنال‌های پیوسته x_t را به احتمالات انتساب به حالات گسسته پنهان $z_t \in \{1, \dots, K\}$ نگاشت کند.

پاسخ به سوال شبیه‌سازی ۵

مسئله: پیاده‌سازی تابعی در پایتون جهت نمونه‌گیری و تولید دنباله از یک مدل HMM دو-حالت با انتشار گوسی، دریافت پارامترهای $\pi, A, (\mu_1, \mu_2), (\sigma_1^2, \sigma_2^2)$ و طول دنباله T ، و بازگرداندن هم‌زمان دنباله حالات پنهان z و دنباله مشاهدات x .

۱. تشریح الگوریتم نمونه‌گیری (Generative Process):

فرایند تولید دنباله بر اساس روابط احتمالی زیر پیاده‌سازی گردیده است:

۱. مقداردهی اولیه ($t = 1$): حالت پنهان اولیه بر اساس توزیع π انتساب داده می‌شود ($z_1 \sim \text{Categorical}(\pi)$) و اولین مشاهده از توزیع گوسی مربوطه نمونه‌گیری می‌شود ($x_1 \sim \mathcal{N}(\mu_{z_1}, \sigma_{z_1}^2)$).

۲. انتقال و انتشار در گام‌های بعدی ($t = 2, \dots, T$): در هر گام زمانی، حالت پنهان بر اساس سطر متناظر با حالت قبلی در ماتریس گذار تعیین می‌شود ($z_t \sim \text{Categorical}(A_{z_{t-1}, :})$) و سپس مقدار مشاهده از توزیع $x_t \sim \mathcal{N}(\mu_{z_t}, \sigma_{z_t}^2)$ با انحراف معیار σ_{z_t} استخراج می‌گردد.

۲. نتایج اجرای نمونه و راست‌آزمایی عددی:

تابع پیاده‌سازی شده اجرا گردید و خروجی‌های عددی زیر به دست آمد:
تحلیل نتایج خروجی: مطابق با خروجی پایتون:

• در تایم‌استپ‌های انتخابی که حالت پنهان $z_t = 0$ است (ابتدا و انتهای دنباله)، مقادیر مشاهده x_t حول میانگین $\mu_1 = 0.0$ قرار دارند (مانند -0.0282 و -0.0188).

• با گذار سیستم به حالت پنهان $z_t = 1$ (از گام ۲ تا ۸)، مقادیر مشاهدات بلافاصله به سمت میانگین $\mu_2 = 4.0$ شیف‌ت پیدا کرده‌اند (مانند 4.3494 و 4.9868).

جدول ۷: پارامترهای ورودی و مقادیر خروجی دقیق نمونه‌گیری از مدل HMM

مقدار	پارامتر ورودی / خروجی
$[0.8, 0.2]$	توزیع حالت اولیه (π)
$\begin{bmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{bmatrix}$	ماتریس گذار (A)
$\mu_1 = 0.0, \mu_2 = 4.0$	میانگین‌های انتشار (μ_1, μ_2)
$\sigma_1^2 = 1.0, \sigma_2^2 = 1.0$	واریانس‌های انتشار (σ_1^2, σ_2^2)
10	طول دنباله (T)
$[0, 1, 1, 1, 1, 1, 1, 1, 0, 0]$	دنباله حالات پنهان (z)
$[1.1562, 2.8395, 4.3494, 4.9868, 3.7319, 3.2211, 4.9430, 4.6628, -0.0282, -0.0188]$	دنباله مشاهدات (x)

این تطابق دقیق، صحت عملکرد تابع مولد در پیاده‌سازی گذار حالات و مدل انتشار را تأیید می‌کند.

پاسخ به سوال تئوری ۱۵

مسئله: چرا رمزگشایی جستجوی کامل (Brute-force Decoding) برای یافتن احتمال‌مندترین دنباله حالت پنهان در دنباله‌های طولانی غیرممکن است؟ تعداد مسیرهای ممکن در صورتی که K حالت و دنباله‌ای به طول T داشته باشیم چقدر است؟

پاسخ:

۱. تعداد مسیرهای ممکن (K^T) : در یک مدل HMM با K حالت پنهان و دنباله‌ای به طول T ، در هر گام زمانی $t \in \{1, 2, \dots, T\}$ سیستم می‌تواند در یکی از K حالت مختلف قرار داشته باشد. بنابراین تعداد کل مسیرهای حالت ممکن (State Paths) برابر است با:

$$\text{Paths Total} = \underbrace{K \times K \times \dots \times K}_{T \text{ times}} = K^T$$

۲. علت عدم امکان اجرای جستجوی کامل (Brute-force Infeasibility):

• پیچیدگی زمانی نمایی (Exponential Complexity): برای محاسبه احتمال هر مسیر کامل، باید ضرب احتمالات گذار و انتشار در طول T گام زمانی انجام شود ($O(T)$). از این روی پیچیدگی محاسباتی روش جستجوی مستقیم برابر با $O(T \cdot K^T)$ خواهد بود.

• انفجار ترکیبیاتی (Combinatorial Explosion): رشد نمایی K^T باعث می‌شود که حتی برای مقادیر بسیار کوچک، محاسبات کامپیوتری غیرممکن شود.

مثال عددی: در یک مدل دو-حالته بسیار ساده ($K = 2$) با طول دنباله نسبتاً کوتاه ($T = 100$):

$$K^T = 2^{100} \approx 1.26 \times 10^{30} \text{ مسیر ممکن}$$

حتی سریع‌ترین ابرکامپیوترهای جهان نیز برای محاسبه و مقایسه این تعداد مسیر به میلیاردها سال زمان نیاز دارند.

۳. برتری الگوریتم ویتربی (Viterbi Algorithm): الگوریتم ویتربی با بهره‌گیری از **برنامه‌نویسی پویا (Dynamic Programming)** و اصل «زیرساختار بهینه»، تنها بهترین مسیر جزئی منتهی به هر حالت را در هر گام نگه می‌دارد. این تکنیک، پیچیدگی محاسباتی را از حالت نمایی $O(T \cdot K^T)$ به **حالت خطی $O(T \cdot K^2)$ کاهش داده و مسئله را کاملاً قابل حل می‌سازد.

پاسخ به سوال شبیه‌سازی ۶

مسئله: پیاده‌سازی الگوریتم ویتربی (Viterbi Decoding) در فضای لگاریتمی برای مدل HMM دو-حالت با انتشار گوسی، آزمایش آن روی دنباله مولد پروژ و گزارش کسر گام‌های زمانی انطباق‌یافته (Matching Fraction) بین حالات پنهان واقعی (z_t) و حالات پیش‌بینی شده ($\hat{z}_t$).

۱. جزئیات فرمول‌بندی الگوریتم ویتربی در فضای لگاریتمی:
به منظور جلوگیری از سرریز عددی (Underflow)، تمامی محاسبات ضرب به جمع در فضای لگاریتمی تبدیل شده‌اند:

۱. گام مقداردهی اولیه ($t = 1$):

$$\delta_1(j) = \log \pi_j + \log \mathcal{N}(x_1; \mu_j, \sigma_j^2), \quad j \in \{1, 2\}$$

۲. گام بازگشتی (Recursion - برای $t = 2, \dots, T$):

$$\begin{aligned} \delta_t(j) &= \max_{1 \leq i \leq K} (\delta_{t-1}(i) + \log A_{ij}) + \log \mathcal{N}(x_t; \mu_j, \sigma_j^2) \\ \psi_t(j) &= \arg \max_{1 \leq i \leq K} (\delta_{t-1}(i) + \log A_{ij}) \end{aligned}$$

۳. گام بازگشت به عقب (Backtracking):

$$\hat{z}_T = \arg \max_{1 \leq j \leq K} \delta_T(j), \quad \hat{z}_t = \psi_{t+1}(\hat{z}_{t+1})$$

۲. نتایج ارزیابی عددی و انطباق حالات:

الگوریتم روی دنباله‌ای به طول $T = 100$ تولیدشده توسط مولد HMM آزمایش گردید و نتایج عددی زیر به دست آمد:

۳. تحلیل و تفسیر نتایج: دستیابی به دقت انطباق بسیار بالای 97.00% (97 گام زمانی از 100) نشان‌دهنده موارد زیر است:

- قدرت بالای بازسازی حالات پنهان: تفکیک مناسب میانگین‌ها ($\Delta\mu = 4.0$) در کنار ترکیب اطلاعات گذار A_{ij} توسط الگوریتم ویتربی، باعث شده مدل بتواند ساختار واقعی پنهان سیستم را با دقت بسیار بالای 97% بازسازی کند.
- علت عدم انطباق 3% (3 تایم‌استپ): مقدار نویز تصادفی در توزیع گوسی در 3 گام زمانی محدود باعث تولید مشاهداتی در ناحیه دم توزیع (Tail Region) نزدیک به مرز تصمیم‌گیری شده است؛ با این حال، الگوریتم به سرعت در گام‌های بعدی مسیر بهینه را بازیابی کرده است.

جدول ۸: گزارش عملکرد و نرخ انطباق دقیق رمزگشایی ویتری در استخراج حالات پنهان

مقدار	معیار / پارامتر ارزیابی
100	طول کل دنباله (T)
2	تعداد حالات پنهان (K)
$\mu_1 = 0.0, \mu_2 = 4.0$	پارامترهای انتشار نرمال (μ_1, μ_2)
$\sigma_1 = 1.0, \sigma_2 = 1.0$	انحراف معیار انتشار (σ_1, σ_2)
100 از 97	تعداد تطابق‌های صحیح $(\sum \mathbb{I}(\hat{z}_t = z_t))$
97.00%	کسر انطباق حالات (Matching Accuracy)

سوال تئوری ۱۶

مسئله: در یک یا دو پاراگراف توضیح دهید چرا رمزگشایی ویتری (Viterbi Decoding) برای روش HMAD مفید است؟ دنباله حالت پنهان رمزگشایی‌شده چه نقشی در ساخت بردار ویژگی $\Psi(x, z)$ ایفا می‌کند؟

پاسخ:

الگوریتم رمزگشایی ویتری از این جهت برای روش تشخیص آنومالی مارکوف پنهان (HMAD) حیاتی است که مشاهدات واقعی (x) به تنهایی ساختار داخلی و مدهای کاری پنهان سیستم را آشکار نمی‌کنند. از آنجا که حالات واقعی ناپیدا هستند، الگوریتم ویتری با بهره‌گیری از برنامه‌نویسی پویا و پیچیدگی محاسباتی کارآمد $O(T \cdot K^2)$ ، احتمال‌مندترین مسیر حالات پنهان $(z^* = \arg \max_z P(x, z | \lambda))$ را برای هر دنباله ورودی استخراج می‌کند. بدون این الگوریتم، دستیابی به ساختار ترتیبی سیستم غیرممکن بود یا مستلزم محاسبات نمایی غیرعملی می‌شد؛ بنابراین ویتری نقش استخراج‌کننده «نقشه پنهان ساختار زمانی» را برای هر دنباله بر عهده دارد.

نقش اصلی دنباله حالت پنهان رمزگشایی‌شده (z^*) ، فراهم کردن یک «پل ساختاری» برای نگاشت داده‌های پیوسته زمانی به بردار ویژگی‌های آگاه از دنباله $(\Psi(x, z^*))$ است. بر اساس این مسیر بازسازی‌شده، بردار ویژگی $\Psi(x, z^*)$ دو دسته اطلاعات کلیدی را فشرده‌سازی می‌کند: اول، نحوه و الگوی گذار بین حالات پنهان در طول زمان (تعداد انتقالات c_{ij})، و دوم، آمار و نحوه انتشار مشاهدات به شرط قرار داشتن در هر حالت پنهان مشخص. در نهایت، این بردار ویژگی غنی از اطلاعات ترتیبی به عنوان ورودی به یک مدل یک-کلاسه (مانند OC-SVM) داده می‌شود؛ بدین ترتیب روش HMAD قدرت مرزبندی مدل‌های یک-کلاسه را با قابلیت مدل‌سازی دینامیک‌های زمانی ترکیب می‌نماید.

ساختار ترتیبی و مدل‌سازی مارکوف

۱. تحلیل تئوری اهمیت ساختار دنباله‌ای و مدل‌های پایه

۱. چرا ساختار دنباله‌ای در تشخیص آنومالی اهمیت دارد؟ در بسیاری از کاربردهای دنیای واقعی (مانند سنسورهای صنعتی، لاگ‌های سرور و دنباله‌های زیستی)، ارزیابی ایستا و مجزای مشاهدات کافی نیست. برخی آنومالی‌ها نه به دلیل وقوع یک مقدار غیرممکن، بلکه به دلیل وقوع یک ****الگوی گذار غیرعادی در طول زمان**** رخ می‌دهند (Sequence Anomalies). مدلی که ترتیب زمانی را نادیده بگیرد، در تشخیص این گونه آنومالی‌های ترتیبی ناکام خواهد بود.

۲. مقایسه مشاهدات مستقل، زنجیره مارکوف و مدل مارکوف پنهان (HMM)

- مشاهدات مستقل (i.i.d.): هیچ وابستگی زمانی بین داده‌ها فرض نمی‌شود ($P(X) = \prod P(X_t)$) و صرفاً احتمال حاشیه‌ای هر داده سنجیده می‌شود.
- زنجیره مارکوف (Markov Chain): وابستگی گام بعدی به گام فعلی مدل‌سازی می‌شود ($P(z_t | z_{t-1})$)، اما حالات سیستم مستقیماً قابل مشاهده هستند.
- مدل مارکوف پنهان (HMM): حالات واقعی سیستم پنهان هستند (z_t) و تحول آن‌ها تابع یک زنجیره مارکوف است؛ در حالی که مشاهدات پیوسته (x_t) از توزیع‌های انتشار گوسی متناظر با هر حالت پنهان تولید می‌شوند.

۳. نقش حالات پنهان و توزیع‌های انتشار: حالات پنهان ($z_t \in \{1, \dots, K\}$) مدهای کاری یا وضعیت‌های ساختاری داخلی سیستم را بازنمایی می‌کنند. توزیع‌های انتشار گوسی $\mathcal{N}(x_t; \mu_i, \sigma_i^2)$ نگاشت بین مشاهدات پیوسته x_t و حالات پنهان z_t را برقرار ساخته و احتمال تولید هر مشاهده در یک حالت مشخص را تعیین می‌نمایند.

۴. ضرورت الگوریتم رمزگشایی ویتربی (Viterbi Decoding): تعداد مسیرهای حالت پنهان ممکن برای دنباله‌ای به طول T برابر با K^T است که محاسبه مستقیم آن به دلیل انفجار ترکیبیاتی غیرممکن است. الگوریتم ویتربی با برنامه‌نویسی پویا و تبدیل ضرب‌ها به جمع در فضای لگاریتمی، احتمالی‌ترین مسیر حالات پنهان (z^*) را با پیچیدگی خطی $\mathcal{O}(T \cdot K^2)$ استخراج می‌کند.

۲. پیاده‌سازی کدها و ارزیابی بازسازی حالات توسط ویتربی

در این بخش، سه تابع کلیدی در پایتون پیاده‌سازی گردید و عملکرد رمزگشایی ویتربی روی داده‌های سنتتیک سنجیده شد:

جدول ۹: خلاصه توابع پیاده‌سازی شده و نتایج ارزیابی الگوریتم ویتربی

تابع پیاده‌سازی شده	مسئولیت و مشخصات
<code>compute_markov_log_likelihood(z, pi, A)</code>	محاسبه لگاریتم احتمال دنباله حالت در فضای لگاریتمی
<code>generate_gaussian_hmm_sequence(...)</code>	تولید داده‌های سنتتیک (z, x) از HMM دو-حالت گوسی
<code>viterbi_gaussian_hmm(x, pi, A, means, vars)</code>	استخراج احتمال‌مندترین مسیر حالت پنهان ($\hat{z}$)
معیار ارزیابی بازسازی حالات	
طول دنباله تست (T)	100 گام زمانی
تعداد حالات پنهان منطبق ($\sum \mathbb{I}(\hat{z}_t = z_t)$)	100 از 97
دقت انطباق حالات (Matching Accuracy)	97.00%

تحلیل دقت بازسازی حالات: الگوریتم ویتربی موفق شد با **دقت 97.00%** حالات پنهان واقعی را از روی دنباله مشاهدات نویزی بازسازی کند. این دقت بالا حاصل تفکیک‌پذیری میانگین‌های انتشار ($\mu_1 = 0.0$ و $\mu_2 = 4.0$) و مدل‌سازی صحیح احتمالات گذار A_{ij} است. خطا در ۳٪ گام‌ها به دلیل قرار گرفتن نویز گوسی در نواحی دم توزیع رخ داده است.

پاسخ به سوال تئوری ۱۷ - امتیازی

مسئله: توزیع مانا (Stationary Distribution) $v = [v_1, v_2]^T$ را برای ماتریس گذار زیر محاسبه کرده و آن را به عنوان کسر زمانی بلندمدت حضور سیستم در هر حالت تفسیر کنید:

$$A = \begin{bmatrix} 0.95 & 0.05 \\ 0.10 & 0.90 \end{bmatrix}$$

شرایط توزیع مانا عبارتند از: $v^T A = v^T$ و $\sum_{i=1}^K v_i = 1$.

۱. محاسبات ریاضی گام به گام:

بر اساس رابطه $v^T A = v^T$ ، ضرب ماتریسی زیر برای اجزای بردار $v = [v_1, v_2]^T$ تشکیل می‌شود:

$$\begin{bmatrix} v_1 & v_2 \end{bmatrix} \begin{bmatrix} 0.95 & 0.05 \\ 0.10 & 0.90 \end{bmatrix} = \begin{bmatrix} v_1 & v_2 \end{bmatrix}$$

این رابطه منجر به دستگاه معادلات خطی زیر می‌گردد:

$$0.95v_1 + 0.10v_2 = v_1 \quad (۱)$$

$$0.05v_1 + 0.90v_2 = v_2 \quad (۲)$$

با ساده‌سازی معادله (۱):

$$0.10v_2 = v_1 - 0.95v_1 \implies 0.10v_2 = 0.05v_1 \implies v_1 = 2v_2$$

حال با اعمال شرط نرمال‌سازی احتمالات ($v_1 + v_2 = 1$):

$$2v_2 + v_2 = 1 \implies 3v_2 = 1 \implies v_2 = \frac{1}{3} \approx 0.3333$$

$$v_1 = 2 \left(\frac{1}{3} \right) = \frac{2}{3} \approx 0.6667$$

بنابراین بردار توزیع مانا برابر است با:

$$v = \begin{bmatrix} \frac{2}{3} \\ \frac{1}{3} \end{bmatrix} \approx \begin{bmatrix} 0.6667 \\ 0.3333 \end{bmatrix}$$

۲. تفسیر کاربردی و بلندمدت (Long-run Interpretation):

توزیع مانا رفتار مجانبی (Asymptotic Behavior) زنجیره مارکوف را پس از سپری شدن گام‌های زمانی بسیار زیاد ($T \rightarrow \infty$) توصیف می‌کند:

• حالت اول ($v_1 = \frac{2}{3} \approx 66.67\%$): سیستم در افق زمانی بلندمدت، حدود $\frac{2}{3}^{**}$ از کل زمان کارکرد خود (۶۶٪.۰۶۶) را در حالت ۱ (حالت نرمال) سپری می‌کند.

• حالت دوم ($v_2 = \frac{1}{3} \approx 33.33\%$): سیستم در افق زمانی بلندمدت، حدود $\frac{1}{3}^{**}$ از کل زمان کارکرد خود (۳۳٪.۰۳۳) را در حالت ۲ (حالت بار سنگین) می‌گذراند.

نتیجه‌گیری: صرف‌نظر از حالت ابتدایی سیستم در شروع کار ($t = 1$)، با گذشت زمان، سیستم همواره نسبت زمان حضور دو به یک ($v_1/v_2 = 2$) را در حالت نرمال نسبت به حالت بار سنگین حفظ خواهد کرد.

پاسخ به سوال تئوری ۱۸ - امتیازی

مسئله: نرخ انتروپی (Entropy Rate) یک زنجیره مارکوف با توزیع مانا v و ماتریس گذار A از رابطه زیر به دست می‌آید:

$$H = - \sum_{i=1}^K v_i \sum_{j=1}^K A_{ij} \log A_{ij}$$

به صورت کیفی توضیح دهید که چگونه یک ماتریس گذار با «انتقالات بسیار قابل پیش‌بینی» از یک ماتریس گذار با «انتقالات تقریباً یکنواخت» متفاوت است. این مفهوم چگونه می‌تواند برای تشخیص آنومالی مفید باشد؟

پاسخ:

۱. مقایسه کیفی ماتریس‌های گذار بر اساس نرخ انتروپی (H):

- انتقالات بسیار قابل پیش‌بینی (Highly Predictable Transitions): در این حالت، سطرهاى ماتریس گذار A قطبی شده‌اند؛ یعنی درایه‌های هر سطر i به سمت 1 یا 0 گرایش دارند ($A_{ij} \approx 1$ برای یک حالت خاص و $A_{ij} \approx 0$ برای سایرین). در این وضعیت، میزان عدم قطعیت سیستم پس از هر مشاهده نزدیک به صفر است ($-\sum_j A_{ij} \log A_{ij} \approx 0$)؛ در نتیجه H بسیار کوچک (نزدیک به صفر) خواهد بود. این امر نشان‌دهنده رفتاری بسیار منظم، قطعی و ساختاریافته است.

- انتقالات تقریباً یکنواخت (Nearly Uniform Transitions): در این حالت، احتمالات گذار بین تمامی حالات تقریباً برابر است ($A_{ij} \approx \frac{1}{K}$). عدم قطعیت در این سیستم به حداکثر مقدار خود می‌رسد ($-\sum_j A_{ij} \log A_{ij} \approx \log K$)؛ بنابراین H به بیشترین مقدار ممکن ($\log K$) می‌رسد. این وضعیت نشان‌دهنده رفتاری تصادفی، بی‌نظم و فاقد الگوی ساختاری است.

۲. کاربرد در تشخیص آنومالی (Utility for Anomaly Detection): نرخ انتروپی می‌تواند به عنوان یک H معیار کلان ساختاری (Macro Structural Metric) جهت پایش وضعیت سیستم و تشخیص رفتارهای غیرعادی استفاده شود:

- تشخیص اختلالات نویزی و حملات پویشی (افزایش ناگهانی انتروپی): رفتار اسمی یک سیستم عملیاتی معمولاً دارای نرخ انتروپی پایین و مشخصی است. اگر سیستم دچار اختلال، نویز شدید یا حمله سایبری (مانند تزریق نویز یا پویش تصادفی پورت‌ها) شود، الگوی گذار حالات تصادفی شده و انتروپی دنباله به شدت افزایش می‌یابد.

- تشخیص قفل‌شدگی یا حلقه‌های بی‌نهایت (کاهش ناگهانی انتروپی): اگر سیستم دچار خرابی سخت‌افزاری یا قفل‌شدگی نرم‌افزاری در یک حلقه تکراری گردد، عدم قطعیت گذارها کاملاً از بین رفته و نرخ انتروپی به صفر افت می‌کند.

نتیجه‌گیری: استخراج انتروپی زنجیره مارکوف به مدل‌های تشخیص آنومالی (مانند HMA) اجازه می‌دهد تا علاوه بر سنجش احتمالات تک‌تک مشاهدات، **درجه بی‌نظمی کلی دنباله** را به عنوان یک ویژگی آگاه از ساختار جهت شناسایی ناهنجاری‌ها به کار گیرند.

پاسخ به سوال تئوری ۲۰ - امتیازی

مسئله: رمزگشایی پسین (Posterior Decoding) احتمال‌مندترین حالت را در هر گام زمانی مجزا انتخاب می‌کند ($z_t = \arg \max_i P(z_t = i | x, \lambda)$)، در حالی که رمزگشایی ویتربی (Viterbi Decoding) احتمال‌مندترین دنباله حالت کلان (Global Sequence) را پیدا می‌کند. توضیح دهید چرا رمزگشایی پسین ممکن است گاهی یک مسیر غیرمعتبر یا بسیار کم‌احتمال تولید کند، اما الگوریتم ویتربی همواره به ساختار گذار مدل وفادار می‌ماند.

پاسخ:

۱. عدم لحاظ احتمالات گذار در تصمیم‌گیری موضعی (Posterior Decoding): در روش رمزگشایی پسین (یا حاشیه‌ای)، انتخاب حالت z_t در زمان t کاملاً **مستقل و جداگانه** از انتخاب حالت z_{t+1} در زمان $t+1$ انجام می‌شود:

$$z_t^* = \arg \max_i P(z_t = i | x, \lambda)$$

این روش صرفاً احتمال حاشیه‌ای حضور در حالت i در تایم‌استپ t را لحاظ می‌کند و **احتمال گذار شرطی** $A_{z_t, z_{t+1}} = P(z_{t+1} | z_t)$ بین دو گام متوالی را در فرایند تصمیم‌گیری شرکت نمی‌دهد.

۲. تولید مسیر غیرمعتبر (Invalid/Impossible Path): فرض کنید براساس احتمالات پسین، حالت i در گام t بیشترین احتمال را داشته باشد ($z_t = i$) و حالت j در گام $t+1$ بیشترین احتمال را به دست آورد ($z_{t+1} = j$). رمزگشایی پسین گذار $i \rightarrow j$ را برمی‌گزیند؛ اما اگر طبق ساختار فیزیکی سیستم یا ماتریس گذار مدل، این انتقال غیرممکن باشد ($A_{ij} = 0$):

$$P(z_1, \dots, z_t = i, z_{t+1} = j, \dots, z_T, x | \lambda) = 0$$

در این حالت، **احتمال کل دنباله انتخاب‌شده برابر با صفر می‌شود** به عبارت دیگر، رمزگشایی پسین مسیری را تولید کرده که از نظر کلان غیرممکن و فاقد واقعیت فیزیکی است.

۳. رعایت یکپارچه ساختار گذار توسط الگوریتم ویتربی (Viterbi Constraint): الگوریتم ویتربی با حل مسئله بهینه‌سازی سراسری:

$$z^* = \arg \max_{z_1, \dots, z_T} P(z_1, \dots, z_T, x | \lambda)$$

حاصل ضرب احتمالات گذار A_{z_{t-1}, z_t} را مستقیماً در فرمول بازگشتی خود ($\delta_t(j) = \max_i [\delta_{t-1}(i) \cdot A_{ij}]$) اعمال می‌کند. در فضای لگاریتمی، اگر گذاری غیرمجاز باشد ($A_{ij} = 0 \implies \log A_{ij} = -\infty$)، آن مسیر به شدت جریمه شده و الگوریتم هرگز مسیری حاوی گذار غیرممکن را به عنوان خروجی نهایی انتخاب نخواهد کرد.

جدول ۱۰: مقایسه رمزگشایی پسین و رمزگشایی ویتری

ویژگی / معیار	رمزگشایی پسین (Posterior)	رمزگشایی ویتری (Viterbi)
هدف بهینه‌سازی	بیشینه‌سازی احتمال هر گام $P(z_t x)$	بیشینه‌سازی احتمال کل دنباله $P(z, x)$
اعتبارسنجی گذارها (A_{ij})	نادیده گرفتن گذارهای بین گامی	تضمین اعتبار تمام گذارها $(A_{ij} > 0)$
احتمال تولید مسیر غیرممکن	وجود دارد (احتمال کل مسیر می‌تواند 0 شود)	صفر (همواره یک مسیر معتبر تولید می‌کند)

پاسخ به سوال شبیه‌سازی ۷

مسئله: مقایسه ضرب مستقیم احتمالات و محاسبات در فضای لگاریتی برای یک زنجیره مارکوف بلند با طول $T = 5000$. محاسبه احتمال به هر دو روش و تعیین گامی که در آن ضرب مستقیم دچار سرریز عددی (Numerical Underflow) می‌شود.

۱. تحلیل تئوری خطای سرریز عددی (Underflow Threshold):
در سیستم استاندارد ممیز شناور با دقت مضاعف (IEEE 754 Double-Precision Float)، کوچک‌ترین عدد مثبت قابل نمایش تقریباً برابر با 2.22×10^{-308} (در حالت نرمال) و 4.94×10^{-324} (در حالت زیرنرمال) است. ضرب متوالی احتمالات کوچکتر از یک ($P(z_t | z_{t-1}) < 1$) باعث افت نمایی حاصل ضرب می‌شود:

$$P(z_1, \dots, z_T) = \pi_{z_1} \prod_{t=2}^T A_{z_{t-1}, z_t} \xrightarrow{T \rightarrow \infty} 0$$

هنگامی که حاصل ضرب از حد 10^{-324} کوچک‌تر شود، سیستم آن را به عنوان 0.0 مطلق ذخیره کرده و تمامی اطلاعات احتمالاتی دنباله نابود می‌شود. در مقابل، فضای لگاریتی ضرب‌ها را به جمع تبدیل کرده و محدوده بسیار وسیعی از اعداد منفی را بدون هیچ‌گونه افت دقت پوشش می‌دهد:

$$\log P(z) = \log \pi_{z_1} + \sum_{t=2}^T \log A_{z_{t-1}, z_t}$$

۲. نتایج تجربی شبیه‌سازی:

شبیه‌سازی روی یک دنباله $T = 5000$ تایی انجام گردید و نتایج دقیق مطابق خروجی اجرای کد به شرح زیر به دست آمد:

جدول ۱۱: مقایسه ضرب مستقیم و جمع لگاریتی در زنجیره مارکوف به طول $T = 5000$

معیار / پارامتر ارزیابی	مقدار
طول کل دنباله (T)	5000
گام زمانی بروز سرریز عددی (Underflow Step)	گام ۱۹۷۶
حاصل ضرب مستقیم احتمالات در گام نهایی ($P(z)$)	0.0 (کاملاً نامعتبر)
مجموع لگاریتم احتمالات در گام نهایی ($\log P(z)$)	-1893.4587

۳. نتیجه‌گیری: مطابق نتایج تجربی، ضرب مستقیم احتمالات در گام ۱۹۷۶** به حد سرریز عددی رسیده و مقدار آن به 0.0 مطلق تبدیل شد؛ در حالی که محاسبه در فضای لگاریتی توانست مقدار دقیق $\log P(z) = -1893.4587$ را بدون هیچ محدودیتی تا پایان دنباله ($T = 5000$) محاسبه کند. این آزمایش ضرورت اجتناب‌ناپذیر محاسبات در فضای لگاریتی را برای تمامی الگوریتم‌های ترتیبی (HMM) به اثبات می‌رساند.

بخش ۵

سوال تئوری ۲۱

مسئله: نگاشت ویژگی OC-SVM به صورت ایستا $\phi(x)$ است، در حالی که HMAD از نگاشت ویژگی مشترک $\Psi(x, z)$ همراه با پیشینه‌سازی روی حالات پنهان استفاده می‌کند $(f(x) = \max_{z \in \mathcal{Z}} \langle w, \Psi(x, z) \rangle - \rho)$. توضیح دهید این پیشینه‌سازی چه عملی انجام می‌دهد و چرا به شناسایی آنومالی‌هایی کمک می‌کند که ویژگی‌های ایستا از تشخیص آن عاجزند؟ پاسخ خود را با یک مثال روشن کنید.

پاسخ:

۱. مفهوم پیشینه‌سازی روی حالات پنهان $(\max_{z \in \mathcal{Z}})$: عبارت پیشینه‌سازی به دنبال یافتن احتمال‌مندترین و منطقی‌ترین «تفسیر ساختاری» یا مسیر حالات پنهان (z^*) برای دنباله مشاهدات x است که آن را تحت توزیع اسمی به بهترین شکل ممکن توصیف کند.

۲. علت برتری نسبت به نگاشت ایستا $\phi(x)$: نگاشت‌های ایستا (مانند خلاصه‌های آماری) کل دنباله را به یک بردار ثابت متراکم کرده و ساختار زمانی را کاملاً نابود می‌سازند. در مقابل، پیشینه‌سازی در HMAD تمام مسیرهای پنهان ممکن را جستجو می‌کند. اگر دنباله‌ای آنومال باشد، هیچ مسیر حالت پنهانی (z) یافت نمی‌شود که هم‌زمان با دینامیک‌های گذار اسمی و الگوی انتشار حالات مطابقت داشته باشد؛ در نتیجه مقدار پیشینه حاصل ضرب داخلی افت کرده و امتیاز اسمی پایینی به آن تعلق می‌گیرد.

۳. ارائه مثال کاربردی: دنباله دماهای یک سنسور را به صورت $60^\circ\text{C} \rightarrow 85^\circ\text{C} \rightarrow 60^\circ\text{C}$ در ۳ گام زمانی متوالی در نظر بگیرید. در نگاشت ایستا (ϕ_{summary}) ، میانگین و دامنه این دنباله کاملاً در محدوده نرمال قرار دارد. اما در HMAD، سیستم مجبور است برای توجیه این جهش و افت سریع، گذارهای پیاپی بین حالات را در بردار $\Psi(x, z)$ ثبت کند. چون این گذارهای سریع در رفتار اسمی سیستم بسیار نادر هستند، هیچ مسیر پنهانی نمی‌تواند امتیاز اسمی بالایی تولید کند و آنومالی ساختاری به درستی کشف می‌شود.

سوال تئوری ۲۲

مسئله: فرض کنید دو دنباله $x^{(1)}$ و $x^{(2)}$ دارای آمارهای خلاصه‌ای کاملاً یکسان (میانگین، واریانس، min و max برابر) باشند. آیا مدل HMAD همچنان می‌تواند امتیاز آنومالی متفاوتی به آن‌ها اختصاص دهد؟ توضیح دهید چرا.

پاسخ:

۱. پاسخ کوتاه: بله، مدل HMAD می‌تواند امتیازهای کاملاً متفاوتی به این دو دنباله اختصاص دهد.

۲. دلیل تئوری: آمارهای خلاصه‌ای ایستا نسبت به ترتیب قرارگیری مشاهدات کاملاً ناوردا (Order-Invariant) هستند. در مقابل، نگاشت ویژگی مشترک $\Psi(x, z)$ در HMAD شامل شمارش انتقالات بین حالات پنهان $(c_{ij}(z) = \sum_{t=2}^T \mathbb{I}(z_{t-1} = i, z_t = j))$ است که مستقیم وابسته به ترتیب زمانی داده‌هاست.

۳. تحلیل مکانیسم عملکرد: اگر در دنباله $x^{(1)}$ مشاهدات به صورت بلوکی و پیوسته باشند، سیستم پنهان در یک حالت باقی مانده و تعداد گذارهای خود-انتقالی (c_{11} یا c_{22}) بالا خواهد بود. اما اگر همان مقادیر در دنباله $x^{(2)}$ به صورت تصادفی برنخورند (Shuffled)، مسیر پنهان استخراج شده ($z^{(2)}$) دچار نوسانات و گذارهای مکرر بین حالات (c_{12} و c_{21}) خواهد شد. این تغییر شدید در مؤلفه‌های بردار ویژگی $\Psi(x^{(2)}, z^{(2)})$ باعث می‌شود امتیاز تصمیم‌گیری $\rho = \langle w, \Psi(x^{(2)}, z^{(2)}) \rangle - f(x^{(1)})$ تفاوت چشمگیری با $f(x^{(1)})$ داشته باشد.

پاسخ به سوال شبیه‌سازی ۸


مسئله: انجام آزمایش اسباب‌بازی (Toy Experiment) برای مقایسه دو دنباله $x^{(1)}$ (بلاک‌های پیوسته) و $x^{(2)}$ (برخورده شده/تصادفی)، بررسی آمارهای خلاصه‌ای کلی، رسم نمودارهای زمانی، تعیین حالات پنهان با شرط $z_t = 1$ به شرط $x_t < 2$ و $z_t = 2$ در غیر این صورت، محاسبه بردار ویژگی مشترک $\Psi(x, z) \in \mathbb{R}^6$ و تحلیل درایه‌های دارای بیشترین تفاوت.

۰۱. بررسی آمارهای خلاصه‌ای کلی و رسم نمودار دنباله‌ها: طبق دستورالعمل مسئله، دو دنباله به طول $T = 100$ از ترکیب ۵۰ نمونه $N(0, 1)$ و ۵۰ نمونه $N(4, 1)$ تولید گردید. آمارهای خلاصه‌ای کلی هر دو دنباله محاسبه شد که به دلیل یکسان بودن اجزا، کاملاً برابر هستند:

جدول ۱۲: مقایسه آمارهای خلاصه‌ای کلی دو دنباله پیوسته و برخورده شده

معیار آماری	دنباله ۱ (بلاک پیوسته $x^{(1)}$)	دنباله ۲ (برخورده شده $x^{(2)}$)	تفاوت
میانگین (Mean)	2.0313	2.0313	0.0000
انحراف معیار (Std Dev)	2.2113	2.2113	0.0000
حداقل (Min)	-1.8264	-1.8264	0.0000
حداکثر (Max)	6.1737	6.1737	0.0000
میانه (Median)	1.7728	1.7728	0.0000

نمودار دو سیگنال در شکل زیر ارائه شده است. تغییر فاز مشخص بین دو بلاک در گام زمانی ۵۰ برای دنباله ۱ مشهود است، در حالی که در دنباله ۲ مشاهدات به صورت تصادفی در طول زمان توزیع شده‌اند.



شکل ۱: نمودار مقایسه‌ای دنباله ۱ (بلاک‌های پیوسته) و دنباله ۲ (برخورده شده)

۰۲. استخراج بردار ویژگی مشترک $\Psi(x, z) \in \mathbb{R}^6$: با اعمال آستانه $z_t = 1$ (برای $x_t < 2$) و $z_t = 2$ (برای $x_t \geq 2$)، مؤلفه‌های بردار ویژگی مشترک شامل شمارش انتقالات (c_{ij}) و مجموع انتشارها (e_i) استخراج گردید:

جدول ۱۳: مقایسه مؤلفه‌های بردار ویژگی مشترک $\Psi(x, z) \in \mathbb{R}^6$ برای دو دنباله

مؤلفه ویژگی	دنباله ۱ (بلاک پیوسته)	دنباله ۲ (برخورده شده)	قدر مطلق تفاوت
c_{11} (Transition 1 $\rightarrow$ 1)	47.00	25.00	22.00
c_{12} (Transition 1 $\rightarrow$ 2)	3.00	26.00	23.00
c_{21} (Transition 2 $\rightarrow$ 1)	3.00	25.00	22.00
c_{22} (Transition 2 $\rightarrow$ 2)	46.00	23.00	23.00
e_1 (Sum $x \mid z = 1$)	1.16	1.16	0.00
e_2 (Sum $x \mid z = 2$)	201.98	201.98	0.00

۳. تحلیل نتایج تجربی :

۱. درایه‌های دارای بیشترین تفاوت: ۴ درایه نخست بردار ویژگی متناظر با شمارش انتقالات حالات $(c_{11}, c_{12}, c_{21}, c_{22})$ تفاوت شدید و چشمگیری را نشان می‌دهند (اختلاف عددی بین 22 تا 23 واحد).

۲. درایه‌های بدون تفاوت: دو درایه آخر مربوط به مجموع انتشارها $(e_1$ و $e_2)$ به دلیل ناوردایی نسبت به ترتیب زمانی، هیچ تفاوتی بین دو دنباله نشان نمی‌دهند (تفاوت 0.00).

۳. تفسیر تئوری: در دنباله پیوسته $x^{(1)}$ ، به دلیل ماندگاری سیستم در هر بلاک، بیشترین سهم متعلق به خود-انتقالی‌هاست $(c_{11} = 47$ و $c_{22} = 46)$. اما در دنباله برخورده شده $x^{(2)}$ ، نوسانات متوالی باعث جهش شدید درایه‌های انتقالات متقاطع شده است $(c_{12} = 26$ و $c_{21} = 25)$. این آزمایش اثبات می‌کند که نگاشت $\Psi(x, z)$ بر خلاف خلاصه‌های آماری، کاملاً به ساختار و ترتیب زمانی داده حساس است.

سوال تئوری ۲۳

مسئله: برای $K = 2$ حالت پنهان و مشاهدات اسکالر $(d = 1)$ ، تمامی ورودی‌های بردار ویژگی مشترک $\Psi(x, z)$ را به صورت صریح بنویسید. این بردار ویژگی چند ورودی دارد و هر ورودی نشان‌دهنده چه مفهومی است؟ پاسخ:

۱. تعداد ورودی‌های بردار ویژگی: بر اساس فرمول عمومی ابعاد بردار ویژگی مشترک $\Psi(x, z) \in \mathbb{R}^{K^2 + K \cdot d}$ ، به ازای $K = 2$ حالت پنهان و ابعاد مشاهدات اسکالر $d = 1$ ، تعداد کل ورودی‌ها برابر است با:

$$\text{Dimension} = 2^2 + (2 \times 1) = 4 + 2 = 6$$

بنابراین این بردار برداری ۶ بعدی در فضای $\mathbb{R}^6$ است.

۲. نمایش صریح بردار ویژگی $\Psi(x, z)$:

$$\Psi(x, z) = \left(c_{11}(z), c_{12}(z), c_{21}(z), c_{22}(z), e_1(x, z), e_2(x, z) \right)^T \in \mathbb{R}^6$$

۳. مفهوم هر یک از ورودی‌ها:

• ویژگی‌های گذار (Transition Features - ۴ ورودی اول):

- $c_{11}(z) = \sum_{t=2}^T \mathbb{I}(z_{t-1} = 1, z_t = 1)$: تعداد تکرار گذار متوالی از حالت پنهان ۱ به حالت ۱ (پایداری و خود-انتقالی در حالت ۱).

- $c_{12}(z) = \sum_{t=2}^T \mathbb{I}(z_{t-1} = 1, z_t = 2)$: تعداد تکرار گذار از حالت پنهان ۱ به حالت ۲ (تغییر فاز و خروج از حالت ۱).

- $c_{21}(z) = \sum_{t=2}^T \mathbb{I}(z_{t-1} = 2, z_t = 1)$: تعداد تکرار گذار بازگشتی از حالت پنهان ۲ به حالت ۱.

- $c_{22}(z) = \sum_{t=2}^T \mathbb{I}(z_{t-1} = 2, z_t = 2)$: تعداد تکرار گذار متوالی از حالت پنهان ۲ به حالت ۲ (پایداری و خود-انتقالی در حالت ۲).

• ویژگی‌های انتشار (Emission Features - ۲ ورودی آخر):

- $e_1(x, z) = \sum_{t=1}^T \mathbb{I}(z_t = 1) \phi(x_t)$: مجموع مقادیر مشاهده شده x_t زمانی که سیستم در حالت پنهان ۱ قرار داشته است.

- $e_2(x, z) = \sum_{t=1}^T \mathbb{I}(z_t = 2) \phi(x_t)$: مجموع مقادیر مشاهده شده x_t زمانی که سیستم در حالت پنهان ۲ قرار داشته است.

پاسخ به سوال شبیه‌سازی ۹


مسئله: پیاده‌سازی تابع `compute_joint_features(x, z, K)` جهت محاسبه بردار ویژگی $\Psi(x, z) \in \mathbb{R}^6$ (شامل نرخ‌های نرمال شده گذار $c_{ij}/(T-1)$ و میانگین‌های انتشار به ازای هر حالت e_i)، تولید ۲۰۰ دنباله نرمال و ۵۰ دنباله آنومال، محاسبه ماتریس ویژگی 250×6 ، رسم نقشه حرارتی (Heatmap) و تحلیل بصری درایه‌های تفکیک کننده.

۱. گزارش اجرای شبیه‌سازی و مقایسه آماری ویژگی‌ها: مطابق دستورالعمل مسئله، ۲۰۰ دنباله نرمال به طول $T = 100$ از توزیع $\mathcal{N}(0, 1)$ و ۵۰ دنباله آنومال شامل یک بلاک ۲۰ تایی از توزیع $\mathcal{N}(4, 1)$ تولید گردید. با اعمال آستانه سخت $z_t = 1$ (اگر $x_t < 2$) و $z_t = 2$ (اگر $x_t \geq 2$)، ماتریس ویژگی 250×6 استخراج شد. جدول زیر میانگین مؤلفه‌های بردار ویژگی $\Psi(x, z)$ را بین دو گروه نرمال و آنومال مقایسه می‌کند:

جدول ۱۴: گزارش نتایج شبیه‌سازی ۹: مقایسه میانگین مؤلفه‌های بردار ویژگی $\Psi(x, z)$ در ۲۵۰ دنباله

مؤلفه ویژگی	میانگین دنباله‌های نرمال (۲۰۰ نمونه)	میانگین دنباله‌های آنومال (۵۰ نمونه)	قدر مطلق تفاوت
$(\text{Norm. Trans } 1 \rightarrow 1) \ c_{11}$	0.9572	0.7491	0.2081
$(\text{Norm. Trans } 1 \rightarrow 2) \ c_{12}$	0.0211	0.0343	0.0132
$(\text{Norm. Trans } 2 \rightarrow 1) \ c_{21}$	0.0213	0.0341	0.0128
$(\text{Norm. Trans } 2 \rightarrow 2) \ c_{22}$	0.0004	0.1824	0.1821
$(\text{Mean } x \mid z = 1) \ e_1$	-0.0523	-0.0337	0.0186
$(\text{Mean } x \mid z = 2) \ e_2$	2.1358	3.8907	1.7549

۲. نقشه ماتریس ویژگی‌ها (Heatmap): نقشه حرارتی ماتریس ویژگی‌های استخراج شده به طول ۲۵۰ دنباله و ابعاد ۶ ویژگی در شکل زیر ترسیم شده است:



شکل ۲: نقشه حرارتی ماتریس ویژگی‌های مشترک 250×6 ($\Psi(x, z)$) و مرز تفکیک گروه‌های نرمال و آنومال

۳. تحلیل تجربی و تعیین درایه‌های تفکیک کننده بصری (بخش: c) بر اساس نقشه حرارتی و نتایج عددی استخراج شده، سه درایه از بردار $\Psi(x, z)$ بیشترین نقش را در تفکیک بصری و ساختاری دو گروه ایفا می‌کنند:

۱. ویژگی e_2 (میانگین انتشار در حالت ۲ - بیشترین تفکیک): این درایه دارای بزرگ‌ترین اختلاف عددی (1.7549) بین دو گروه است. در دنباله‌های نرمال، مقدار e_2 برابر 2.1358 است (زیرا تنها مقادیر اندکی از نویز گوسی که بالای آستانه ۲ قرار گرفته‌اند به این حالت می‌روند)، اما در دنباله‌های آنومال با ورود بلاک $\mathcal{N}(4, 1)$ ، میانگین این مشاهدات به 3.8907 جهش می‌کند. در نقشه حرارتی، این ستون کاملاً روشن و متمایز است.

۲. ویژگی c_{22} (نرخ خود-انتقالی حالت ۲): در دنباله‌های نرمال، احتمال ماندن متوالی در حالت ۲ تقریباً صفر است (0.0004). اما به دلیل پیوسته بودن بلاک آنومالی ۲۰ تایی، مقدار c_{22} در دنباله‌های آنومال به 0.1824 افزایش می‌یابد (اختلاف 0.1821) و در نقشه حرارتی به صورت یک نوار مشخص روشن نمایان می‌شود.

۳. ویژگی c_{11} (نرخ خود-انتقالی حالت ۱): در دنباله‌های نرمال، سیستم تقریباً همیشه در حالت ۱ می‌ماند (0.9572). اما با ورود ۲۰ گام آنومال، این نرخ به 0.7491 افت می‌کند (اختلاف 0.2081).

نتیجه‌گیری: ترکیب ویژگی‌های گذار ساختاری (c_{11}, c_{22}) و ویژگی انتشار (e_2)، مرز جداکننده کاملاً شفاف ایجاد کرده است که ورودی فوق‌العاده مناسبی برای مدل‌های کلاسیفایر یک-کلاس مانند OC-SVM فراهم می‌سازد.

سوال تئوری ۲۴

مسئله: الگوریتم آموزش تناوبی بین یک گام رمزگشایی و تتری (Viterbi Step) و یک گام آموزش OC-SVM نوسان می‌کند. اگر این الگوریتم تنها برای یک تکرار ($M = 1$) اجرا شود چه اتفاقی می‌افتد؟ اجرای تکرارهای بیشتر چگونه مدل یادگرفته شده را بهبود می‌بخشد؟

پاسخ:

۱. پیامدهای اجرای تنها یک تکرار ($M = 1$): اگر الگوریتم تنها در ۱ تکرار متوقف شود، مسیر حالات پنهان اولیه ($z^{(1)}$) کاملاً وابسته به پارامترهای اولیه و تقریبی مدل HMM (مانند خوشه‌بندی اولیه K-means) خواهد بود. در نتیجه:

- بردار ویژگی‌های مشترک اولیه ($\Psi(x, z^{(1)})$) بر اساس حالات پنهان ناپخته و بهبودنیافته تشکیل می‌شود.
- مدل OC-SVM مرز تصمیم‌گیری خود را روی ویژگی‌هایی تنظیم می‌کند که هنوز با دینامیک‌های واقعی داده‌های اسمی انطباق کامل نیافته‌اند و نرخ خطای تشخیص افزایش می‌یابد.

۲. نحوه بهبود مدل در تکرارهای بیشتر ($M > 1$): اجرای تکرارهای متعدد، یک چرخه بازخورد مثبت و تقویت متقابل (Mutual Reinforcement Loop) ایجاد می‌کند:

- بازآراست پارامترهای انتشار و گذار: پس از هر گام ویتری، پارامترهای توزیع گوسی (μ_k, σ_k^2) و ماتریس گذار (A_{ij}) بر اساس تخصیص‌های جدید بروزرسانی می‌شوند.
- بهبود دقت استخراج مسیر پنهان: با دقیق‌تر شدن پارامترهای HMM، الگوریتم ویتری در تکرار بعدی مسیرهای پنهان با کیفیت‌تر و منطقی‌تر ($z^{(m)}$) استخراج می‌کند.
- شفاف‌سازی بردار ویژگی $\Psi(x, z)$: با تثبیت حالات پنهان واقعی، درایه‌های بردار ویژگی ۶ بعدی (شامل نرخ‌های گذار c_{ij} و انتشارهای e_k) ساختار اسمی داده‌ها را به شکل بسیار شفاف‌تری بازتاب می‌دهد و مرز تصمیم OC-SVM را فشرده‌تر و دقیق‌تر می‌سازند.

پاسخ به سوال شبیه‌سازی ۱۰

حلقه ساده‌شده HMAD با $K = 2$ ، مقداردهی اولیه K-means روی تمام تاپم‌استپ‌های ۲۹۲ ضربان نرمال، $M_{\max} = 10$ و $\nu = 0.1$ اجرا شد. هیچ مشاهده‌ای از آزمون در تخمین پارامترهای HMM یا مقیاس‌ساز ویژگی مشترک وارد نشد.

جدول ۱۵: روند همگرایی HMAD روی آموزش نرمال ECG5000

تکرار	درصد انتساب‌های تغییرکرده	میانگین امتیاز آموزش
۱	۱۰۰٫۰۰۰	۰٫۶۵۷۳
۲	۰٫۶۸۵	۰٫۳۵۰۱

از آنجا که تغییر در تکرار دوم کمتر از یک درصد بود، توقف زودهنگام فعال شد. پارامترهای نهایی عبارت‌اند از

$$\mu = (-2.4556, 0.1907), \quad \sigma^2 = (1.5563, 0.4444),$$

$$\pi = (0.7911, 0.2089), \quad A = \begin{bmatrix} 0.8921 & 0.1079 \\ 0.0031 & 0.9969 \end{bmatrix}.$$

این دو حالت برچسب پزشکی از پیش تعیین‌شده نیستند؛ آن‌ها دو رژیم دامنه‌ای آموخته‌شده از مورفولوژی ضربان نرمال‌اند.

جدول ۱۶: پارامترهای نهایی توزیع انتشار دو حالت پنهان


حالت	میانگین μ_k	واریانس σ_k^2	تفسیر صرفاً محاسباتی
۱	-2.4556	1.5563	رژیم دامنه پایین تر و گذرا
۲	0.1907	0.4444	رژیم غالب پیرامون خط مبنا

جدول ۱۷: پارامترهای اولیه و انتقالی مدل آموخته شده

پارامتر	مقدار
π	(0.7911, 0.2089)
A_{11}, A_{12}	(0.8921, 0.1079)
A_{21}, A_{22}	(0.0031, 0.9969)

مراحل هر تکرار حلقه آموزش:

۱. با پارامترهای فعلی HMM، مسیر ویتربی هر ضربان نرمال محاسبه شد.
 ۲. از زوج (x, z^*) چهار نرخ گذار نرمال شده و دو میانگین انتشار استخراج و بردار $\Psi(x, z^*) \in \mathbb{R}^6$ ساخته شد.
 ۳. مقیاس ساز و OC-SVM ساختاری فقط روی همین بردارهای آموزش نرمال برازش شدند.
 ۴. پارامترهای انتشار و گذار از مسیرهای تازه بازآورد و درصد تغییر انتساب‌های حالت محاسبه شد.
- توقف پس از دو تکرار به معنی اثبات بهینه سراسری نیست؛ تنها نشان می‌دهد مسیرهای حالت تحت قاعده توقف تعریف شده پایدار شده‌اند. برای جلوگیری از ادعای پزشکی ناموجه، حالت‌ها صرفاً رژیم‌های آماری نامیده می‌شوند.



شکل ۳: پروفایل همگرایی HMAD روی ضربان‌های نرمال ECG5000

پاسخ به سوالات تئوری - بخش ۴.۵

سوال تئوری ۲۵

مسئله: در طول فاز پیش‌بینی (Prediction)، چرا اجرای الگوریتم رمزگشایی ویتری روی دنباله تست ضروری است و نمی‌توان از یک مسیر حالت پنهان ثابت یا تصادفی استفاده کرد؟ اگر گام ویتری حذف شود و برای تمامی دنباله‌های تست از مسیر ثابت $z = (1, 1, \dots, 1)$ استفاده شود، چه مشکلی پیش می‌آید؟
پاسخ:

۱. ضرورت اجرای الگوریتم ویتری در فاز پیش‌بینی: الگوریتم ویتری بر اساس پارامترهای یادگرفته‌شده HMM (π, A, B) ، احتمال‌مندترین مسیر حالات پنهان $(z^* = \arg \max_z P(x, z | \lambda))$ را برای یک دنباله تست جدید x استخراج می‌کند. این گام تعیین می‌کند که مشاهدات پیوسته زمانی تحت کدام «تفسیر ساختاری اسمی» بهترین توجیه را دارند. بدون الگوریتم ویتری، امکان استخراج بردار ویژگی‌های آگاه از ساختار زمانی $\Psi(x, z^*)$ وجود ندارد.

۲. پیامدهای حذف گام ویتری و فرض حالت ثابت $z = (1, 1, \dots, 1)$: اگر گام ویتری حذف شود و تمام حالات به صورت ساده‌لوحانه $z_t = 1$ فرض شوند، سه مشکل حاد رخ می‌دهد:

- کور شدن کامل ویژگی‌های گذار (c_{ij}) : تمام شمارش‌های انتقالات مربوط به حالت ۲ (c_{12}, c_{21}, c_{22}) برابر ۰.۰ شده و $c_{11} = 1.0$ می‌گردد. در نتیجه مدل نسبت به هرگونه تغییر فاز، نوسان یا آنومالی ساختاری کاملاً «کور» می‌شود.
- تخریب ویژگی‌های انتشار (e_i) : تمام مشاهدات سیگنال x_t بدون توجه به مقدارشان به حالت ۱ نسبت داده می‌شوند $(e_1 = \sum x_t)$ و $e_2 = 0$ می‌گردد. این کار بردار ویژگی ۶ بعدی را به یک جمع ساده ایستای بدون ترتیب تنزل می‌دهد.
- از دست رفتن ماهیت HMAD: مدل توانایی تفکیک دنباله‌های نرمال از آنومال را از دست داده و عملکرد آن به شدت افت می‌کند (معیار ROC-AUC به شدت سقوط خواهد کرد).

پاسخ به سوال شبیه‌سازی ۱۱

مدل آموزش‌دیده روی کل بخش رسمی آزمون ارزیابی شد. برای هر ضربان، مسیر حالت با ویتربی استخراج، $\Psi(x, z^*) \in \mathbb{R}^6$ محاسبه و سپس با OC-SVM امتیازدهی شد.

جدول ۱۸: نتایج پیش‌بینی HMAD و مقایسه با خط پایه

F1	Recall	Precision	ROC-AUC	مدل
۰٫۹۰۷۱	۰٫۹۹۷۹	۰٫۸۳۱۴	۰٫۹۸۴۰	OC-SVM Flattened
۰٫۸۹۱۲	۰٫۹۴۶۶	۰٫۸۴۱۹	۰٫۹۵۷۷	HMAD

در آزمایش کنترلی با انتساب ثابت $z_t = 1$ ، تمام بردارهای ویژگی مشترک از نظر گذار یکسان شدند و ROC-AUC به ۰٫۵۰۰۰ سقوط کرد. بنابراین ویتربی برای استخراج اطلاعات مفید ضروری است. با این حال، HMAD

ساده از خط پایه پهن شده ضعیف تر بود؛ علت محتمل، فشرده شدن شکل موج ۱۴۰ بعدی به تنها شش ویژگی و از دست رفتن جزئیات مکانی ECG است.

تحلیل تفصیلی پیش بینی و نقش مسیر ویتربی

در مرحله پیش بینی، پارامترهای HMM مقیاس ساز و مدل یک کلاسه همگی ثابت نگه داشته شدند. برای هر دنباله آزمون ابتدا مسیر

$$z^* = \arg \max_z \log P(x, z \mid \pi, A, \mu, \sigma^2)$$


با الگوریتم ویتربی محاسبه شد؛ سپس بردار مشترک از همان مسیر ساخته و امتیاز نهایی $s(x) = -f(x)$ گزارش گردید. هیچ برچسب آزمونی در رمزگشایی یا محاسبه ویژگی دخالت نداشت.

• موفقیت مدل: Precision برابر 0.8419 از مقدار 0.8314 خط پایه پهن شده کمی بیشتر است؛ بنابراین نمایش فشرده در نقطه کار صفر بخشی از مثبت های کاذب را کاهش داده است.

• شکست مدل: Recall به 0.9466 و ROC-AUC به 0.9577 کاهش یافته است. دو میانگین انتشار و چهار نرخ گذار برای بازسازی تمام تفاوت های شکل موج کافی نیستند.

• آزمایش حذف مسیر: در حالت ثابت، شمارش انتقال ها و میانگین های وابسته به حالت تنوع ساختاری لازم را از دست دادند و رتبه بندی به سطح تصادفی رسید. این نتیجه نقش واقعی مسیر پنهان را نشان می دهد، اما برتری HMD بر بهترین خط پایه را ثابت نمی کند.

نکته تفسیری: مسیرهای نشان داده شده در شکل تنها نمونه های نماینده از خروجی ثابت آزمون اند و برای انتخاب یا حذف نمونه ها استفاده نشده اند. اختلاف مسیر در نواحی قله و بازگشت ضربان قابل مشاهده است، ولی برچسب حالت ها معنای بالینی مستقیم ندارد.



شکل ۴: مسیر حالت ویتربی برای یک ضربان نرمال و یک ضربان آتومال که درست طبقه بندی شده اند

شبهه‌کد کامل الگوریتم‌های HMAD :

طبق دستورالعمل پروژه، شبهه‌کد کامل، خودکفا و مستقل الگوریتم‌های آموزش و پیش‌بینی HMAD در ادامه ارائه شده است تا بدون نیاز به مراجعه به متون بیرونی قابل پیاده‌سازی باشد.

الگوریتم ۱: فرآیند آموزش تناوبی HMAD (HMAD Training Loop)

۱. ورودی‌ها: مجموعه دنباله‌های آموزشی اسمی $X_{\text{train}} = \{x^{(1)}, \dots, x^{(N)}\}$ به طول T ، تعداد حالات پنهان $K = 2$ ، پارامتر hyperparameter مدل OC-SVM (ν) ، حداکثر تکرار M_{max} .

۲. گام ۱ (مقداردهی اولیه):

• $X_{\text{pooled}} = \bigcup_{i=1}^N \{x_t^{(i)}\}_{t=1}^T$:تجميع تمامی گام‌های زمانی داده‌ها:

• اجرای K-means با $K = 2$ روی X_{pooled} جهت استخراج مراکز اولیه μ_1, μ_2 و واریانس‌ها σ_1^2, σ_2^2 .

• تنظیم ماتریس گذار اولیه: $A = \begin{bmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{bmatrix}$ و توزیع اولیه $\pi = [0.5, 0.5]^T$.

۳. گام ۲ (حلقه تکرار آموزش $m = 1 \dots M_{\text{max}}$):

(آ) استخراج حالات پنهان: برای هر دنباله $x^{(i)}$ ، اجرای الگوریتم ویتري در فضای لگاریتمی جهت محاسبه $z^{(i)} = \arg \max_z \log P(x^{(i)}, z | \pi, A, \mu, \sigma^2)$.

(ب) محاسبه بردار ویژگی مشترک: برای هر جفت $(x^{(i)}, z^{(i)})$ ، تشکیل بردار $\Psi(x^{(i)}, z^{(i)}) \in \mathbb{R}^{K^2+K}$ شامل:

$$c_{jk} = \frac{1}{T-1} \sum_{t=2}^T \mathbb{I}(z_{t-1}^{(i)} = j, z_t^{(i)} = k), \quad e_k = \frac{\sum_{t: z_t^{(i)} = k} x_t^{(i)}}{\sum_{t=1}^T \mathbb{I}(z_t^{(i)} = k) + \epsilon}$$

(ج) آموزش OC-SVM: نرمال‌سازی ماتریس ویژگی‌ها با StandardScaler و fit کردن مدل One-Class SVM با پارامتر ν .

(د) بروزرسانی پارامترهای HMM:

$$\mu_k = \text{mean}(\{x_t^{(i)} | z_t^{(i)} = k\}), \quad \sigma_k^2 = \text{var}(\{x_t^{(i)} | z_t^{(i)} = k\})$$

$$A_{jk} = \frac{\sum_{i=1}^N \sum_{t=2}^T \mathbb{I}(z_{t-1}^{(i)} = j, z_t^{(i)} = k)}{\sum_{i=1}^N \sum_{t=2}^T \mathbb{I}(z_{t-1}^{(i)} = j)}$$

(ه) بررسی همگرایی: اگر درصد تغییر حالات پنهان نسبت به تکرار قبل کمتر از 1% باشد، خروج از حلقه.

۴. خروجی: پارامترهای یادگرفته‌شده HMM (π, A, μ, σ^2) ، مقیاس‌دهنده StandardScaler و مدل آموزش‌دیده OC-SVM.

الگوریتم ۲: خط لوله پیش‌بینی و ارزیابی HMAD (HMAD Prediction Pipeline)

۱. ورودی‌ها: دنباله جدید آزمون $x = (x_1, \dots, x_T)$ ، پارامترهای یادگرفته‌شده $HMM(\pi, A, \mu, \sigma^2)$ ، مقیاس‌دهنده StandardScaler و مدل OC-SVM.

۲. گام ۱ (استخراج حالت پنهان بهینه با ویتری): اجرای الگوریتم ویتری در فضای لگاریتمی روی دنباله x جهت یافتن مسیر حالت پنهان با بیشترین احتمال:

$$z^* = \arg \max_{z \in \mathcal{Z}} \left(\log \pi_{z_1} + \log B_{z_1}(x_1) + \sum_{t=2}^T (\log A_{z_{t-1}, z_t} + \log B_{z_t}(x_t)) \right)$$

۳. گام ۲ (ساخت بردار ویژگی مشترک): محاسبه بردار $\Psi(x, z^*) = (c_{11}, c_{12}, c_{21}, c_{22}, e_1, e_2)^T$ بعدی ۶.

۴. گام ۳ (ارزیابی با OC-SVM)

• مقیاس‌سازی بردار ویژگی: $\Psi_{\text{scaled}} = \text{StandardScaler.transform}(\Psi(x, z^*))$

• محاسبه امتیاز تصمیم‌گیری: $f(x) = \text{OC-SVM.decision_function}(\Psi_{\text{scaled}})$

۵. خروجی: امتیازی $f(x) \geq 0$ به معنی اسبی/نرمال و $f(x) < 0$ به معنی آنومال است.

بخش ۶: برنامه پیاده‌سازی و آزمایش‌ها

۱۰۶ مجموعه داده نهایی: ECG5000

ECG5000 از آرشیو معتبر UCR/TSML و بر پایه رکورد chf07 پایگاه PhysioNet BIDMC CHF انتخاب شد. داده خام از ثبت طولانی ECG یک بیمار ۴۸ ساله با نارسایی قلبی شدید منشأ گرفته است، اما تقسیم به دنباله‌ها دل‌بخوایی نیست: هر دنباله یک ضربان قلب است که بر اساس رخداد فیزیولوژیک استخراج و به طول ۱۴۰ درون‌یابی شده است. ترتیب نمونه‌ها شکل موج و زمان نسبی اجزای ضربان را مشخص می‌کند. کلاس ۱ نرمال و اجتماع کلاس‌های ۲ تا ۵ شامل PVC، R-on-T PVC، ضربان زودرس فوق‌بطنی و ضربان طبقه‌بندی‌نشده به عنوان آنومال تعریف شد. منبع و سیاست split پیش از اجرای مدل تثبیت شد.

جدول ۱۹: آمار ثابت مجموعه داده ECG5000

بخش	نرمال	آنومال	مجموع
آموزش مورد استفاده	۲۹۲	۰	۲۹۲
آزمون رسمی و دست‌نخورده	۲۶۲۷	۱۸۷۳	۴۵۰۰

آموزش شامل $292 \times 140 = 40880$ تایم‌استپ نرمال است و شروط حداقل اندازه را برآورده می‌کند. طول همه دنباله‌ها ثابت و برابر ۱۴۰ و تعداد مقادیر گمشده صفر است. هش آرشیو داندوده‌شده:

SHA-256: 41F6DE20AC895E9CE31753860995518951F1ED42A405D0E51C909D27E3B3C5A4

۱.۱.۶ منبع، منشأ و واحد دنباله

نسخه استفاده شده مستقیماً از صفحه ECG5000 در آرشیو UCR/TSML دریافت شد. طبق توضیح آرشیو، داده از رکورد chf07 پایگاه نارسایی قلبی BIDMC منشأ می گیرد. واحد تحلیل یک ضربان از پیش تقسیم شده است، نه یک پنجره دلخواه از سیگنال طولانی. هر ضربان پس از استخراج به ۱۴۰ نقطه درونیابی شده و بنابراین همه دنباله‌ها طول یکسان دارند.

۲.۱.۶ تعریف نرمال و آنومال در سطح دنباله

برچسب در سطح کل ضربان تعریف می شود. کلاس ۱ ضربان نرمال است و کلاس‌های ۲ تا ۵ به ترتیب انواع ضربان ناهنجار یا طبقه‌بندی نشده را تشکیل می دهند. برای مسئله تک کلاسه، کلاس‌های ۲ تا ۵ بدون تغییر داخلی در یک برچسب آنومال ادغام شدند. این ادغام فقط برای ارزیابی دودویی است و هیچ نمونه‌ای بر اساس آسان یا دشوار بودن انتخاب نشده است.

جدول ۲۰: توزیع برچسب‌های رسمی ECG5000 و نقش آن‌ها در پروژه

کلاس	توصیف آرشیو	آموزش رسمی	آزمون رسمی	نقش در تشخیص آنومالی
۱	Normal (N)	۲۹۲	۲۶۲۷	نرمال
۲	R-on-T PVC	۱۷۷	۱۵۹۰	آنومال
۳	PVC	۱۰	۸۶	آنومال
۴	SP or ectopic beat	۱۹	۱۷۵	آنومال
۵	Unclassified beat	۲	۲۲	آنومال

۳.۱.۶ انطباق با معیارهای اعلام شده استاد

۱. ترتیب ۱۴۰ مشاهده، مورفولوژی زمانی یک ضربان را می سازد و جابه‌جایی یا حذف ترتیب معنای فیزیولوژیک نمایش را تغییر می دهد.
۲. آموزش نهایی شامل ۲۹۲ دنباله کاملاً نرمال و ۴۰۸۸۰ تایم‌استپ است؛ بنابراین هر دو حداقل ۱۰۰ دنباله و ۵۰۰۰ تایم‌استپ رعایت شده‌اند.
۳. آزمون رسمی ۱۸۷۳ آنومال و ۲۶۲۷ نرمال دارد و برای ارزیابی پایدار بسیار بزرگ‌تر از حداقل خواسته شده است.
۴. آنومالی‌ها واقعی و در شکل کامل ضربان ظاهر می شوند؛ هیچ جهش مصنوعی با دامنه بسیار بزرگ به داده تزریق نشده است.
۵. تقسیم آموزش و آزمون رسمی پیش از مدل‌سازی ثابت شد و کل آزمون بدون حذف کلاس یا نمونه حفظ گردید.

۲.۶ پیش‌پردازش، جلوگیری از تسریب و بازتولیدپذیری

تنها برچسب‌های بخش رسمی آموزش برای جدا کردن ۲۹۲ ضربان نرمال استفاده شدند. بخش رسمی آزمون بدون حذف، نمونه‌برداری گزینشی یا جابه‌جایی حفظ شد. برای هر بازنمایی، StandardScaler فقط روی ویژگی‌های

آموزش نرمال برازش و همان تبدیل روی آزمون اعمال شد. $\nu = 0.1$ و $\gamma = \text{scale}$ پیش از ارزیابی اصلی ثابت شدند؛ آستانه عملیاتی همان $f(x) = 0$ بود. فایل آرشیو، فایل‌های استخراج‌شده، manifest کد مشترک ecg5000_hmad.py، seed ثابت ۱۴۰۵ و خروجی results_ecg5000.json همراه پروژه ارائه شده‌اند. زمان تقریبی برازش و امتیازدهی خط پایه ۰.۰۶ ثانیه و زمان آموزش/امتیازدهی HMAD روی کل آزمون ۹.۸۶ ثانیه بود.

۱۰.۲.۰۶ دسترسی، اعتبار فایل و بازتولیدپذیری

آرشیو اصلی در مسیر data/ECG5000 نگهداری می‌شود و هش SHA-256 آن در بخش قبل گزارش شد. seed تمام بخش‌های تصادفی، از مقداردهی اولیه K-means تا ساخت‌های cohort تحلیل حساسیت، برابر ۱۴۰۵ است. فایل manifest منبع، نام فایل‌های train/test و سیاست ادغام کلاس‌ها را ثبت می‌کند.

۲۰.۲.۰۶ استانداردسازی بدون تسمیه

برای هر خانواده ویژگی یک StandardScaler مستقل ساخته شد. اگر Φ_{tr} ماتریس ویژگی آموزش باشد، پارامترهای

$$\hat{\mu}_j = \frac{1}{n} \sum_{i=1}^n \Phi_{ij}, \quad \hat{\sigma}_j^2 = \frac{1}{n} \sum_{i=1}^n (\Phi_{ij} - \hat{\mu}_j)^2$$

فقط از ۲۹۲ ضریب نرمال محاسبه شدند. سپس تبدیل $(\Phi - \hat{\mu})/\hat{\sigma}$ بدون بازبرازش روی آزمون اعمال شد. ویژگی‌های خام آزمون، توزیع کلاس‌ها و برچسب‌ها در هیچ مرحله آموزشی وارد نشدند.

۳۰.۲.۰۶ قرارداد امتیازدهی و معیارها

خروجی decision_function در سمت نرمال مثبت است؛ برای سازگاری با تعریف متداول امتیاز آنومالی، $s(x) = f(x) -$ استفاده شد. ROC-AUC از $s(x)$ و برچسب دودویی رسمی محاسبه گردید. برای معیارهای آستانه‌ای، پیش‌بینی $f(x) < 0$ آنومال در نظر گرفته شد. این مرز پس از دیدن آزمون جابه‌جا نشد.

۴۰.۲.۰۶ دامنه محاسباتی و زمان اجرا


پیچیدگی ویتربی برای یک دنباله $\mathcal{O}(K^2T)$ و حلقه ساده‌شده آموزش برای M تکرار و n دنباله تقریباً $\mathcal{O}(MnK^2T)$ است. با $K = 2$ و $T = 140$ ، مدل روی رایانه معمولی قابل اجرا باقی می‌ماند.

جدول ۲۱: دامنه و زمان تقریبی اجرای پیکربندی نهایی

مرحله	حجم داده	زمان تقریبی
خط پایه پهن‌شده: استخراج، برازش و امتیازدهی	۲۹۲ آموزش و ۴۵۰۰ آزمون	0.06 ثانیه
حلقه آموزش و ارزیابی HMAD	$K = 2$ ، دو تکرار مؤثر	9.86 ثانیه

۳.۶ ارزیابی اصلی و نمودارها

۱.۳.۶ نمونه‌های واقعی نرمال و آنومال




شکل ۵: یک ضربان نرمال کلاس ۱ و یک ضربان آنومال کلاس ۲ از بخش رسمی آزمون

برخلاف داده قبلی، بازه مصنوعی $\mathcal{N}(4, 1)$ تزریق نشده است؛ اختلاف در مورفولوژی کامل ضربان، زمان قله‌ها، پهنا و توالی تغییرات دیده می‌شود.

۲.۳.۶ نتایج روی آزمون رسمی ثابت

جدول ۲۲: نتایج اصلی روی تمام ۴۵۰۰ ضربان آزمون

F1	Recall	Precision	ROC-AUC	مدل
۰٫۹۰۷۱	۰٫۹۹۷۹	۰٫۸۳۱۴	۰٫۹۸۴۰	OC-SVM Flattened
۰٫۸۶۶۱	۰٫۹۲۷۴	۰٫۸۱۲۴	۰٫۹۵۱۸	OC-SVM Summary
۰٫۹۰۷۵	۰٫۹۹۸۴	۰٫۸۳۱۹	۰٫۹۸۲۳	OC-SVM Window
۰٫۸۹۱۲	۰٫۹۴۶۶	۰٫۸۴۱۹	۰٫۹۵۷۷	HMA




شکل ۶: منحنی‌های ROC روی بخش رسمی و دست نخورده آزمون ECG5000

۳.۳.۶ تحلیل حساسیت نرخ آنومالی

برای پاسخ به الزام تحلیل حساسیت بدون ایجاد های test بسیار کوچک، چهار cohort ثابت و از پیش تعیین شده، هر یک شامل ۲۰۰۰ نمونه، از آزمون رسمی ساخته شدند. تعداد آنومال به ترتیب ۲۰، ۱۰۰، ۲۰۰ و ۴۰۰ بود؛ بنابراین حتی حالت یک درصد نیز حداقل ۲۰ آنومال دارد. این ها cohort برای انتخاب مدل استفاده نشدند.

جدول ۲۳: ROC-AUC در های cohort حساسیت ثابت

HMAD	OC-SVM Summary	OC-SVM Flattened	نرخ آنومالی
۰٫۹۴۵۲	۰٫۹۸۱۲	۰٫۹۹۲۱	۰٫۰۱
۰٫۹۶۵۸	۰٫۹۶۷۶	۰٫۹۸۹۷	۰٫۰۵
۰٫۹۶۱۹	۰٫۹۶۳۵	۰٫۹۸۸۶	۰٫۱۰
۰٫۹۶۵۲	۰٫۹۶۱۴	۰٫۹۹۰۲	۰٫۲۰



شکل ۷: پروفایل حساسیت ROC-AUC روی های cohort ثابت ۲۰۰۰ تایی

۴.۶ مقایسه بازنمایی های خط پایه

بازنمایی پهن شده $\mathbb{R}^{140}$ بهترین AUC را داشت؛ خلاصه پنجره ای ۲۰ بعدی تقریباً هم سطح و خلاصه کلی ۵ بعدی ضعیف تر بود. این نتیجه نشان می دهد ترتیب و مکان نسبی بخش های ضربان اطلاعات افزوده دارد، ولی هم ترازى موجود در ECG۵۰۰۰ باعث می شود بردار خام نیز بسیار رقابتی باشد.

۱.۴.۶ بازنمایی پهن شده (Flattened Sequence)

در این روش هیچ فشرده سازی انجام نمی شود و

$$\phi_{\text{flat}}(x) = [x_1, x_2, \dots, x_{140}]^T \in \mathbb{R}^{140}.$$

این نمایش ترتیب، مکان قله ها و شکل کامل موج را حفظ می کند. نقطه ضعف آن وابستگی به طول ثابت و هم ترازى است؛ در داده هایی با تغییر فاز یا طول متغیر، مؤلفه های متناظر الزاماً رخداد یکسانی را نمایش نمی دهند.

۲.۴.۶ خلاصه آماری کلی (Global Summary)

بردار پنج بعدی

$$\phi_{\text{summary}}(x) = [\mu(x), \sigma(x), \min(x), \max(x), \text{median}(x)]^T$$

توزیع حاشیه ای دامنه را توصیف می کند. این روش کم بعد و سریع است، اما دو ضربان با ترتیب متفاوت و آمار کلی مشابه را یکسان می بیند. افت AUC آن شاهد مستقیم هزینه حذف ترتیب در این مسئله است.

۳.۴.۶ خلاصه آماری پنجره ای (Window Summary)

ضربان به $W = 10$ پنجره متوالی و بدون هم پوشانی، هر کدام با طول ۱۴، تقسیم شد. از هر پنجره میانگین و انحراف معیار استخراج گردید:

$$\phi_{\text{window}}(x) = [\mu_1, \sigma_1, \dots, \mu_{10}, \sigma_{10}]^T \in \mathbb{R}^{20}.$$

این نمایش موقعیت تقریبی اجزای ضربان را با بعد بسیار کمتر از موج خام نگه می دارد.

۴.۴.۶ تحلیل تجربی سه بازگامی

۱. پهن شده: بیشترین ROC-AUC برابر 0.9840 را ثبت کرد؛ بنابراین هم ترازوی ضربان‌ها اجازه داده است مدل از جزئیات نقطه به نقطه استفاده کند.
 ۲. پنجره‌ای: با AUC برابر 0.9823 تقریباً هم سطح بود و در آستانه صفر اندکی F1 بالاتر داشت. این نتیجه نشان می‌دهد ساختار محلی پنجره‌ای بخش عمده اطلاعات را حفظ می‌کند.
 ۳. خلاصه کلی: با AUC برابر 0.9518 ضعیف تر بود؛ حذف مکان و ترتیب قله‌ها موجب از دست رفتن اطلاعات تشخیصی شد.
- معیار رتبه‌بندی اصلی ROC-AUC است، در حالی که اختلاف کوچک F1 به نقطه کار ثابت صفر مربوط می‌شود. از آزمون برای انتخاب آستانه یا تنظیم نمایش استفاده نشده است.

۵.۶ تحلیل مدل HMAD

بردار مشترک شش بعدی شامل چهار نرخ گذار و دو میانگین انتشار وابسته به حالت بود. ویتربی ضروری بود، زیرا حذف آن AUC را به ۰.۵ رساند. با وجود این، HMAD نهایی از baseline flattened ضعیف تر شد. نتیجه منفی از نظر علمی معنادار است: مدل دنباله‌ای ساده با دو حالت، شکل موج ۱۴۰ بعدی را بیش از حد فشرده می‌کند. بنابراین «آگاه از توالی بودن» به تنهایی تضمین برتری نیست؛ نمایش باید با ساختار داده متناسب باشد.

۱.۵.۶ فضای حالت و انتشار

فضای پنهان $\mathcal{Z} = \{1, 2\}$ است و برای هر حالت یک انتشار گوسی تک متغیره با (μ_k, σ_k^2) در نظر گرفته شد. مقداردهی اولیه با K-means روی تمام تایم‌استپ‌های آموزش نرمال انجام شد. این خوشه‌بندی فقط نقطه شروع محاسباتی است و تفسیر بالینی برای حالت‌ها تعریف نمی‌کند.

۲.۵.۶ بردار ویژگی مشترک

برای مسیر z ، چهار نرخ گذار

$$c_{ij}(z) = \frac{1}{T-1} \sum_{t=2}^T \mathbb{I}[z_{t-1} = i, z_t = j]$$

و دو میانگین انتشار حالت وابسته

$$e_k(x, z) = \frac{\sum_{t=1}^T \mathbb{I}[z_t = k] x_t}{\max(1, \sum_{t=1}^T \mathbb{I}[z_t = k])}$$

محاسبه شدند. بنابراین

$$\Psi(x, z) = [c_{11}, c_{12}, c_{21}, c_{22}, e_1, e_2]^T \in \mathbb{R}^6.$$

نرمال‌سازی شمارش‌ها بر طول دنباله از وابستگی مستقیم به T می‌کاهد و استفاده از میانگین به جای جمع از بزرگ شدن مقیاس جلوگیری می‌کند.

۳.۵.۶ حلقه آموزش متناوب

در هر تکرار، مسیر ویتربی همه ضربان‌های آموزش با HMM فعلی استخراج، بردارهای مشترک ساخته، مقیاس‌ساز و OC-SVM برازش و سپس پارامترهای HMM از مسیرهای جدید بازبرآورد شدند. درصد تغییر مسیرها معیار توقف بود. مدل در تکرار دوم به تغییر 0.685% رسید و بر اساس آستانه یک درصد متوقف شد.

۴.۵.۶ تحلیل موفقیت و شکست

مسیر پنهان واقعاً اطلاعات دارد، زیرا جایگزینی آن با مسیر ثابت AUC را به 0.5 رساند. با این حال، فشردن سازی ۱۴۰ مشاهده به شش مقدار، جزئیات پنهان، مکان و دامنه قله‌ها را حذف می‌کند. این مبادله توضیح می‌دهد چرا HMAD با وجود تفسیرپذیری گذارها، در ECG۵۰۰۰ از بردار پهن شده ضعیف‌تر است.

۶.۶ محدودیت‌ها

تمام ۵۰۰۰ ضربان از یک بیمار منشأ گرفته‌اند و تعمیم بین‌بیماری محدود است. افزون بر این، های annotation رکورد مبنا با آشکارساز خودکار تولید و به صورت دستی تصحیح نشده‌اند. این محدودیت‌های کیفیت برچسب و تعمیم‌پذیری در تفسیر نتایج لحاظ می‌شوند و هیچ نمونه دشواری پس از مشاهده نتایج حذف نشده است.

- جداسازی رسمی آرشیو الزاماً معادل جداسازی بین‌بیماری نیست، زیرا تمام ضربان‌ها به یک بیمار نسبت داده شده‌اند.
- برچسب خودکار می‌تواند دارای خطا باشد؛ بنابراین اعداد گزارش شده عملکرد نسبت به برچسب آرشیو هستند، نه حقیقت بالینی بازبینی شده توسط متخصص.
- مدل دو حالت عمده ساده نگه داشته شده است. تعداد حالت بیشتر یا ویژگی انتشار غنی تر ممکن است عملکرد را تغییر دهد، اما باید با validation مستقل انتخاب شود.
- برتری خط پایه به طول ثابت و هم‌ترازی ECG۵۰۰۰ وابسته است و نباید بدون آزمایش به دنباله‌های متغیر طول تعمیم داده شود.

استودنت دیلوربل: تحلیل مقایسه‌ای جامع عملکرد OC-SVM و HMAD

ارزیابی نهایی باید علاوه بر اعداد، محل موفقیت و شکست هر فرض مدل را روشن کند. جدول زیر جمع‌بندی شواهد نظری و تجربی پروژه است.

جدول ۲۴: تحلیل مقایسه‌ای ویژگی‌ها، مواضع موفقیت و شکست مدل‌های OC-SVM و HMAD

محور ورودی	OC-SVM با بازمانی ثابت	HMAD ساختاری
اطلاعات حفظ شده	بردارهای $\mathbb{R}^{140}$ یا $\mathbb{R}^{20}$ یا $\mathbb{R}^5$	بردار مشترک $\Psi(x, z^*) \in \mathbb{R}^6$
موفقیت مشاهده شده	مورفولوژی کامل در حالت پهن شده یا آمار دامنه در خلاصه‌ها	نرخ گذار حالت و میانگین انتشار وابسته به حالت
شکست مشاهده شده	بهترین AUC برابر 0.9840؛ بهره‌گیری قوی از هم‌ترازی ضربان	AUC برابر 0.9577 و precision کمی بالاتر در مرز صفر
شاهد اهمیت ترتیب	خلاصه کلی با حذف ترتیب افت کرد؛ بردار خام به ناهم‌ترازی حساس است	فشردن سازی شدید موجب افت recall و حذف جزئیات شکل موج شد
هزینه محاسباتی	برتری پهن شده و پنجره‌ای بر خلاصه کلی سریع و مستقیم پس از استخراج ویژگی	سقوط AUC به 0.5 با مسیر حالت ثابت نیازمند ویتربی و بازآورد متناوب با پیچیدگی بیشتر

نتیجه تحلیلی: در این داده واقعی، مدل ثابت لزوماً ساده لوحانه نیست؛ هم ترازوی فیزیولوژیک باعث شده بردار خام ترتیب را به طور ضمنی حفظ کند. HMAD نیز شکست کامل نخورده است، زیرا مسیر ویتربی اطلاعات ساختاری واقعی استخراج می کند، اما ویژگی مشترک شش بعدی برای حفظ تمام مورفولوژی کافی نیست. بنابراین پاسخ علمی پروژه وابسته به نوع نمایش است: مدل دنباله ای زمانی برتری محتمل دارد که گذارها و رژیم های پنهان عامل اصلی آنومالی باشند و نمایش مشترک ظرفیت کافی برای ثبت آن ها داشته باشد.

بخش 7: نتیجه گیری و جمع بندی نهایی (Conclusion)

این پروژه خط پایه OC-SVM و مدل ساده شده HMAD را در یک مسئله واقعی تشخیص ضربان غیرنرمال مقایسه کرد. پروتکل نهایی کاملاً one-class بود: آموزش تنها با ۲۹۲ ضربان نرمال و ارزیابی روی کل آزمون رسمی ۴۵۰۰ تایی انجام شد.

۱۰۷ پاسخ به پرسش اصلی

در ECG5000، OC-SVM با موج پهن شده بهترین عملکرد را با $ROC-AUC = 984000$ به دست آورد؛ HMAD به 95770 رسید. پس مدل سازی حالت پنهان در این پیکربندی ساده باعث بهبود معیار اصلی نشد. علت اصلی، هم ترازوی مناسب ضربان ها و حفظ کامل مورفولوژی در بردار 140 بعدی، در مقابل فشردگی شدید HMAD به شش ویژگی است.

این پاسخ باید در چارچوب مسئله تفسیر شود. مقایسه میان «مدل ثابت» و «مدل دنباله ای» به تنهایی کافی نیست، زیرا بازنمایی ورودی تعیین می کند چه اطلاعاتی در اختیار مدل قرار گیرد. بردار پهن شده در ECG5000 عملاً ترتیب را با جایگاه هر مؤلفه حفظ می کند؛ بنابراین خط پایه از اطلاعات زمانی کاملاً محروم نیست. HMAD ترتیب را به صورت صریح و قابل تفسیر در نرخ های گذار بازنمایی می کند، اما ظرفیت شش ویژگی آن از موج کامل کمتر است.

۱. معیار اصلی رتبه بندی پیوسته، برتری خط پایه پهن شده را نشان داد.

۲. معیارهای آستانه ای نشان دادند HMAD کمی precision بیشتر، ولی recall و F1 کمتر دارد.

۳. نتیجه کنترل مسیر ثابت ثابت کرد که بخش پنهان مدل بی اثر نیست؛ ضعف نهایی از کمبود ظرفیت نمایش مشترک ناشی می شود، نه صرفاً از ناموفق بودن ویتربی.

۲۰۷ ارزش ساختار دنباله ای

ساختار زمانی همچنان مهم است: خلاصه کلی که ترتیب را حذف می کند به AUC برابر 95180 افت کرد، در حالی که بازنمایی پنجره ای به 98230 رسید. همچنین انتساب ثابت حالت در HMAD عملکرد را به سطح تصادفی 50 کاهش داد؛ بنابراین مسیر ویتربی واقعاً اطلاعات ساختاری استخراج می کند، هرچند نمایش مشترک فعلی برای شکست دادن بردار خام کافی نیست.

سه شاهد مکمل برای این نتیجه وجود دارد. نخست، اختلاف بین خلاصه کلی و خلاصه پنجره ای نشان می دهد دانستن محل تقریبی رخدادها ارزش افزوده دارد. دوم، نزدیکی بازنمایی پنجره ای و پهن شده نشان می دهد بسیاری از تفاوت های ضربان در ساختار محلی قابل بازیابی اند. سوم، آزمایش حذف مسیر در HMAD نشان می دهد نرخ گذار و تفکیک انتشارهای حالت وابسته بدون رمزگشایی معتبر فرو می ریزند. بنابراین پروژه اهمیت ترتیب را تأیید می کند، اما گزاره قوی تر «هر مدل دنباله ای از هر مدل ثابت بهتر است» را رد می کند.

۳.۷ موفقیت‌ها، شکست‌ها و محدودیت‌ها

خط پایه در تشخیص تقریباً همه آنومالی‌ها recall بسیار بالا داشت، اما تعداد false ها باعث precision حدود ۰٫۸۳ شد. precision HMAD کمی بالاتر ولی recall پایین‌تر داشت. داده از یک بیمار و annotation خودکار است؛ لذا نتایج نباید به جمعیت‌های دیگر تعمیم قطعی داده شود. در تمام تحلیل‌ها test ثابت ماند و هیچ نمونه یا کلاس دشواری حذف نشد. موفقیت‌های تجربی:

- اجرای کاملاً تک کلاسه با آموزش صرفاً نرمال و ارزیابی روی ۴۵۰۰ دنباله رسمی؛
- حفظ پروتکل بدون تسریب برای تمام مقیاس‌سازها و مدل‌ها؛
- دستیابی به AUC بالا برای چند بازنمایی مستقل و مشاهده نتیجه پایدار در های-cohort حساسیت؛
- ارائه نتیجه منفی HMAD بدون حذف نمونه‌های دشوار یا تنظیم پسینی روی آزمون.

شکست‌ها و تهدیدهای اعتبار:

- مدل HMAD دو حالت جزئیات ریخت‌شناسی ضربان را به اندازه بردار خام حفظ نکرد؛
- یک‌بیماری بودن داده، اعتبار بیرونی و تعمیم به بیماران جدید را محدود می‌کند؛
- برچسب‌های خودکار ممکن است خطا داشته باشند و معیارها را نسبت به حقیقت بالینی منحرف کنند؛
- آستانه صفر برای مقایسه منصفانه ثابت نگه داشته شد، اما لزوماً بهترین نقطه عملیاتی پزشکی نیست.

۴.۷ جمع‌بندی نهایی

نتیجه اصلی این است که برتری مدل دنباله‌ای وابسته به تناسب نمایش با مسئله است. HMAD ساده برای تفسیر گذارها و رژیم‌های پنهان مفید است، اما روی ضربان‌های کوتاه و هم‌تراز، OC-SVM پهن‌شده اطلاعات مورفولوژیک بیشتری حفظ می‌کند. توسعه آینده می‌تواند از تعداد حالت بیشتر، ویژگی انتشار غنی‌تر، مدل چندبیماری و validation مستقل استفاده کند؛ بدون آنکه test برای تنظیم مدل به کار رود.

مسیرهای توسعه باید پیش از ارزیابی نهایی تعریف شوند. افزایش K ، افزودن واریانس و ویژگی‌های مشتق زمانی به Ψ ، استفاده از مدل انتشار چندمتغیره و ارزیابی روی داده چندبیماری گزینه‌های منطقی‌اند. با این حال، هر انتخاب باید روی validation جداگانه انجام شود و بخش آزمون رسمی برای گزارش نهایی دست‌نخورده باقی بماند. همچنین مقایسه آینده باید هزینه محاسباتی، تفسیرپذیری، کیفیت آستانه و پایداری در برابر ناهم‌ترازی را در کنار AUC بررسی کند.

در جمع‌بندی، پاسخ پروژه یک نتیجه شرطی و قابل دفاع است: وقتی دنباله‌ها کوتاه، ثابت طول و دقیقاً هم‌تراز باشند، یک خط پایه ثابت با حفظ موج کامل می‌تواند از یک مدل پنهان کم‌ظرفیت بهتر باشد. مزیت مدل ساختاری زمانی ظاهر می‌شود که تعریف حالت‌ها و ویژگی مشترک واقعاً دینامیک مولد آنومالی را بازنمایی کند. این تمایز، مهم‌تر از اعلام ساده برنده یک جدول است.

منابع داده

مراجع

- [1] UCR/TSML Time Series Classification Archive, “ECG5000,” <https://www.timeseriesclassification.com/description.php?Dataset=ECG5000>.
- [2] PhysioNet, “BIDMC Congestive Heart Failure Database v1.0.0,” <https://physionet.org/content/chfdb/1.0.0/>.
- [3] H. A. Dau et al., “The UCR Time Series Archive,” <https://arxiv.org/abs/1810.07758>.