

مقدمه ای بر یادگیری ماشین (۱-۲۵۷۳۷)

تمرین سری اول

ترم بهار ۱۴۰۴-۰۵

دانشکده‌ی مهندسی برق

دانشگاه صنعتی شریف

استاد: دکتر سجاد امینی



مهلت تحویل: شنبه ۱۹ اردیبهشت ساعت ۲۳:۵۹

(*) مسائلی که با ستاره مشخص شده‌اند امتیازی هستند و حل کردن آن‌ها نمره‌ی امتیازی خواهد داشت!

برخی از فرمول‌های کاربردی

• فرض کنید $\mathbf{X} = (\mathbf{X}_1, \mathbf{X}_2)^T$ یک بردار تصادفی توأم گاوسی با پارامترهای زیر باشد:

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \boldsymbol{\Sigma} = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}, \quad \boldsymbol{\Delta} = \boldsymbol{\Sigma}^{-1} = \begin{pmatrix} \Delta_{11} & \Delta_{12} \\ \Delta_{21} & \Delta_{22} \end{pmatrix}.$$

در این صورت توزیع‌های حاشیه‌ای عبارتند از:

$$\begin{aligned} p_{\mathbf{X}_1}(\mathbf{x}_1) &= \mathcal{N}(\boldsymbol{\mu}_1, \Sigma_{11}), \\ p_{\mathbf{X}_2}(\mathbf{x}_2) &= \mathcal{N}(\boldsymbol{\mu}_2, \Sigma_{22}). \end{aligned} \quad (1)$$

و توزیع پسین عبارت است از:

$$\begin{aligned} p_{\mathbf{X}_1|\mathbf{X}_2}(\mathbf{x}_1|\mathbf{x}_2) &= \mathcal{N}(\boldsymbol{\mu}_{1|2}, \Sigma_{1|2}) \\ \boldsymbol{\mu}_{1|2} &= \boldsymbol{\mu}_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{y}_2 - \boldsymbol{\mu}_2) = \boldsymbol{\mu}_1 - \Delta_{11}^{-1}\Delta_{12}(\mathbf{y}_2 - \boldsymbol{\mu}_2) \\ \Sigma_{1|2} &= \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} = \Delta_{11}^{-1} \end{aligned} \quad (2)$$

$$\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sqrt{\text{Var}[X]\text{Var}[Y]}}$$

۱ زنجیره مارکوف گاوسی

می‌نویسیم $X \rightarrow Y \rightarrow Z$ و می‌گوییم X, Y, Z یک زنجیره مارکوف را تشکیل می‌دهند وقتی داشته باشیم:

$$X|Y \perp\!\!\!\perp Z|Y$$

که به این معنی است:

$$p_{X,Z|Y}(x,z|y) = p_{X|Y}(x|y)p_{Z|Y}(z|y).$$

برای سه متغیر گاوسی با ویژگی فوق، $\rho_{X,Z}$ را بر حسب $\rho_{X,Y}$ و $\rho_{Y,Z}$ محاسبه کنید.

۲ تلفیق سنسورها

تصور کنید دما یک عدد ثابت z است (که ما هیچ چیزی درباره آن نمی‌دانیم). شما می‌توانید آن را با $Z \sim \mathcal{N}(0, +\infty)$ مدل کنید). ما دو سنسور داریم که در آن‌ها دما با نویز اندازه‌گیری می‌شود. واریانس نویز برای هر یک از آن‌ها معلوم است و به ترتیب v_1 و v_2 می‌باشد. فرض کنید ما n_1 مشاهده از سنسور اول انجام می‌دهیم که هر کدام با $\{Y_1^{(i)}\}_{i=1}^{n_1}$ داده می‌شود و n_2 مشاهده از سنسور دوم که با $\{Y_2^{(i)}\}_{i=1}^{n_2}$ داده می‌شود. فرض کنید تمام این مشاهدات به عنوان مجموعه‌ای به نام $\mathcal{D}$ نشان داده شوند. با استفاده از واریانس‌های داده شده، $p_{Z|\mathcal{D}}(z|\mathcal{D})$ را بیابید و Z را با استفاده از میانگین آن تخمین بزنید.

راهنمایی: فرض کنید Z یک متغیر تصادفی نرمال با یک توزیع پیشین است و سعی کنید توزیع پسین را با استفاده از معادلات داده شده در ابتدای تمرین تخمین بزنید. ابتدا باید $\{Y_1^{(i)}\}_{i=1}^{n_1}, \{Y_2^{(i)}\}_{i=1}^{n_2}$ و پارامترهای آن‌ها را به روشی دقیق فرموله کنید.

۳ المپیک ۲۰۲۶

در المپیک امسال، مسابقه پرش طول در طی n روز برگزار می‌شود. در هر روز از این مسابقه، هر کدام از شرکت‌کنندگان باید k بار پرش خود را انجام بدهند. طول هر پرش یک ورزشکار بر حسب متر که آن را با متغیر تصادفی M نمایش می‌دهیم از توزیع زیر پیروی می‌کند:

$$P(M = m) = \frac{1}{(e - 1)m!}, \quad (m \in \mathbb{N})$$

دقت کنید که پرش‌های انجام شده توسط ورزشکار، مستقل از یکدیگرند. گویم یک روز از مسابقه برای ورزشکار روز خوبی است، اگر در آن روز تمامی پرش‌هایی که انجام می‌دهد طولی بیشتر یا مساوی m^* داشته باشد. همچنین یک ورزشکار موفق است، در صورتی که حداقل یک روز خوب در مسابقه داشته باشد. نشان دهید که نابرابری زیر برقرار می‌باشد:

$$P(\text{موفق بودن یک ورزشکار}) \leq \frac{ne^k(e-2)^k}{(m^*(e-1)-e)^{rk}}$$

۴ احتمال چندمتغیره و سیستم‌های خطی-گاوسی

فرض کنید بردار تصادفی $z \in \mathbb{R}^d$ دارای توزیع

$$z \sim \mathcal{N}(\mu_z, \Sigma_z)$$

باشد. همچنین مشاهده‌ی $y \in \mathbb{R}^m$ از رابطه‌ی خطی-گاوسی زیر تولید می‌شود:

$$y = Wz + b + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \Sigma_y), \quad \varepsilon \perp z.$$

۱. نشان دهید که بردار $\begin{bmatrix} z \\ y \end{bmatrix}$ نیز گاوسی چندمتغیره است. سپس میانگین و ماتریس کوواریانس توزیع مشترک (z, y) را استخراج و به‌طور کامل اثبات کنید.

۲. با استفاده از توزیع مشترک، توزیع شرطی

$$p(z | y)$$

را استخراج کنید. فرمول‌های $\mu_{z|y}$ و $\Sigma_{z|y}$ را با اثبات کامل ماتریسی (بدون ارجاع به فرمول‌های از پیش آماده) به‌دست آورید.

۳. ثابت کنید که ماتریس کوواریانس شرطی $\Sigma_{z|y}$ مستقل از مقدار مشاهده‌شده‌ی y است.

۴. فرض کنید ماتریس W رتبه‌ی کامل ندارد. تحلیل کنید که این موضوع چه اثری بر شناسایی‌پذیری مؤلفه‌های z و عدم قطعیت پسین دارد.

۵. حالتی را در نظر بگیرید که توزیع y به جای گاوسی منفرد، یک مخلوط گاوسی (GMM) باشد:

$$p(y) = \sum_{k=1}^K \pi_k \mathcal{N}(y | \mu_k, \Sigma_k).$$

توضیح دهید که چرا این مدل قادر به مدل سازی داده های چندمدی است و همچنین توضیح دهید استنتاج $p(z | y)$ در این حالت چه محدودیت هایی پیدا می کند.

۵ مرتب!

فرض کنید X_1 و X_2 دو متغیر تصادفی مستقل و هم توزیع با تابع توزیع تجمعی $F_X(x)$ باشند. اگر

$$U = \max\{X_1, X_2\}, \quad V = \min\{X_1, X_2\},$$

آنگاه:

۱. $F_U(u)$ و $F_V(v)$ و نیز $f_U(u)$ و $f_V(v)$ را بیابید.

۲. بخش قبل را برای n متغیر تصادفی مستقل و هم توزیع $\{X_i\}_{i=1}^n$ تعمیم دهید؛ یعنی تابع توزیع تجمعی و تابع چگالی

$$U = \max\{X_1, \dots, X_n\}, \quad V = \min\{X_1, \dots, X_n\}$$

را محاسبه کنید.

۳. متغیرهای تصادفی $X_1 \sim \text{Exponential}(\lambda_1)$ و $X_2 \sim \text{Exponential}(\lambda_2)$ را در نظر بگیرید که مستقل اند. تابع چگالی احتمال و امید ریاضی متغیر تصادفی

$$V = \min\{X_1, X_2\}$$

را بیابید.

۴. متغیرهای تصادفی مستقل و هم توزیع $X_i \sim \text{Uniform}(a, b)$ را در نظر بگیرید. برای مجموعه $\{X_i\}_{i=1}^n$ ، توزیع تجمعی و تابع چگالی

$$U = \max\{X_1, \dots, X_n\}, \quad V = \min\{X_1, \dots, X_n\}$$

را به دست آورید.

۶ طبقه بندی بهینه ییزی

سیستمی پزشکی قصد دارد بر اساس یک نشانگر زیستی تک بعدی X ، وجود بیماری را تشخیص دهد. دو کلاس داریم:

$$Y = 1 : \text{بیمار}, \quad Y = 0 : \text{سالم}$$

احتمال پیشین بیماری برابر است با:

$$P(Y = 1) = \pi, \quad P(Y = 0) = 1 - \pi$$

و توزیع شرطی نشانگر زیستی به صورت زیر است:

$$X | Y = 0 \sim \mathcal{N}(0, 1), \quad X | Y = 1 \sim \mathcal{N}(\mu, 1)$$

در یک طبقه بند آستانه ای، پیش بینی $Y = 1$ زمانی انجام می شود که $X \geq t$.

۱. $p(x | Y = 0)$ و $p(x | Y = 1)$ را بیابید و با استفاده از قانون بیز، عبارت صریح $P(Y = 1 | X = x)$ را استخراج کنید.

۲. نشان دهید که طبقه بند بهینه برای کمینه کردن خطا یک طبقه بند آستانه ای است. آستانه بهینه t^* را بر حسب μ و π بیابید.

۳. اگر $\mu = 2$ و $\pi = \frac{1}{3}$ ، مقدار عددی t^* را محاسبه کنید.
۴. نرخ خطای نوع اول (False Positive Rate) و نرخ خطای نوع دوم (False Negative Rate) را برای آستانه‌ی دلخواه t بر حسب تابع توزیع تجمعی نرمال استاندارد Φ به دست آورید.
۵. ریسک کلی طبقه‌بند برابر است با:

$$R(t) = P(Y = 0, X \geq t) + P(Y = 1, X < t)$$
- نشان دهید که این ریسک در t^* کمینه می‌شود و توضیح دهید که چرا این نتیجه، نمونه‌ای از Bayes decision rule است.
۶. حال فرض کنید هزینه‌های اشتباه متفاوت باشند: هزینه‌ی خطای نوع اول برابر c_{01} و هزینه‌ی خطای نوع دوم برابر c_{10} است. آستانه بهینه‌ی جدید t_{cost}^* را به دست آورید.
۷. فرض کنید π نامعلوم باشد و مشاهدات برچسب‌ها $y_1, \dots, y_n$ در دست باشد. با مدل برنولی، تخمینگر بیشینه درست‌نمایی (MLE) را برای π بیابید.
۸. اگر توزیع پیشین $\pi \sim \text{Beta}(\alpha, \beta)$ باشد، توزیع پسین π را پس از مشاهده داده‌های $y_1, \dots, y_n$ استخراج کنید.
۹. به صورت کیفی توضیح دهید که امید پسین π چگونه بر آستانه‌ی بهینه تأثیر می‌گذارد، به خصوص در حالت‌هایی که داده‌ها نامتوازن هستند.

۷ حفاری یا عدم حفاری؟ (Drill baby drill!)

شما به عنوان مدیر تحلیل ریسک در یک شرکت نفتی کار می‌کنید. زمین‌شناسان تخمین زده‌اند که در یک منطقه خاص، احتمال وجود مخزن نفت حدود ۲۰٪ است. هزینه عملیات حفاری در این منطقه ۴۰۰,۰۰۰ دلار است. اگر نفت پیدا شود، درآمد حاصل از آن ۲,۰۰۰,۰۰۰ دلار خواهد بود (که پس از کسر هزینه حفاری، سود خالص ۱,۶۰۰,۰۰۰ دلار می‌شود). اگر نفت نباشد، هزینه حفاری کاملاً سوخت می‌شود (ضرر ۴۰۰,۰۰۰ دلاری). شرکت یک آزمایش «لرزه‌نگاری» (Seismic Test) انجام می‌دهد که دقت آن به شرح زیر است:

- حساسیت (Sensitivity): اگر نفت وجود داشته باشد، آزمایش به احتمال ۹۰٪ نتیجه «مثبت» (ساختار نفتی) را نشان می‌دهد.
 - ویژگی (Specificity): اگر نفت وجود نداشته باشد، آزمایش به احتمال ۸۵٪ نتیجه «منفی» (زمین خشک) را نشان می‌دهد.
- مطلوب است:

۱. تصمیم‌گیری (Drill?): دو گزارش آزمایش لرزه‌نگاری از دو سایت مختلف به دست شما رسیده است. برای هر کدام تصمیم بگیرید که آیا باید حفاری انجام شود یا خیر؟ (مبنای تصمیم، بیشینه کردن امید ریاضی سود یا Expected Monetary Value - EMV است).

- (آ) سایت A: نتیجه آزمایش لرزه‌نگاری مثبت است.
- (ب) سایت B: نتیجه آزمایش لرزه‌نگاری منفی است.

۲. آستانه قیمت (Price Threshold): فرض کنید قیمت جهانی نفت نوسان دارد و درآمد ۲ میلیون دلاری ثابت نیست. اگر نتیجه آزمایش لرزه‌نگاری مثبت باشد، حداقل درآمد حاصل از نفت (Revenue) چقدر باید باشد تا ریسک حفاری توجیه‌پذیر شود؟ (به عبارت دیگر، آستانه درآمد برای تصمیم Drill در حالت تست مثبت را پیدا کنید).

۳. تکنولوژی جدید (New Tech): یک شرکت رقیب، تکنولوژی جدیدی برای حفاری ارائه داده که هزینه حفاری را به ۱۰۰,۰۰۰ دلار کاهش می‌دهد، اما دقت تست‌های آن کمتر است (حساسیت ۷۰٪ و ویژگی ۷۰٪). آیا با این هزینه‌های پایین‌تر، استراتژی شما برای سایت‌هایی با تست منفی تغییر می‌کند؟