

مقدمه ای بر یادگیری ماشین (۱-۲۵۷۳۷)



تمرین سری دوم

ترم بهار ۱۴۰۴-۰۵

دانشکده‌ی مهندسی برق

دانشگاه صنعتی شریف

استاد: دکتر سجاد امینی

مهلت تحویل: شنبه ۲۶ اردیبهشت ساعت ۲۳:۵۹

(*) مسائلی که با ستاره مشخص شده‌اند امتیازی هستند و حل کردن آن‌ها نمره‌ی امتیازی خواهد داشت!

۱ فضاهای برداری، نرم‌ها و تجزیه مقادیر ویژه

فرض کنید $A \in \mathbb{R}^{n \times n}$ یک ماتریس متقارن و مثبت معین (Symmetric Positive Definite) باشد.

۱. ثابت کنید که تمام مقادیر ویژه‌ی ماتریس A حقیقی و اکیداً مثبت هستند.

۲. نشان دهید که تابع $f(x) = \sqrt{x^T A x}$ که در آن $x \in \mathbb{R}^n$ است، در شرایط یک نرم (Norm) صدق می‌کند. (اثبات نامساوی مثلثی برای این نرم الزامی است).

۳. اگر تجزیه مقادیر ویژه‌ی A به صورت $A = Q \Lambda Q^T$ باشد، نشان دهید که معکوس ماتریس A (یعنی A^{-1}) نیز متقارن و مثبت معین است و مقادیر ویژه‌ی آن را برحسب مقادیر ویژه‌ی A به دست آورید.

۲ ضرب ماتریسی و عملگرها

۱. ثابت کنید که هیچ دو ماتریس X و Y با ابعاد $n \times n$ وجود ندارند که در معادله‌ی زیر صدق کنند (که در آن I ماتریس همانی است):

$$XY - YX = I$$

۲. فرض کنید A یک ماتریس متعامد (Orthogonal Matrix) باشد. ثابت کنید که ضرب هر بردار x در A ، طول نرم دوم (L2-Norm) آن را تغییر نمی‌دهد (یعنی $\|Ax\|_2 = \|x\|_2$).

۳ حساب ماتریسی و ماتریس‌های خاص

تابع $f(X) = \text{Trace}(X^T A X B)$ را در نظر بگیرید که در آن X, A, B ماتریس‌های مربعی $n \times n$ هستند و A و B ماتریس‌های متقارن می‌باشند.

۱. گرادینان این تابع را نسبت به ماتریس X (یعنی $\nabla_X f(X)$) محاسبه کنید.

۲. اگر بخواهیم $f(X)$ را با شرط متعامد بودن ماتریس X (یعنی $X^T X = I$) بیشینه کنیم، فرمول لاگرانژین (Lagrangian) این مسئله را بنویسید.

۳. ثابت کنید که اگر X یک ماتریس پادمقارن (Skew-symmetric) باشد، یعنی $X^T = -X$ ، در این صورت برای هر بردار $v \in \mathbb{R}^n$ داریم:

$$v^T X v = 0$$

۴ روش‌های مرتبه اول و دوم

تابع روزنبروک (Rosenbrock function) به صورت زیر داده شده است که a و b پارامترهای مثبت هستند:

$$f(x_1, x_2) = (a - x_1)^2 + b(x_2 - x_1)^2$$

۱. بردار گرادیان ∇f و ماتریس هسین (Hessian) $\nabla^2 f$ را محاسبه کنید.
۲. نقاط مینیمم محلی و سراسری این تابع را پیدا کرده و با استفاده از ماتریس هسین ثابت کنید که این نقاط واقعاً مینیمم هستند.
۳. رفتار و سرعت همگرایی روش گرادیان کاهشی (Gradient Descent) را با روش نیوتون (Newton's Method) در نزدیکی نقطه مینیمم سراسری این تابع مقایسه کنید و دلیل تفاوت آن‌ها را به لحاظ ریاضی بحث کنید.

۵ بهینه‌سازی مقید و شرایط KKT

مسئله بهینه‌سازی زیر را در نظر بگیرید:

$$\begin{aligned} \min_{x_1, x_2} \quad & f(x_1, x_2) = x_1^2 + x_2^2 \\ \text{s.t.} \quad & g(x_1, x_2) = x_1 + x_2 - 2 \leq 0 \\ & h(x_1, x_2) = x_1^2 - x_2 \leq 0 \end{aligned}$$

۱. تابع لاگرانژ (Lagrangian) این مسئله را تشکیل دهید.
۲. شرایط (Karush-Kuhn-Tucker) KKT را برای این مسئله به طور کامل بنویسید (شامل ایستایی، امکان‌پذیری اولیه، امکان‌پذیری دوگان، و مکمل بودن).
۳. با استفاده از شرایط KKT، نقطه یا نقاط بهینه‌ی سراسری این مسئله را به دست آورید و اثبات کنید که چرا این نقاط بهینه‌ی سراسری هستند.

۶ گرادیان کاهشی تصادفی و تحدب

فرض کنید تابع هزینه برای یک مسئله یادگیری ماشین به صورت زیر تعریف شده است که L یک تابع زیان محدب (Convex Loss Function) است:

$$J(\theta) = \frac{1}{N} \sum_{i=1}^N L(\theta; x_i, y_i) + \frac{\lambda}{2} \|\theta\|_2^2$$

۱. ثابت کنید که تابع $J(\theta)$ یک تابع اکیداً محدب (Strictly Convex) است. چرا این ویژگی در بهینه‌سازی اهمیت دارد؟
۲. قانون بروزرسانی را برای این تابع بنویسید.
۳. به لحاظ تئوری بیان کنید که چرا اگر نرخ یادگیری (Learning Rate) به تدریج با شرایط خاصی کاهش یابد، الگوریتم SGD به مینیمم سراسری همگرا می‌شود.

۷ Water-filling

مسئله بهینه‌سازی محدب زیر را در نظر بگیرید:

$$\begin{aligned} \text{minimize} \quad & - \sum_{i=1}^n \log(\alpha_i + x_i) \\ \text{subject to} \quad & x \geq 0, \quad \mathbf{1}^T x = 1 \end{aligned}$$

که در آن $\alpha_i > 0$ است. این مسئله در نظریه اطلاعات و هنگام تخصیص توان به مجموعه‌ای از n کانال مخابراتی مطرح می‌شود. متغیر x_i نشان‌دهنده توان فرستنده تخصیص‌یافته به کانال i -ام است و $\log(\alpha_i + x_i)$ ظرفیت یا نرخ ارتباط آن کانال را نشان

می‌دهد. بنابراین، هدف مسئله این است که توان کل (که برابر با یک در نظر گرفته شده) را به گونه‌ای بین کانال‌ها توزیع کنیم که مجموع نرخ ارتباط بیشینه شود.
با استفاده از شرایط KKT، پاسخ بهینه (x^*) را به دست آورده و نحوه یافتن آن را توضیح دهید.

۸ نامساوی ون-نیومن (*)

در این سوال قصد داریم نامساوی ون-نیومن را اثبات نماییم. این نامساوی می‌گوید فرض کنید $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}$ با مقادیر تکین $\sigma_1(\mathbf{A}) \geq \dots \geq \sigma_r(\mathbf{A})$ و $\sigma_1(\mathbf{B}) \geq \dots \geq \sigma_r(\mathbf{B})$ باشند که $r = \min\{m, n\}$ ، آن‌گاه:

$$|\text{tr}\{\mathbf{A}^\top \mathbf{B}\}| \leq \sum_{i=1}^r \sigma_i(\mathbf{A}) \sigma_i(\mathbf{B}).$$

۱. در ابتدا نشان دهید که اگر $\mathbf{U}$ و $\mathbf{V}$ دو ماتریس مثبت نیمه معین هرمیتی باشند و λ_1 متناظر با بزرگ‌ترین مقدار ویژه‌ی یک ماتریس باشد، نشان دهید که:

$$\lambda_1(\mathbf{UV}) \leq \lambda_1(\mathbf{U}) \lambda_1(\mathbf{V}).$$

۲. حال به کمک بخش قبل نشان دهید که:

$$\prod_{i=1}^k \lambda_i(\mathbf{UV}) \leq \prod_{i=1}^k \lambda_i(\mathbf{U}) \prod_{i=1}^k \lambda_i(\mathbf{V}).$$

که در آن $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k$ مقادیر ویژه‌ی ماتریس‌های متناظر به ترتیب نزولی هستند.

۳. می‌دانیم که مقادیر تکین یک ماتریس نوعی مانند $\mathbf{A}$ در رابطه‌ی زیر صدق می‌کنند.

$$\sigma_i(\mathbf{A}) = (\lambda_i(\mathbf{A}\mathbf{A}^\dagger))^{\frac{1}{2}}$$

حال به کمک رابطه‌ی بالا و قضایای ثابت شده در بخش قبل، قضیه ون-نیومن را ثابت نمایید.

۹ بهینه‌سازی مرتبه دوم

برای یک تابع دلخواه $f(x)$ می‌توان از سری تیلور^۱ مرتبه دوم در نزدیکی نقطه $\mathbf{x}_0$ استفاده کرد:

$$f(x) \approx f(x_0) + (x - x_0)^\top \nabla f(\mathbf{x}_0) + \frac{1}{2} (x - x_0)^\top \mathbf{H}(x - x_0),$$

که در اینجا $\nabla f(\mathbf{x}_0)$ بردار gradient تابع در نقطه $\mathbf{x}_0$ است و $\mathbf{H}$ ماتریس هسین Hessian Matrix تابع f در نقطه $\mathbf{x}_0$ است که به صورت زیر تعریف می‌شود:

$$H_{i,j} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$$

حال به پرسش‌های زیر پاسخ دهید:

(آ) فرض کنید نرخ یادگیری ϵ در الگوریتم Gradient Descent به صورت $x = x_0 - \epsilon g$ به کار می‌رود، که در آن $g = \nabla f(\mathbf{x}_0)$ می‌باشد. طبق بسط تیلور، مقدار $f(x_0 - \epsilon g)$ را به صورت تقریبی تا جمله مرتبه سوم بنویسید.

(ب) در صورتی که $\mathbf{g}^\top \mathbf{H} \mathbf{g}$ منفی یا صفر باشد، افزایش یا کاهش نرخ یادگیری ϵ چه تأثیری بر مقدار تقریبی $f(x)$ خواهد داشت؟ چرا استفاده از این روش بهینه‌سازی در چنین شرایطی مناسب نیست؟

(پ) اگر $\mathbf{g}^\top \mathbf{H} \mathbf{g}$ مثبت باشد، با مشتق‌گیری از عبارت ارائه‌شده نسبت به ϵ و قرار دادن آن برابر صفر، نرخ یادگیری^۲ بهینه ϵ^* را به دست آورید.

(ت) با توجه به رابطه به دست آمده برای ϵ^* ، توضیح دهید که مقدار نرخ یادگیری بهینه ϵ^* در چه شرایطی بیشینه و کمینه خواهد شد. راهنمایی: Hx را به صورت ترکیب خطی از بردارهای ویژه $\mathbf{H}$ و مقدار ویژه‌های متناظر آن بنویسید.

¹Taylor Series

²Learning Rate

۱۰ نرم فروبینیوس

نرم فروبینیوس^۳ برای ماتریس $A \in \mathbb{R}^{m \times n}$ به صورت زیر تعریف می‌شود:

$$\|A\|_F = \sqrt{\text{tr}\{A^T A\}}$$

۱. ثابت کنید:

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |A_{i,j}|^2}.$$

۲. اگر مقادیر تکی ماتریس A را با $\sigma_1, \sigma_2, \dots, \sigma_r$ نشان دهیم، ثابت کنید:

$$\|A\|_F = \sqrt{\sum_{i=1}^r \sigma_i^2}.$$

۳. ثابت کنید:

$$\sigma_{\max}(A) \leq \|A\|_F \leq \sqrt{r} \sigma_{\max}(A)$$

۴. ماتریس‌های $A \in \mathbb{R}^{m \times n}$ و $B \in \mathbb{R}^{n \times p}$ را در نظر بگیرید. نشان دهید

$$\|AB\|_F \leq \|A\|_F \|B\|_F \quad (\Gamma)$$

$$\|AB\|_F \leq \sigma_{\max}(A) \|B\|_F \quad (\text{ب})$$

۵. ثابت کنید برای هر $x \in \mathbb{R}^n$

$$\sigma_{\min}(A) \leq \frac{x^T A x}{x^T x} \leq \sigma_{\max}(A)$$

۱۱ کاهش بعد ماتریس‌ها (*)

در این سؤال می‌خواهیم یکی از کاربردهای مهم تجزیه مقادیر تکی برای ماتریس‌ها را بیان کنیم و آن این است که به تعبیری بهترین تخمین رنک پایین از یک ماتریس را می‌توان از آن‌ها به دست آورد.

فرض کنید $A \in \mathbb{R}^{m \times n}$ با تجزیه مقادیر تکی به صورت $A = U \Sigma V^T$ وجود داشته باشد. برای یک عدد صحیح $k \leq \min\{m, n\}$ ماتریس $A_k \in \mathbb{R}^{m \times n}$ را که قرار است تقریبی از ماتریس A باشد، به صورت $A_k = U_k \Sigma_k V_k^T$ تعریف می‌کنیم که U_k و V_k به ترتیب k ستون اول U و V و همچنین Σ_k بلوک $k \times k$ سمت بالا و چپ از ماتریس Σ است (که شامل k بزرگ‌ترین مقادیر تکی ماتریس A می‌باشد). به تعبیر دیگر شما می‌توانید A_k را به صورت $A_k = \sum_{i=1}^k \lambda_i u_i v_i^T$ نیز بنویسید که در آن $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{\min(m,n)}$ مقادیر تکی ماتریس A هستند.

۱. برای به دست آوردن یک تقریب خوب از ماتریس A مسئله‌ی بهینه‌سازی زیر را در نظر بگیرید.

$$\min_{X: \text{rank}(X) \leq k} \|A - X\|_F$$

نشان دهید A_k جواب مسئله‌ی بهینه‌سازی فوق است.

راهنمایی: از نامساوی ون-نیومن در سوال ۸ استفاده کنید.

۲. حال به جای نرم فروبینیوس در مسئله‌ی بهینه‌سازی قبل، نرم عملگری یک ماتریس را در نظر می‌گیریم. یعنی مسئله‌ی بهینه‌سازی قسمت قبل را به صورت زیر تغییر می‌دهیم.

$$\min_{X: \text{rank}(X) \leq k} \|A - X\|_2$$

نشان دهید هم‌چنان جواب مسئله‌ی بهینه‌سازی فوق A_k است.

راهنمایی: $k+1$ ستون اول ماتریس V را در نظر بگیرید و به کمک ترکیب خطی آن‌ها، یک بردار در فضای پوچ ماتریس X که متغیر مسئله‌ی بهینه‌سازی فوق است، بسازید.

³Frobenious Norm