

مقدمه ای بر یادگیری ماشین (۱-۲۵۷۳۷)



تمرین سری سوم

ترم بهار ۱۴۰۴-۰۵

دانشکده‌ی مهندسی برق

دانشگاه صنعتی شریف

استاد: دکتر سجاد امینی


مهلت تحویل: ۲۵ خرداد ساعت ۲۳:۵۹

(*) مسائلی که با ستاره مشخص شده‌اند امتیازی هستند و حل کردن آن‌ها نمره‌ی امتیازی خواهد داشت!

۱ رگرسیون لجستیک رگولاریزد شده (Regularized Logistic Regression)

می‌خواهیم رگرسیون لجستیک همراه با تنظیم‌گری (Regularization) را روی یک مسئله دسته‌بندی باینری (دو کلاسه) در یک فضای ویژگی دوبعدی ($d = 2$) اعمال کنیم. از یک بُعد موهومی برای در نظر گرفتن جمله بایاس α استفاده می‌کنیم؛ بنابراین بردار وزن به فرم $w = [w_1 \ w_2 \ \alpha]^T$ است و به انتهای هر نقطه آموزشی یک عدد «۱» اضافه شده است. اگر تنظیم‌گری ℓ_2 را تنها روی یکی از وزن‌ها اعمال کنیم چه اتفاقی می‌افتد؟

نقاط آموزشی ما در ادامه نشان داده شده‌اند. علامت‌های ضربدر دارای برچسب $y_i = +1$ و دایره‌ها دارای برچسب $y_i = 0$ هستند.



شکل ۱: نقاط آموزشی در فضای دوبعدی

(آ) فرض کنید روی w_2 تنظیم‌گری اعمال می‌کنیم. می‌خواهیم تابع هزینه زیر را کمینه کنیم:

$$J(w) = \left(- \sum_{i=1}^n \left(y_i \ln s(X_i \cdot w) + (1 - y_i) \ln(1 - s(X_i \cdot w)) \right) \right) + \lambda w_2^2$$

که در آن $s(\gamma)$ تابع لجستیک (سیگموئید) است و $\lambda > 0$ ابرپارامتر تنظیم‌گر است.

با افزایش λ از صفر تا بی‌نهایت، توضیح دهید که مرز تصمیم چگونه تغییر می‌کند، تعداد نقاط آموزشی که به اشتباه دسته‌بندی می‌شوند (Misclassified) چگونه تغییر می‌کند و چرا.

(ب) فرض کنید روی بایاس α تنظیم‌گری اعمال می‌کنیم. حال می‌خواهیم تابع هزینه زیر را کمینه کنیم:

$$J(w) = \left(- \sum_{i=1}^n \left(y_i \ln s(X_i \cdot w) + (1 - y_i) \ln(1 - s(X_i \cdot w)) \right) \right) + \lambda \alpha^2$$

با افزایش λ از صفر تا بی‌نهایت، توضیح دهید که مرز تصمیم چگونه تغییر می‌کند، تعداد نقاط آموزشی که به اشتباه دسته‌بندی می‌شوند چگونه تغییر می‌کند و چرا.

۲ رگرسیون خطی و لجستیک

(آ) در سوال قبل، استفاده از رگرسیون خطی برای دسته‌بندی دوکلاسه با برجسب‌های $\{0, 1\}$ را بررسی کردیم حال در اینجا از یک مدل خطی به فرم زیر استفاده می‌کنیم:

$$y = \mathbf{w}^T \mathbf{x} + b$$

و تابع زیان خطای مربعات (Squared Error) نیز به صورت $\mathcal{L}(y, t) = \frac{1}{2}(y - t)^2$ تعریف می‌شود. دیدیم که این روش دارای این مشکل است که پیش‌بینی‌های صحیح با اطمینان بالا (Confident correct predictions) را جریمه می‌کند. آیا در صورت استفاده از تابع زیان لولای اصلاح‌شده (Modified Hinge Loss) زیر، این مشکل برطرف می‌شود؟

$$\mathcal{L}(y, t) = \begin{cases} \max(0, y), & t = 0 \\ 1 - \min(1, y), & t = 1 \end{cases}$$

پاسخ خود را به صورت ریاضی توجیه کنید.

(ب) مدل رگرسیون لجستیک $y = g(\mathbf{w}^T \mathbf{x})$ را در نظر بگیرید که با استفاده از تابع زیان آنتروپی متقاطع باینری (Binary Cross Entropy) آموزش داده می‌شود و در آن $g(z) = \frac{1}{1+e^{-z}}$ تابع سیگموئید است. یکی از دوستان شما نسخه اصلاح‌شده‌ای از رگرسیون لجستیک را پیشنهاد می‌دهد که در آن از تابع زیر استفاده می‌شود:

$$g(z) = \frac{e^{-z}}{1 + e^{-z}}$$

این مدل پیشنهادی نیز همچنان با تابع زیان آنتروپی متقاطع باینری آموزش داده می‌شود. پارامترهای آموزش‌دیده‌ی مدل و همچنین پیش‌بینی‌های آن، چه تفاوتی با رگرسیون لجستیک معمولی خواهند داشت؟ پاسخ خود را به صورت ریاضی توجیه کنید (ارائه یک توضیح صرفاً گرافیکی کافی نیست).

۳ الگوریتم‌های دسته‌بندی

۱.۳ بیز ساده (Naive Bayes)

به یاد بیاورید که یک دسته‌بند بیز ساده فرض می‌کند ویژگی‌های $x_1, x_2, \dots$ به شرط برجسب کلاس y از یکدیگر مستقل هستند، بنابراین:

$$P(y|X = (x_1, \dots, x_n)) \propto P(X, y) = P(X|y) \cdot P(y) = P(y) \cdot \prod_i P(x_i|y),$$

و در نتیجه پیش‌بینی آن را می‌توان به صورت زیر نوشت:

$$\arg \max_y P(y|X) = \arg \max_y P(y) \cdot \prod_i P(x_i|y). \quad (1)$$

اکنون دسته‌بند غیرخطی زیر را با قاعده دسته‌بندی به فرم زیر در نظر بگیرید:

$$\arg \max_y S \left(w_0 + \sum_{i=1}^n w_{y,i} x_i \right), \quad (2)$$

که در آن S تابع سیگموئید است.


(آ) فرض کنید ویژگی‌های ورودی باینری هستند، یعنی $x_i \in \{0, 1\}$. در این شرایط، قاعده دسته‌بندی بیز ساده در رابطه (؟؟) را بازنویسی کنید تا فرمی مشابه با دسته‌بند غیرخطی در رابطه (؟؟) پیدا کند. (راهنمایی: از این واقعیت که x_i باینری است استفاده کنید).

(ب) وزن‌های w_0 و $w_{y,i}$ (برای $i = 1, \dots, n$) را برحسب احتمالات بیز ساده با استفاده از $P(y)$ و $P(x_i|y)$ بیان کنید. فرض کنید تمام احتمالات بیز ساده غیرصفر هستند.

۲.۳ رگرسیون لجستیک در برابر بیز ساده گاوسی

اکنون دیگر دسته‌بند بیز ساده را به داشتن ویژگی‌های بولی (باینری) محدود نمی‌کنیم. مسئله دسته‌بندی سه مجموعه داده دو بعدی زیر به دو کلاس (که با علامت‌های «پلاس» و «لوزی» نشان داده شده‌اند) را با استفاده از دو دسته‌بند در نظر بگیرید: رگرسیون لجستیک و بیز ساده گاوسی (Gaussian Naive Bayes). برای بیز ساده گاوسی، فرض کنید هر دو کلاس در بُعد y دارای واریانس برابر هستند.

برای هر یک از سه مجموعه داده زیر، مرز تصمیم رگرسیون لجستیک را با یک خط پُر (ممتد) و مرز بیز ساده گاوسی را با یک خط چین رسم کنید. اگر هر یک از دسته‌بندها نتوانستند داده‌ها را به درستی دسته‌بندی کنند، در سمت راست شکل در یک جمله دلیل آن را توضیح دهید. توجه: شما فقط برای مواردی که داده‌ها به درستی قابل دسته‌بندی هستند نیاز به رسم مرز تصمیم دارید.



شکل ۲: مجموعه داده‌های دو بعدی برای مقایسه رگرسیون لجستیک و بیز ساده گاوسی.

۴ رگرسیون خطی با نویز لاپلاسی (*)

اگر فرض کنیم داده‌های ما از یک رابطه خطی پیروی می‌کنند اما دارای نویز با توزیع نرمال هستند، رگرسیون کمترین مربعات (Least-Squares Regression) توسط برآوردگر بیشینه درستی‌نمایی (MLE) توجیه می‌شود. اما اگر نویز با توزیع لاپلاس (Laplace Distribution) بهتر مدل شود چه اتفاقی می‌افتد؟ فرض کنید $\epsilon \sim \text{Laplace}(\mu, \beta)$ نشان‌دهنده متغیر تصادفی ϵ است که از یک توزیع لاپلاس تک‌متغیره با میانگین μ و پارامتر مقیاس β استخراج شده است. تابع چگالی احتمال (PDF) این توزیع به صورت زیر است:

$$f(\epsilon; \mu, \beta) = \frac{1}{2\beta} \exp \left(-\frac{|\epsilon - \mu|}{\beta} \right)$$

طبق نمادگذاری معمول ما، ورودی شامل یک ماتریس طراحی $X \in \mathbb{R}^{n \times d}$ (Design Matrix) و یک بردار y است؛ به طوری که y_i برچسب مربوط به نمونه X_i است و $X_i^\top$ نشان‌دهنده سطر i -ام ماتریس X می‌باشد. برای سادگی، رگرسیون خطی را از مبدأ (بدون جمله بایاس α) در نظر می‌گیریم، بنابراین تابع رگرسیون به فرم $h(x) = w^\top x$ خواهد بود. مدل ما فرض می‌کند که هر برچسب y_i از یک رابطه خطی که با نویز لاپلاسی مختل شده است به دست می‌آید:

$$y_i \sim \text{Laplace}(w^\top X_i, \beta)$$

که در آن $w \in \mathbb{R}^d$ رابطه خطی واقعی را نشان می‌دهد. قصد داریم از برآوردگر بیشینه درستی‌نمایی برای تخمین w استفاده کنیم.

(آ) تابع درستی‌نمایی $\mathcal{L}(w; X, y)$ را برای پارامتر w ، با فرض ثابت بودن داده‌های X و y بنویسید.

(ب) تابع لگاریتم درستی‌نمایی $\ell(w; X, y)$ را برای پارامتر w ، با فرض ثابت بودن داده‌های X و y ، تا حد امکان در ساده‌ترین فرم خود بنویسید.

(ج) ساده‌ترین تابع هزینه‌ای (Cost Function) که با کمینه کردن آن، دقیقاً همان مقدار w حاصل از بیشینه‌سازی درستی‌نمایی به دست می‌آید، چیست؟

(د) تابع هزینه‌ای که در بخش قبل به دست آوردید چه تفاوتی با رگرسیون کمترین مربعات استاندارد دارد؟ آیا نسبت به داده‌های پرت (Outliers) حساس‌تر است یا کمتر حساس است؟ چرا؟

(ه) قاعده بروزرسانی گرادینت کاهشی دسته‌ای (Batch Gradient Descent) را برای کمینه کردن تابع هزینه خود بنویسید. از η به عنوان اندازه گام (Learning Rate) استفاده کنید. می‌توانید از نمونه‌های آموزشی که گرادینت تابع زیان برای آن‌ها تعریف نشده است صرف نظر کنید. راهنمایی: به یاد بیاورید که مشتق $\frac{d}{d\alpha} |\alpha|$ برای $\alpha > 0$ برابر ۱، برای $\alpha < 0$ برابر -۱ و برای $\alpha = 0$ تعریف نشده است.

۵ تحلیل ممیز گاوسی (Gaussian Discriminant Analysis)

فرض کنید می‌خواهیم مدلی برای پیش‌بینی عملکرد دانشجویان در آزمون میان‌ترم دکتر آمینی بسازیم. از تعدادی از دانشجویان دوره‌های قبل نظرسنجی کرده‌ایم و مدت زمان مطالعه آن‌ها (به ساعت) برای امتحان و همچنین وضعیت قبولی یا مردودی آن‌ها را ثبت کرده‌ایم که در نتیجه دو کلاس زیر تشکیل شده‌اند:

• قبول شده (Passed): $\{4, 5, 5.5, 6.5, 7, 8\}$

• مردود شده (Failed): $\{0, 1, 2, 3, 4\}$

ساعات مطالعه، تنها ویژگی (Feature) است که برای هر دانشجو در اختیار داریم ($d = 1$). فرض کنید توزیع ساعات مطالعه برای هر دو گروه دانشجویان قبول شده و مردود شده، دارای توزیع نرمال (گاوسی) است. دو روش برای مدل‌سازی این داده‌ها در نظر بگیرید: تحلیل ممیز خطی (LDA) و تحلیل ممیز درجه دوم (QDA). از تابع زیان ۰-۱ (0-1 loss) برای تعریف ریسک استفاده کنید.

(آ) میانگین‌های نمونه μ_p, μ_f و واریانس‌های σ_p^2, σ_f^2 را برای مدل QDA محاسبه کنید. (زیرنویس‌های p و f به ترتیب نشان‌دهنده قبولی (pass) و مردودی (fail) هستند). پاسخ‌های خود را به صورت ساده‌ترین کسر ممکن (نه به صورت اعشاری) بیان کنید.

(ب) میانگین‌های نمونه و واریانس‌های μ_p, μ_f و σ_p^2, σ_f^2 را برای مدل LDA استفاده می‌شود را محاسبه کنید. پاسخ‌های خود را به صورت ساده‌ترین کسر ممکن (نه اعشاری) بیان کنید.

(ج) مرز تصمیم (Decision Boundary) را برای مدل LDA محاسبه کنید. در محاسبات از کسرها (و نه اعداد اعشاری) استفاده کنید و پاسخ نهایی را تا حد امکان در ساده‌ترین فرم ممکن بیان کنید (دقت کنید که پاسخ شما به احتمال زیاد شامل یک عبارت لگاریتمی خواهد بود).

۶ تخمین نویز در رگرسیون خطی

می‌خواهیم یک قانون طبیعی خطی $g(z) = v^T z$ (یا $g(z) = \text{«حقیقت پایه»}$ یا Ground Truth) را تعیین کنیم که هر نقطه داده $z \in \mathbb{R}^d$ را به یک برجسب در $\mathbb{R}$ نگاشت می‌کند. (برای سادگی، در این سوال از جمله بایاس α استفاده نمی‌کنیم؛ فرض کنید قانون طبیعی ما در $0 = g(0)$ صدق می‌کند).

اما اندازه‌گیری‌ها دارای نویز هستند، بنابراین آنچه ما به دست می‌آوریم یک ماتریس طراحی (Design Matrix) $X \in \mathbb{R}^{n \times d}$ و یک بردار $y \in \mathbb{R}^n$ از برجسب‌ها است به طوری که $y_i = v^T X_i + \epsilon_i$ ، که در آن $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$ نویز تصادفی است (و هر ϵ_i مستقل از بقیه است). در کلاس، از برآوردگر بیشینه درستی‌نمایی (MLE) استفاده کردیم تا استفاده از میانگین مربعات خطا به عنوان تابع هزینه برای رگرسیون خطی را توجیه کنیم و بردار وزن $w \in \mathbb{R}^d$ را محاسبه کنیم که تخمینی از v است. اکنون می‌خواهیم از MLE برای تخمین σ^2 ، یعنی واریانس نویز اندازه‌گیری، استفاده کنیم.

(آ) تابع درستی‌نمایی (Likelihood Function) $\mathcal{L}(\sigma; y, X, v)$ را برای به دست آوردن برجسب‌های y_i با فرض ثابت بودن مقادیر X و v بنویسید. (نکته: در این مسئله، X و v تصادفی نیستند. در پاسخ شما نباید پارامتر μ یا سایر پارامترهای ذکر نشده وجود داشته باشد.)

(ب) تابع لگاریتم درستی‌نمایی (Log-Likelihood) $\ell(\sigma; y, X, v)$ را بنویسید و مقداری از σ^2 را پیدا کنید که ℓ را بیشینه می‌کند. مراحل کار خود را نشان دهید. (نکته: نیازی نیست ثابت کنید که این مقدار واقعاً یک نقطه ماکزیمم است.)

(ج) مقدار بهینه σ^2 که به دست آوردید، شبیه به کدام فرمول آشنا برای شماست؟ (پاسخ «میانگین واریانس برجسب‌های y_i » قابل قبول نیست؛ منظور فرمول دیگری است.)

(د) متأسفانه، ما مقدار v را نمی‌دانیم. با توجه به اینکه نمی‌توانیم به v دسترسی پیدا کنیم، چگونه باید σ^2 را تخمین بزنیم؟ تخمینی از تخمین خود برای σ^2 را بنویسید که صرفاً برحسب y ، X و n بیان شده باشد و هیچ v ی در آن نباشد. (این همان برآوردگر بیشینه درستی‌نمایی $\hat{\sigma}^2$ برای واریانس واقعی σ^2 است). پاسخ نهایی خود را به فرم ماتریسی و بدون استفاده از عملگر سیگما (Σ) بنویسید. فرض کنید ماتریس X دارای رتبه کامل (d Rank) است.

۷ کاربرد رگرسیون لجستیک در پرتودرمانی

یک سیستم برای برنامه‌ریزی پرتودرمانی (Radiation Therapy) را در نظر بگیرید. با فرض یک بیمار دارای تومور بدخیم، مسئله انتخاب زمان بهینه تابش پرتو برای آن بیمار است. یک عنصر کلیدی در این مسئله، تخمین احتمال از بین رفتن کامل تومور با توجه به ویژگی‌های خاص آن است. یک دانشمند داده اطلاعات زیر را در رابطه با این سیستم پرتودرمانی جمع‌آوری کرده است: متغیر X_1 نشان‌دهنده مدت زمان تابش پرتو به بیمار برحسب میلی‌ثانیه، X_2 نشان‌دهنده اندازه تومور برحسب سانتی‌متر، و Y یک متغیر پاسخ باینری است که نشان می‌دهد آیا تومور با موفقیت از بین رفته است یا خیر. این دانشمند داده، یک مدل رگرسیون لجستیک به فرم $Pr\{Y = 1|X\} = \sigma(\theta_0 + \theta_1 X_1 + \theta_2 X_2)$ را روی مجموعه داده برازش (Fit) کرده و برآوردهای زیر را برای پارامترها به دست آورده است:

$$\hat{\theta}_0 = -6, \quad \hat{\theta}_1 = 0.05, \quad \hat{\theta}_2 = 1$$

(آ) احتمال از بین رفتن تومور را برای بیماری تخمین بزنید که توموری به اندازه $3/5$ سانتی‌متر دارد و به مدت 40 میلی‌ثانیه تحت پرتودرمانی قرار می‌گیرد.

(ب) برای اینکه احتمال از بین رفتن تومور برای بیمار بخش (آ) دقیقاً 50% باشد، او باید چند میلی‌ثانیه تحت تابش پرتو قرار گیرد؟

۸ رگرسیون ریبج با یک ویژگی

نمونه‌ای به ما داده شده است که در آن هر نقطه تنها یک ویژگی دارد. بنابراین، ماتریس طراحی ما یک بردار ستونی است که آن را به صورت $x \in \mathbb{R}^n$ (به جای X) می‌نویسیم. مدل تولید داده اسکالر زیر را در نظر بگیرید:

$$y_i = \omega x_i + e_i$$

که در آن $x_i \in \mathbb{R}$ تنها ویژگی ورودی نقطه i ، $y_i \in \mathbb{R}$ برجسب اسکالر آن (یک اندازه‌گیری نویزدار)، $e_i \sim \mathcal{N}(0, 1)$ نویز گاوسی استاندارد با میانگین صفر و واریانس واحد، و $\omega \in \mathbb{R}$ رابطه خطی واقعی و ثابتی است که می‌خواهیم آن را تخمین بزنیم.

متغیرهای e_i متغیرهای تصادفی مستقل و هم‌توزیع (i.i.d) و تنها منبع تصادفی بودن مسئله هستند. ما بردار طراحی x را ثابت (غیر تصادفی) در نظر می‌گیریم. هدف ما برازش یک مدل خطی و به دست آوردن تخمینی مانند w_λ برای پارامتر واقعی w است. تخمین رگرسیون ریدج برای w به صورت زیر است:

$$w_\lambda = \arg \min_{w \in \mathbb{R}} \left(\lambda w^T + \sum_{i=1}^n (y_i - x_i w)^2 \right) \quad \text{که } \lambda \geq 0 \text{ در آن}$$

(آ) مقدار w_λ را برحسب λ ، S_{xx} و S_{xy} بیان کنید، که در آن $S_{xx} = \sum_{i=1}^n x_i^2$ و $S_{xy} = \sum_{i=1}^n x_i y_i$ است.

(ب) مربع سوگیری (Squared Bias) تخمین گر ریدج $w_\lambda z$ را در نقطه تست $z \in \mathbb{R}$ محاسبه کنید که به صورت زیر تعریف می‌شود:

$$\text{bias}^2(w_\lambda, z) = (\mathbb{E}[w_\lambda z] - wz)^2$$

که در آن امید ریاضی نسبت به متغیرهای y_i گرفته می‌شود. نتیجه خود را برحسب w ، λ ، S_{xx} و z بیان کنید. (راهنمایی: ابتدا عبارت امید ریاضی را ساده کنید.)

(ج) اگر از روش حداقل مربعات (Ordinary Least Squares) استفاده کنیم (یعنی $\lambda = 0$)، مقدار سوگیری چقدر خواهد بود؟

۹ پاسخ دوگان برای رگرسیون ریدج (Dual Solution for Ridge Regression)

به یاد بیاورید که رگرسیون ریدج تابع هدف زیر را کمینه می‌کند:

$$L(w) = \|Xw - y\|_2^2 + \lambda \|w\|_2^2$$

که در آن X یک ماتریس طراحی $n \times d$ ، w یک بردار d -بعدی و y یک بردار n -بعدی است. می‌دانیم که تابع $L(w)$ توسط مقدار زیر کمینه می‌شود:

$$w^* = (X^T X + \lambda I)^{-1} X^T y$$

به عنوان یک روش جایگزین، نقطه کمینه‌کننده می‌تواند به صورت ترکیب خطی از سطرهاى ماتریس طراحی نمایش داده شود. یعنی، یک بردار n -بعدی α^* وجود دارد به طوری که تابع هدف $L(w)$ با $w^* = X^T \alpha^*$ برابر می‌شود. بردار α^* پاسخ دوگان (Dual Solution) برای مسئله رگرسیون خطی نامیده می‌شود.

(آ) با استفاده از رابطه $w = X^T \alpha$ ، تابع هدف L را برحسب α تعریف کنید.

(ب) نشان دهید که $\alpha^* = (XX^T + \lambda I)^{-1} y$ یک پاسخ دوگان است.

(ج) برای اینکه پاسخ در بخش (ب) خوش‌تعریف (Well-defined) باشد، ماتریس $XX^T + \lambda I$ باید معکوس‌پذیر باشد. با فرض $\lambda > 0$ ، نشان دهید که ماتریس $XX^T + \lambda I$ معکوس‌پذیر است. (راهنمایی: ماتریس‌های مثبت معین معکوس‌پذیر هستند.)