

مقدمه ای بر یادگیری ماشین (۱-۲۵۷۳۷)



تمرین سری چهارم

ترم بهار ۱۴۰۴-۰۵

دانشکده‌ی مهندسی برق

دانشگاه صنعتی شریف

استاد: دکتر سجاد امینی

مهلت تحویل: جمعه ۱۲ تیر ساعت ۲۳:۵۹

(*) مسائلی که با ستاره مشخص شده‌اند امتیازی هستند و حل کردن آن‌ها نمره‌ی امتیازی خواهد داشت!

۱ همگرایی Perceptron

الگوریتم Perceptron یکی از الگوریتم‌های پایه‌ای در یادگیری ماشین برای دسته‌بندی خطی‌پذیر (linearly separable) است. در این سوال قصد دارید قضیه همگرایی Perceptron را اثبات کنید.

مفروضات

۱. مجموعه داده آموزشی شامل m نمونه به صورت $\{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ است، که در آن $x_i \in \mathbb{R}^d$ و $y_i \in \{-1, +1\}$.

۲. فرض کنید داده‌ها خطی‌پذیر هستند. یعنی بردار $w^* \in \mathbb{R}^d$ و اسکالر $b^* \in \mathbb{R}$ وجود دارد به طوری که:

$$y_i(\langle w^*, x_i \rangle + b^*) \geq 1, \quad \forall i = 1, \dots, m$$

۳. همچنین فرض کنید $\|x_i\| \leq R$ برای همه i (یعنی داده‌ها در یک کره به شعاع R محدود هستند).

۴. الگوریتم Perceptron با قاعده به‌روزرسانی زیر داده شده است:

$$\begin{cases} w_{t+1} = w_t + y_i x_i \\ b_{t+1} = b_t + y_i \end{cases} \quad \text{: (پیش‌بینی اشتباه) اگر } y_i(\langle w_t, x_i \rangle + b_t) \leq 0$$

در غیر این صورت وزن‌ها تغییر نمی‌کنند.

مطلوب است:

۱. نشان دهید تعداد دفعات به‌روزرسانی الگوریتم Perceptron در حین اجرا روی مجموعه داده خطی‌پذیر، حداکثر $\frac{R^2 \|\theta^*\|^2 + 1}{\gamma^2}$ است، که در آن $\theta^* = [w^*; b^*]$ و $\gamma = \min_i y_i(\langle w^*, x_i \rangle + b^*) > 0$ (فاصله (margin) داده‌ها از ابرصفحه جداکننده).

۲. برای اثبات، مراحل زیر را دنبال کنید:

(آ) فرض کنید $\theta_t = [w_t; b_t]$ و $\phi_i = [x_i; 1]$ به ترتیب بردار وزن توسعه‌یافته و بردار ویژگی توسعه‌یافته باشند. قاعده به‌روزرسانی را بر حسب θ_t و ϕ_i بازنویسی کنید.

(ب) نشان دهید اگر در مرحله t به روزرسانی روی نمونه (x_i, y_i) انجام شود، آنگاه:

$$\langle \theta_{t+1}, \theta^* \rangle \geq \langle \theta_t, \theta^* \rangle + \gamma$$

(ج) همچنین نشان دهید:

$$\|\theta_{t+1}\|^2 \leq \|\theta_t\|^2 + R^2 + 1$$

(د) با استفاده از نامساوی Cauchy-Schwarz و ترکیب نتایج بالا، یک کران بالا برای تعداد به روزرسانی‌ها به دست آورید.

(ه) نتیجه بگیرید که الگوریتم Perceptron در تعداد متناهی گام همگرا می‌شود.

۳. توضیح دهید که اگر داده‌ها خطی‌پذیر نباشند (non-separable)، چه اتفاقی برای الگوریتم Perceptron می‌افتد؟ آیا همگرایی همچنان تضمین می‌شود؟

۲ مشتق کانولوشن


فرض کنید برداری به طول N دارید و قصد دارید یک لایه کانولوشن یک‌بعدی روی آن اعمال کنید. حاصل اعمال یک لایه کانولوشن را از طریق رابطه‌ی زیر به دست آورید:

$$Z = W * X \quad \longrightarrow \quad Z_i = \sum_{j=0}^{K-1} W_j X_{i+j}$$

به دست می‌آوریم که K اندازه‌ی فیلتر را نشان می‌دهد. اگر مقدار $\frac{\partial L}{\partial Z_i}$ برای تمامی مقادیر i بدانیم، رابطه‌ی مربوط به $\frac{\partial L}{\partial W_j}$ را به طور دقیق پیدا کنید. نشان دهید این رابطه، عملاً معادل اعمال یک فیلتر کانولوشن است.

۳ کانولوشن گسترش یافته

در شبکه‌های پیچشی به صورت متداول از لایه‌های کانولوشن ساده استفاده می‌شود که با آن‌ها آشنا هستید. نوع دیگری از لایه‌ها که می‌توان از آن‌ها در شبکه‌های پیچشی استفاده نمود، لایه کانولوشن گسترش یافته یا متغیر است. در شکل ۱ تصویر شهودی از فیلتر کانولوشن گسترش یافته ارائه شده است. این فیلترها میان خانه‌هایی که فیلتر با استفاده از اطلاعات آن‌ها لایه بعد را محاسبه می‌کند فاصله می‌اندازند یا به بیانی دیگر در زمان اعمال فیلتر و انجام عملیات ضرب کانولوشن، بر روی ورودی با گام (dilated) بزرگتری حرکت می‌کنیم. توجه کنید طول گام مفهومی متفاوت نسبت به طول گام (stride) در لایه‌های شبکه کانولوشن دارد.



شکل ۱: شهودی از کانولوشن گسترش یافته با گام‌های متفاوت

همانطور که در شکل نیز مشخص است این روش، یک روش کم هزینه برای افزایش محدوده دید شبکه‌های پیچشی است. کانولوشن گسترش یافته به صورت فرم بسته ریاضی زیر تعریف می‌شود:

$$(K *_D I)(i, j) = \sum_{m=-\infty}^{\infty} \sum_{n=-\infty}^{\infty} K(m, n) I(i + Dm, j + Dn)$$

(آ) برای ورودی $I \in \mathbb{R}^{M \times N}$ و کرنل $K \in \mathbb{R}^{F \times F}$ نشان دهید خروجی عملگر کانولوشن گسترش یافته دارای ابعاد $(M - DF + D) \times (N - DF + D)$ است.

(ب) نشان دهید کانولوشن گسترش یافته معادل کانولوشن با کرنل متغیر شده K' است. ماتریس A را مشخص کنید. ($K' = K \otimes A$ ، عملگر $\otimes$ کرونکر محصول (kronecker product) است.)

(ج) فرض کنید یک لایه ورودی با ابعاد $M \times N$ به یک شبکه عصبی با سه لایه کانولوشن گسترش یافته داده می شود. در این شبکه، هر لایه کانولوشن شامل تعدادی فیلتر است که بر روی قسمت های مختلف ورودی حرکت می کند و ویژگی های گوناگون آن را استخراج می کند. هدف ما بررسی تعداد پیکسل های قابل مشاهده توسط یک عنصر خاص مانند (i, j) از خروجی است. به عبارت دیگر، محدوده ای از ورودی که این عنصر را تحت تأثیر قرار می دهد را در صورت وجود امکان محاسبه به صورت پارامتری بیابید.

ابعاد فیلترها به ترتیب از چپ به راست برابر هستند با:


$$(w - 1) \times (w - 1), \quad w \times w, \quad (w + 1) \times (w + 1)$$

پارامتر گسترش این فیلترها به ترتیب از چپ به راست برابر است با:

$$d - 1, \quad d, \quad d + 1$$

۴ Convolution Backpropagation

یکی از اساسی ترین اجزا در یک شبکه ژرف، انتشار به عقب یا Backpropagation است. شبکه داده شده در شکل را در نظر بگیرید. در این شکل، وزن های لایه اول با $W^{(1)}$ و وزن های لایه دوم با $W^{(2)}$ و وزن های لایه تمام متصل با $W^{(fc)}$ نمایش داده شده اند. همچنین، $P^{(1)}$ ، $P^{(2)}$ و $P^{(3)}$ به ترتیب خروجی های لایه اول، دوم و سوم شبکه هستند.



شکل ۲: معماری شبکه

- ورودی شبکه: یک تانسور با ابعاد $8 \times 4 \times 4$
- لایه اول: لایه کانولوشن با ۴ فیلتر $1 \times 1 \times 4$ که خروجی $P^{(1)}$ با ابعاد $4 \times 4 \times 4$ تولید می کند.
- لایه دوم: لایه کانولوشن با ۱ فیلتر $2 \times 2 \times 4$ که خروجی $P^{(2)}$ با ابعاد $1 \times 1 \times 4$ تولید می کند.
- لایه سوم: لایه Avg. Pooling با کرنل 2×2 و گام ۲، که خروجی $P^{(3)}$ با ابعاد $1 \times 1 \times 1$ ایجاد می کند.
- لایه چهارم: لایه Flatten که $P^{(3)}$ را به یک بردار v با ابعاد 1×1 تبدیل می کند.
- لایه پنجم: لایه تمام متصل با تابع فعال سازی Sigmoid که خروجی نهایی را تولید می کند.

وزن های فیلترهای کانولوشن در لایه های اول و دوم ($W^{(1)}$ و $W^{(2)}$) و وزن های لایه تمام متصل ($W^{(fc)}$) از جمله پارامترهای قابل آموزش شبکه هستند. هدف شبکه، بهینه سازی این وزن ها برای کمینه سازی یک تابع زیان است.

وظایف:

۱. با استفاده از قاعده مشتق زنجیره ای و بر اساس مشتق $\frac{\partial L}{\partial z}$ ، عبارت های زیر را محاسبه کنید:

$$\frac{\partial L}{\partial P_{i,j}^{(3)}} \text{ یعنی Average Pooling لایه خروجی نسبت به گرادیان زیان نسبت به خروجی لایه } \bar{A}$$

(ب) گرادیان زیان نسبت به خروجی لایه اول کانولوشن یعنی $\frac{\partial L}{\partial P_{i,j,k}^{(1)}}$

۲. گرادیان زیان نسبت به وزن $W_{1,1,k}^{(1)}$ یکی از فیلترهای لایه اول کانولوشن را محاسبه کنید.

۳. عبارت گرادیان $\frac{\partial L}{\partial W_{i,j,k}^{(2)}}$ یکی از وزنهای فیلتر کانولوشن لایه دوم را به دست آورید.

۵ PDS Kernels

نشان دهید هسته‌های (kernel) زیر (PDS) Positive Definite Symmetric هستند:

۱. $K(x, y) = \cos(x - y)$ بر روی $\mathbb{R} \times \mathbb{R}$

۲. $K(x, y) = \cos(x^2 - y^2)$ بر روی $\mathbb{R} \times \mathbb{R}$

۳. $K(x, y) = (x + y)^{-1}$ بر روی $(0, +\infty) \times (0, +\infty)$

۴. $K(x, x') = \cos \angle(x, x')$ بر روی $\mathbb{R}^n \times \mathbb{R}^n$ ، که در آن $\angle(x, x')$ زاویه بین x و x' است.

۵. $K(x, x') = \exp(-\lambda [\sin(x' - x)]^2)$ بر روی $\mathbb{R} \times \mathbb{R}$ ، $\forall \lambda > 0$ (راهنمایی: $[\sin(x' - x)]^2$ را به صورت مربع نرم اختلاف دو بردار بازنویسی کنید).

۶ Explicit Polynomial Kernel Mapping

فرض کنید K یک هسته چندجمله‌ای (polynomial kernel) از درجه d باشد، یعنی:

$$K : \mathbb{R}^N \times \mathbb{R}^N \rightarrow \mathbb{R}, \quad K(\mathbf{x}, \mathbf{x}') = (\mathbf{x} \cdot \mathbf{x}' + c)^d, \quad c > 0$$

نشان دهید بعد فضای ویژگی (feature space) مرتبط با K برابر است با:

$$\binom{N+d}{d}$$

K را بر حسب هسته‌های $k_i : (\mathbf{x}, \mathbf{x}') \mapsto (\mathbf{x} \cdot \mathbf{x}')^i$ که در آن $i \in [0, d]$ است، بنویسید. وزن تخصیص داده شده به هر k_i در این عبارت چیست؟ این وزن چگونه به صورت تابعی از c تغییر می‌کند؟

۷ Classifier-Based Kernel

فرض کنید S یک نمونه آموزشی به اندازه m باشد. فرض می‌کنیم S بر اساس توزیع احتمال $D(x, y)$ تولید شده است، که در آن $(x, y) \in X \times \{-1, +1\}$.

۱. طبقه‌بند بیز (Bayes classifier) $h^* : X \rightarrow \{-1, +1\}$ را تعریف کنید. نشان دهید هسته K^* که به صورت $K^*(x, x') = h^*(x)h^*(x')$ برای هر $x, x' \in X$ تعریف می‌شود، متقارن و مثبت معین (positive definite symmetric) است. بعد فضای ویژگی طبیعی (natural feature space) مرتبط با K^* چقدر است؟

۲. بیان جواب به دست آمده با استفاده از SVMها و این هسته را ارائه دهید. تعداد بردارهای پشتیبان (support vectors) چقدر است؟ مقدار حاشیه (margin) چقدر است؟ خطای تعمیم (generalization error) جواب به دست آمده چقدر است؟ تحت چه شرایطی داده‌ها به صورت خطی جداپذیر (linearly separable) هستند؟

۳. فرض کنید $h : X \rightarrow \mathbb{R}$ یک تابع دلخواه با مقدار حقیقی باشد. تحت چه شرطی روی h ، هسته K که به صورت $K(x, x') = h(x)h(x')$ برای $x, x' \in X$ تعریف می‌شود، متقارن و مثبت معین است؟

Soft and Hard SVM ۸

۱. اثبات کنید مسئله Hard-Margin SVM تنها در حالتی جواب دارد که مجموعه آموزشی separable باشد. در ادامه نشان دهید این مسئله ابرصفحه با بیشینه Margin را پیدا می‌کند.

۲. مسئله دوگان Hard-Margin SVM را بدست آورید. در صورتی که مسئله دوگان را حل کنیم، چگونه می‌توانیم یک نقطه جدید را classify کنیم؟ در ادامه فرض کنید مجموعه آموزشی separable باشد. مسئله Soft-Margin SVM را بنویسید و متغیرهای جدید اضافه شده را توضیح دهید. در ادامه دوگان این مسئله را نیز بدست آورید.

۳. نشان دهید مسئله Soft-Margin SVM با مسئله زیر معادل است.

$$\min_{w,b} \lambda \|w\|^2 + \frac{1}{m} \sum_{i=1}^m \max\{0, 1 - y_i(\langle w, x_i \rangle + b)\}$$