

مقدمه ای بر یادگیری ماشین (۱-۲۵۷۳۷)



تمرین سری پنجم

ترم بهار ۱۴۰۴-۰۵

دانشکده‌ی مهندسی برق

دانشگاه صنعتی شریف

استاد: دکتر سجاد امینی

مهلت تحویل: یکشنبه ۲۱ تیر ساعت ۸:۵۹

(*) مسائلی که با ستاره مشخص شده‌اند امتیازی هستند و حل کردن آن‌ها نمره‌ی امتیازی خواهد داشت!

۱ SVM با کرنل گاوسی

آموزش یک ماشین بردار پشتیبان با استفاده از کرنل گاوسی زیر را در نظر بگیرید:

$$K(x, z) = \exp(-||x - z||^2 / \tau^2).$$

ما نشان خواهیم داد که تا زمانی که هیچ دو نقطه یکسانی در مجموعه آموزشی وجود نداشته باشد، همواره می‌توان مقداری برای پارامتر پهنای باند τ پیدا کرد به طوری که SVM به خطای آموزشی صفر دست یابد.

۱. تابع تصمیم یاد گرفته شده توسط ماشین بردار پشتیبان را می‌توان به صورت زیر نوشت:

$$f(x) = \sum_{i=1}^m \alpha_i y^{(i)} K(x^{(i)}, x) + b.$$

فرض کنید داده‌های آموزشی $\{(x^{(i)}, y^{(i)})\}_{i=1}^m$ شامل نقاطی هستند که حداقل به اندازه فاصله ϵ از هم جدا شده‌اند، یعنی $||x^{(i)} - x^{(j)}|| \geq \epsilon$ برای $i \neq j$. مقادیری برای پارامترهای $\{\alpha_i\}$ ، b ، و τ بیابید به طوری که هر $x^{(i)}$ به درستی دسته‌بندی شود.

راهنمایی: فرض کنید $\alpha_i = 1$ برای تمام i ها و $b = 0$ باشد. سپس توجه کنید که برای $y \in \{\pm 1\}$ پیش‌بینی روی $x^{(i)}$ صحیح است اگر $|f(x^{(i)}) - y^{(i)}| < 1$ باشد، بنابراین τ را طوری انتخاب کنید که این نامساوی برای تمام i ها برقرار باشد.

۲. فرض کنید یک SVM را با slack variables و با استفاده از پارامتر τ که در قسمت (الف) یافتید، اجرا می‌کنیم. آیا دسته‌بند حاصل لزوماً به خطای آموزشی صفر دست خواهد یافت؟ چرا؟ یک توضیح کوتاه (بدون اثبات) کافی است.

۲ تحلیل مؤلفه‌های اصلی (PCA) و خطی بودن ویژگی‌ها (کاهش ابعاد)

فرض کنید یک مجموعه داده داریم که با ماتریس طراحی مرکز یافته $X \in \mathbb{R}^{N \times D}$ نمایش داده شده است، و ماتریس کوواریانس نمونه آن را به صورت $S = \frac{1}{N} X^T X$ محاسبه می‌کنیم. فرض کنید مقادیر ویژه S برابر با $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D \geq 0$ باشد. بردارهای ویژه یک‌ه و متعامد (orthonormal) متناظر $p_1, \dots, p_D$ باشند.

اکنون فرض کنید مجموعه داده را با افزودن یک ویژگی جدید که دقیقاً کپی ویژگی اول است، گسترش دهیم. بنابراین، ماتریس طراحی جدید به صورت $\tilde{X} = [X, X_{:,1}] \in \mathbb{R}^{N \times (D+1)}$ خواهد بود.

۱. فرض کنید $\tilde{S}$ ماتریس کواریانس نمونه جدید با ابعاد $(D+1) \times (D+1)$ باشد. مقادیر ویژه جدید $\tilde{\lambda}_i$ و بردارهای ویژه جدید $\tilde{p}_i$ را به صورت تحلیلی برحسب λ_i و p_i اولیه به دست آورید.
۲. اگر الگوریتم PCA را روی $\tilde{X}$ اجرا کنیم و داده‌ها را روی اولین مؤلفه اصلی آن تصویر کنیم، آیا واریانس این تصویر یک‌بعدی با تصویر کردن X اولیه روی اولین مؤلفه اصلی‌اش متفاوت خواهد بود؟ پاسخ خود را به صورت ریاضی اثبات کنید.
۳. بر اساس یافته‌های خود، به صورت شهودی توضیح دهید که چرا PCA نسبت به تغییر مقیاس ناوردا (scale-invariant) نیست و چرا استانداردسازی داده‌ها پیش از اعمال PCA بسیار حیاتی است.

۳ الگوریتم AdaBoost و حاشیه‌های زیان نمایی

- الگوریتم AdaBoost به صورت تکراری یک مدل افزودنی به فرم $f_M(x) = \sum_{m=1}^M \beta_m F_m(x)$ را با کمینه‌سازی زیان نمایی $L_m(F) = \sum_{i=1}^N \exp(-y_i(f_{m-1}(x_i) + \beta F(x_i)))$ می‌سازد که در آن $y \in \{-1, +1\}$.
۱. در گام M از مدل‌سازی افزودنی مرحله به مرحله پیشرو، ضریب به‌روزرسانی وزن‌ها به صورت $\beta_m = \frac{1}{Z} \log \left(\frac{1 - \text{err}_m}{\text{err}_m} \right)$ دست می‌آید. این فرمول را با یافتن β_m بهینه‌ای که زیان نمایی L_m را کمینه می‌کند، استخراج کنید.
 ۲. تابع زیان نمایی، حاشیه‌های منفی بزرگ (جایی که $y_i f(x_i) \ll 0$) را به شدت جریمه می‌کند. به صورت ریاضی توضیح دهید که با افزایش m ، وزن نمونه‌ها $(w_{i,m+1})$ برای داده‌های پرت بسیار شدید چگونه رفتار می‌کند.
 ۳. با توجه به تفاوت‌های Discrete AdaBoost و Real AdaBoost، توضیح دهید که استفاده از خروجی‌های حقیقی (Confidence scores) در مدل Real AdaBoost چگونه می‌تواند به کالیبره شدن حاشیه‌ها در برابر داده‌های پرت کمک کند و رفتار تابع زیان را تغییر دهد؟
 ۴. الگوریتم AdaBoost را با یک مدل Bagging متشکل از دقیقاً همان یادگیرنده‌های ضعیف مقایسه کنید. اگر یک مجموعه داده واقعی با ۳۰٪ برچسب‌های کاملاً مخدوش (نویز خالص) به شما داده شود، انتظار دارید کدام روش گروهی بیشتر آسیب ببیند و دچار بیش‌برازش (overfit) شود؟ استدلال خود را بر پایه تابع زیان نمایی و ماهیت ترتیبی Boosting بنا کنید.

۴ Fisher kernel (*)

یک توزیع گاوسی با بردار میانگین μ و ماتریس کواریانس معلوم Σ در نظر بگیرید. کرنل فیشر بین دو نقطه داده x و x' به صورت زیر تعریف می‌شود:

$$k(x, x') = U(x)^T \mathcal{I}^{-1} U(x'),$$

که در آن $U(x) = \nabla_{\mu} \log p(x | \mu)$ گرادیان لگاریتم درست‌نمایی نسبت به پارامتر میانگین μ است، و $\mathcal{I}$ ماتریس اطلاعات فیشر می‌باشد. کرنل فیشر را برای این توزیع گاوسی به دست آورید. ابتدا، Fisher score را محاسبه کنید:

$$U(x) = \nabla_{\mu} \log \mathcal{N}(x | \mu, \Sigma)$$

سپس، ماتریس اطلاعات فیشر را محاسبه نمایید:

$$\mathcal{I} = \mathbb{E}_x[U(x)U(x)^T]$$

این مقادیر را در عبارت کرنل فیشر جایگذاری کرده و نشان دهید که رابطه به صورت زیر ساده می‌شود:

$$k(x, x') = (x - \mu)^T \Sigma^{-1} (x' - \mu),$$

که همان ضرب داخلی ماهالانویس مجذور بین x و x' است.

۵ پیوند هندسی یادگیری بدون نظارت و با نظارت (PCA + درخت‌های تصمیم) (*)

درخت‌های تصمیم (CART) فضای ورودی را با استفاده از انشعاب‌های هم‌راستا با محورها (axis-aligned splits) تقسیم می‌کنند. از سوی دیگر، PCA داده‌ها را روی یک پایه متعامد جدید تصویر می‌کند.

۱. فرض کنید یک مجموعه داده دسته‌بندی دوتایی و دویعدی داریم که در آن کلاس مثبت در امتداد خط $x_2 = x_1 + 2$ و کلاس منفی در امتداد خط $x_2 = x_1 - 2$ با فشردگی بالا خوشه‌بندی شده‌اند. به صورت ریاضی و هندسی توضیح دهید که چرا یک درخت تصمیم استاندارد برای جداسازی این کلاس‌ها، با وجود تفکیک‌پذیری خطی آن‌ها، به عمق بسیار زیادی نیاز خواهد داشت.

۲. اکنون فرض کنید PCA را بر روی کل مجموعه داده ترکیب‌شده اعمال می‌کنیم. ثابت کنید که اولین مؤلفه اصلی p_1 موازی با بردار $[1, 1]^T$ خواهد بود.

۳. فرض کنید $z_2 = p_2^T x$ و $z_1 = p_1^T x$ ویژگی‌های تبدیل‌شده با PCA باشند. نشان دهید که یک درخت تصمیم آموزش‌دیده روی داده‌های تبدیل‌شده Z ، برای رسیدن به خطای آموزشی صفر تنها به عمق ۱ (یک تک انشعاب) نیاز دارد.

۴. در قسمت‌های قبل، PCA به طور بی‌نقصی به درخت تصمیم کمک کرد. یک پیکربندی هندسی خاص از مجموعه داده را توصیف کنید که در آن داده‌های خام برای دسته‌بندی کامل تنها به ۱ انشعاب نیاز دارند، اما داده‌های تبدیل‌شده با PCA این تفکیک‌پذیری را از بین برده و درخت تصمیم را مجبور می‌کند به طور غیرضروری عمیق شده و دچار بیش‌برازش شود.

۶ الگوریتم انتظار-بیشینه‌سازی (EM) و کران ELBO (*)

در الگوریتم EM برای یک مدل ترکیبی گاوسی (GMM)، ما به طور متناوب بین به‌روزرسانی احتمالات پسین متغیرهای پنهان (گام E) و پارامترهای توزیع (گام M) جابجا می‌شویم. الگوریتم EM کران پایین شواهد (ELBO) را بهینه‌سازی می‌کند:

$$\mathcal{L}(\theta, q) = \sum_{n=1}^N (\mathbb{E}_{q_n} [\log p(x_n, z_n | \theta)] + \mathbb{H}(q_n))$$

۱. نشان دهید که تفاوت بین لگاریتم درست‌نمایی واقعی $LL(\theta) = \sum_{n=1}^N \log p(x_n | \theta)$ و ELBO دقیقاً برابر با دیورژانس کولبک-لایلر (KL) بین توزیع متغیر $q_n(z_n)$ و توزیع پسین واقعی $p(z_n | x_n, \theta)$ است.

۲. ثابت کنید که در گام E، قرار دادن $q_n(z_n) = p(z_n | x_n, \theta^{(t)})$ باعث می‌شود کران ELBO دقیقاً با لگاریتم درست‌نمایی برابر شود (یعنی کران مماس یا tight می‌شود).

۳. مجانب‌های K-Means سخت (Hard K-Means Asymptotics): فرض کنید یک GMM با K مؤلفه داریم که در آن ماتریس‌های کوواریانس برای همه k ها به فرم $\Sigma_k = \epsilon I$ محدود شده‌اند. ثابت کنید که وقتی $\epsilon \rightarrow 0$ ، احتمال پسین در گام E یعنی $q_n(z_n = k)$ به یک بردار one-hot تبدیل می‌شود. در نتیجه، نشان دهید که الگوریتم EM به طور کامل به الگوریتم خوشه‌بندی K-Means استاندارد تقلیل می‌یابد.

۴. تحلیل کیفی: در EM استاندارد برای GMM، ماتریس‌های کوواریانس Σ_k گاهی اوقات ممکن است در طول گام M بدحالت (ill-conditioned) یا تکین شوند. به صورت هندسی و احتمالاتی توضیح دهید چرا این پدیده "فروپاشی واریانس" رخ می‌دهد. بدون نوشتن معادلات صریح، توضیح دهید که معرفی یک پیشین بیزی (Bayesian prior) روی ماتریس‌های کوواریانس چگونه از این امر جلوگیری می‌کند؟