

تمرین ۵

حامد باطای ۱۳۹۹/۱۰/۲۶

$$y^{(i)} f(x^{(i)}) > 0$$

۱) برای این SVM در دسته بندی کند:

$$\text{hint} \rightarrow f(x) = \sum_{j=1}^m y^{(j)} K(x^{(j)}, x)$$

$$\rightarrow y^{(i)} f(x^{(i)}) = y^{(i)} K(x^{(i)}, x^{(i)}) + y^{(i)} \sum_{j \neq i} y^{(j)} K(x^{(j)}, x^{(i)})$$

$$= 1 + \sum_{j \neq i} y^{(i)} y^{(j)} \exp\left(-\frac{\|x^{(i)} - x^{(j)}\|^2}{\sigma^2}\right)$$

$$\Rightarrow |f(x^{(i)}) - y^{(i)}| = \left| \sum_{j \neq i} y^{(j)} \exp\left(-\frac{\|x^{(j)} - x^{(i)}\|^2}{\sigma^2}\right) \right|$$

$$\sum_{j \neq i} 1 \cdot \exp\left(-\frac{\|x^{(j)} - x^{(i)}\|^2}{\sigma^2}\right) < (m-1) \exp\left(-\frac{\epsilon^2}{\sigma^2}\right)$$

همچنین می دانیم که (نامساوی مثلث)

$$(m-1) \exp\left(-\frac{\epsilon^2}{\sigma^2}\right) < 1 \rightarrow \exp\left(-\frac{\epsilon^2}{\sigma^2}\right) < \frac{1}{m-1}$$

$$\rightarrow \sigma < \frac{\epsilon}{\sqrt{\ln(m-1)}}$$

۲. خیر. زیرا که در soft margin sum، الگوریتم به دنبال توازن بین حاشیه و میزان خطا است. در صورتی که پارامتر جریمه C به اندازه کافی بزرگ نباشد، مدل ترجیح می دهد برای بدست آوردن حاشیه امن بزرگ تر، خطای غیر صفر را روی داده های آموزشی بپذیرد.

$$\tilde{p}_0 = \frac{1}{\sqrt{K}} \begin{bmatrix} -1 \\ 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix} = \frac{1}{\sqrt{K}} \begin{bmatrix} -e_1 \\ 1 \end{bmatrix} \quad \checkmark$$

(1)

.1

$$\tilde{S} p_0 = \begin{bmatrix} s & s e_1 \\ e_1^T s & e_1^T s e_1 \end{bmatrix} \tilde{p}_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \rightarrow \tilde{\lambda}_0 = 0 \quad \checkmark$$

$$\tilde{S} \tilde{p} = \tilde{\lambda} \tilde{p} \rightarrow M^T S M \tilde{p} = \tilde{\lambda} \tilde{p} \rightarrow M M^T S M \tilde{p} = \tilde{\lambda} M \tilde{p}$$

$$w = M \tilde{p} \in \mathbb{R}^p, \quad M M^T = \begin{bmatrix} I_p e_1 \end{bmatrix} \begin{bmatrix} I_p \\ e_1^T \end{bmatrix} = I_p + e_1 e_1^T$$

$$\Rightarrow S w + e_1 e_1^T S w = \tilde{\lambda} w \rightarrow w = (\tilde{\lambda} I_p - S)^{-1} e_1 (e_1^T S w)$$

$$\rightarrow e_1^T S w = e_1^T S (\tilde{\lambda} I_p - S)^{-1} e_1 e_1^T S w$$

$$\Rightarrow e_1^T S (\tilde{\lambda} I_p - S)^{-1} e_1 = 1$$

$$\Rightarrow e_1 \left(\sum_{j=1}^p \frac{\lambda_j}{\tilde{\lambda} - \lambda_j} p_j p_j^T \right) e_1 = 1$$

$$\Rightarrow \sum_{j=1}^p \frac{\lambda_j p_{j,1}^2}{\tilde{\lambda} - \lambda_j} = 1 \quad (\tilde{\lambda}_i \text{ equation}) \quad \checkmark$$

$$\tilde{p}_i = \frac{1}{\tilde{\lambda}_i} \begin{bmatrix} s w_i \\ e_1^T s w_i \end{bmatrix} = \begin{bmatrix} w_i - \frac{e_1^T s w_i e_1}{\tilde{\lambda}_i} \\ \frac{e_1^T s w_i}{\tilde{\lambda}_i} \end{bmatrix} \quad \checkmark$$

$$\text{var}_{\text{old}} = \lambda_1 = \max_{u: \|u\|_2=1} u^T S u$$

$$\text{var}_{\text{new}} = \tilde{\lambda}_1 \max_{\tilde{p}: \|\tilde{p}\|_2=1} \tilde{p}^T \tilde{S} \tilde{p}$$

.2

$$p = \begin{bmatrix} u \\ \alpha \end{bmatrix}, \quad \|u\|_2^2 + \alpha^2 = 1$$

$$\rightarrow \tilde{x}_1 = \max_{u, \alpha} \begin{bmatrix} u^T \alpha \\ e_1^T s \quad e_1^T s e_1 \end{bmatrix} \begin{bmatrix} u \\ \alpha \end{bmatrix}$$

$$= \max_{u, \alpha} (u + \alpha e_1)^T s (u + \alpha e_1)$$

اگر فرض کنیم بردار ترکیب نهایی، هم راست با وکتور مولفه اول است.

$$u + \alpha e_1 = k p_1 \Rightarrow u = k p_1 - \alpha e_1$$

$$\rightarrow \text{واریانس مقور} = (k p_1)^T s (k p_1) = k^2 \lambda$$

$$\rightarrow \|k p_1 - \alpha e_1\|_2^2 + \alpha^2 = 1, \quad \|p_1\|_2 = \|e_1\|_2 = 1, \quad p_{1,1} = e_1^T p_1$$

$$\Rightarrow 2\alpha^2 - 2k p_{1,1} \alpha + (k^2 - 1) = 0$$

برای دانستن جواب حقیقی نبی به α :

$$\Delta = (2k p_{1,1})^2 - 4(2)(k^2 - 1) \geq 0 \Rightarrow k^2 \leq \frac{2}{2 - p_{1,1}}$$

$$0 < p_{1,1} < 1 \quad \text{بردار یکتا است}$$

$$\Rightarrow \tilde{x}_1 \geq k^2 \lambda > \lambda_1$$

پس به متغیرهای خواسته بود (بزرگترین) گرد در هر دو حالت خاص $(p_{1,1} = 0)$

تغییر در ساختار و مقیاس یک ویژگی مانند تکرار آج، ماتریس کوواریانس را تغییر می دهد
 هم. و به سبب خود می کشد. هدف PCA ماکزیمیز کردن پراکندگی عددی است پس

به مقیاس و ساختار داده ها حساس است نه به مقیاس و ساختار داده ها

تا تفاوت در واحد های اندازه گیری، جهت معادله های اصل را مخدوش کند

۳

۱.

طبق Forward stagewise additive model

$$L_m(\beta, F) = \sum_{i=1}^N \exp(-y_i (t_{m-1}(x_i) + \beta F(x_i)))$$

where $y_i \in \{-1, +1\}$, $F(x_i) \in \{-1, 1\}$

$$w_{i,m} \triangleq \exp(-y_i t_{m-1}(x_i))$$

$$\rightarrow L_m(\beta, F) = \sum_{i=1}^N w_{i,m} \exp(-y_i \beta F(x_i))$$

$y_i F(x_i)$ تبادله مقدار دارد، $\leftarrow$

$$L_m(\beta, F) = \sum_{y_i = F(x_i)} w_{i,m} \exp(-\beta) + \sum_{y_i \neq F(x_i)} w_{i,m} \exp(\beta)$$

$\sum w_{i,m} \exp(-\beta)$ را که وزن می بینیم.

$$\begin{aligned} \rightarrow &= \exp(-\beta) \sum_{i=1}^N w_{i,m} + (\exp(\beta) - \exp(-\beta)) \sum_{i=1}^N w_{i,m} \mathbb{I}(y_i \neq F(x_i)) \\ &= [\exp(-\beta)(1 - \text{err}_m) + \exp(\beta) \text{err}_m] \sum_{i=1}^N w_{i,m} \end{aligned}$$

$$\frac{\partial L_m}{\partial \beta} = 0 \rightarrow \exp(2\beta) = \frac{1 - \text{err}_m}{\text{err}_m}$$

$$\rightarrow \beta_m = \frac{1}{2} \ln\left(\frac{1 - \text{err}_m}{\text{err}_m}\right)$$

$$w_{i,m+1} = w_{i,m} \exp(\gamma_i \beta_i F_m(q_i))$$

۲. در اینجا

برای داده های y_i $F_m(q_i) = -1$ ←

$$w_{i,m+1} = w_{i,m} \exp(\beta_m) , \beta_m > 0$$

با افزایش m ، وزن داده های y_i به شکل نمایی افزایش می یابد و الگوریتم در هر مرحله m وزن این اعداد را در عددی از یک بزرگ تر ضرب می کند. به وزن داده های y_i بر تابع هدف صدق شده $\rightarrow$ تغییر نامناسب هر

$$F_m(q) = \frac{1}{2} \ln \left(\frac{p_m(q)}{1 - p_m(q)} \right)$$

در Real Adaboost، خروجی های حقیقی پیوسته نقش تبدیل کننده شده به ± 1 را بازی می کنند، برخلاف مدل گسسته که جستجو بسته به ± 1 و تائیدی به داده های y_i اعمال می کند. در واقع مدل پیوسته با کاهش F_m روی نقاط y_i ، حاشیه تصمیم روگایر می کند (تابع cost باید از 0 باشد)

۳. Bagging مدل های خود را موازی و مستقل آموزش می دهد Adaboost بسیار بهتر از overfit می کند چون به دلیل ماهیت ترتیبی، در هر گام روی خطای قبلی ~~متمرکز~~ متمرکز شده و به دلیل cost نمایی، وزن نویز زیاد شده و مدل ساختار ~~مقاوم~~ دگر نویز را بی اثر می کند و در واقع حفظ می کند

$$p(u) = N(u, \Sigma)$$

$$\rightarrow \log p = -\frac{n}{2} \log 2\pi - \frac{1}{2} \log |\Sigma| - \frac{1}{2} (x-u)^T \Sigma^{-1} (x-u) \quad (11)$$

$$\rightarrow \nabla_u = -\Sigma^{-1} (x-u) = u(x)$$

$$I = E_u [u(x) u(x)^T] = E_u [\Sigma^{-1} (x-u) (x-u)^T \Sigma^{-1}]$$

$$= \Sigma^{-1} E_u [(x-u) (x-u)^T] \Sigma^{-1} = \Sigma^{-1} \Sigma \Sigma^{-1} = \Sigma^{-1}$$

$$\Rightarrow K(x, x') = u(x)^T I^{-1} u(x')$$

$$= (x-u)^T \Sigma^{-1} \Sigma \Sigma^{-1} (x'-u) = (x-u)^T \Sigma^{-1} (x'-u)$$

۱ دقیق فرم ما لایف بک

(12)

۱. درختهای تقسیم، فضای ورودی روی ~~شکل~~ بازنمایی و از طریق انشعاب

های هموار است با محورهای تقسیم بندی می کند و هر شریک در گره داخلی صرفاً به

محور نامگذاری روی یک ویژگی واحد عمل می کند (مثلاً (x, y)) پس برای

جداسازی کلاسی های که مرز واقعاً صواب نیست، مجبوراً تقریب دیگری می زنیم.

۲- ممکن زیاده نیمی درخت می شود

$$\max_a a^T S a \text{ subject to } \|a\|_2 = 1 \quad ۲.$$

۱

که د ماتریس کواریانس است.

داده های هر دو کلاس در امتداد خطوطی با شیب یکسان هستند $\rightarrow V = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

$$S = \begin{bmatrix} \sigma^2 & \rho \sigma^2 \\ \rho \sigma^2 & \sigma^2 \end{bmatrix} \quad \text{س:}$$

که ۱ د پ نشان می دهد همبستگی زیاد مثبت است.

$$\text{بزرگترین مقدار ویژه} \rightarrow \lambda_1 = \sigma^2(1+\rho), \lambda_2 = \sigma^2(1-\rho)$$

۱- اولین مؤلفه اصلی حاصل از $\beta_1 \sim \beta_2$ باشد دقیق موازی با $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ است

$$\beta_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad ۳.$$

$$\beta_2 \text{ orthonormal} \rightarrow \beta_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

$$\Rightarrow z_1 = \beta_1^T x = \frac{1}{\sqrt{2}}(x_1 + x_2), z_2 = \beta_2^T x = \frac{1}{\sqrt{2}}(x_2 - x_1)$$

بر کلاس مثبت، نقاط ریس $x_2 = x_1 + \gamma$

$$z_2 = \frac{\gamma}{\sqrt{2}}$$

$$\gamma > 0 \rightarrow z_2 > 0$$

$$z_2 < 0$$

همین روش برای کلاس منفی نشان می دهد که

س: $z_2 = 0$ مرز این آ می باشد.

ک.

داده های که فلاس مثبت آن در ربع سوم هستند ($x_1 < 0$)

فلاس منفی در ربع اول ($x_1 > 0$) به شکل یک بیضی بسیار کشیده در امتداد خط

$x_1 = x_2$ توزیع شده اند.

اینطور داده های خام، باید تک انشعاب به معنای است با هم ($x_1 < 0$)

کاملاً تکلیف می شن اما PCA تحت کشیدگی بیضی، محورهای عمود بر هم می

فرخونه ← overfit

$$L = \sum_{2n} q_n(2n) \log \frac{p(x_n, 2n | \theta)}{q_n(2n)} \rightarrow p(2n | \theta, x_n) p(x_n | \theta) \quad (4)$$

$$= \underbrace{\sum q_n(2n) \log \frac{p(2n | x_n, \theta)}{q_n(2n)}}_{p_{KL}} + \sum q_n(2n) \log p(x_n | \theta)$$

$$\Rightarrow L(\theta, q) = \sum_{n=1}^N L(\theta, q_n | x_n) = \log p \sum_{2n} q_n(2n)$$

$$\rightarrow L(\theta, q) = L(\theta) - \sum_{n=1}^N D_{KL} \left(\frac{q_n(2n)}{p(2n | x_n, \theta)} \right)$$

$$q_n^{(t)}(2n) = p(2n | x_n, \theta^{(t)})$$

۲.

$$\Rightarrow D_{KL} A = \sum_{2n} p(2n | x_n, \theta^{(t)}) \log 1 = 0$$

$$\rightarrow L(\theta^{(t)}, q^{(t)}) = L(\theta^{(t)}) \quad \checkmark$$

$$q_n(z_n) \Big|_{z_n=k} = \frac{\pi_k \mathcal{N}(a_n | a_k, \Sigma_k)}{\sum_{l=1}^K \pi_l \mathcal{N}(a_n | a_l, \Sigma_l)} \quad . \omega$$

$$\xi_k = \epsilon I \Rightarrow q_n(z_n=k) = \frac{\pi_k \exp\left(-\frac{1}{2\epsilon} \left[\|a_n - a_k\|^2 - \|a_n - a_k^*\|^2 \right]\right)}{\sum_{l=1}^K \pi_l \exp\left(-\frac{1}{2\epsilon} \left[\|a_n - a_l\|^2 - \|a_n - a_k^*\|^2 \right]\right)}$$

where $a_k^* = \arg \min_l \|a_n - a_l\|^2$

$k = k^*$:

$$\lim_{\epsilon \rightarrow 0^+} q_n = \frac{\pi_{k^*} \cdot 1}{\pi_{k^*} \cdot 1 + 0 + \dots + 0} = 1$$

$k \neq k^*$:

$$\lim_{\epsilon \rightarrow 0^+} q_n = \frac{0}{\pi_{k^*}} = 0$$

سوی د مواقع بردار به یک بردار نه شي

$$q_n(z_n=k) = \mathbb{I}(k = \arg \min_l \|a_n - a_l\|^2)$$

$$\rightarrow a_k^{(t)} = \frac{\sum_{n=1}^N q_n(k) a_n}{\sum q_n(k)} = \frac{\sum_{n \in \text{cluster } k} a_n}{N_k}$$

سوی د EM ک-means به یو لړ

ک

اگر تو فرایند بنیہ سازی (مثل EM) می بیند یک خوشه گاوسی (تقریباً بیفتد روی
نقطه داده و داده دیگر نرسد، ایجاد خوشه ~~صاف~~ منقبض شد و $\sum_k | \rightarrow 0$
در واقع از دید مادی، خوشه از بدی گون $\leftarrow$ نقطه می شود
و از دید احتمال، هیچی احتمال در $\leftarrow$ نقطه $\leftarrow$ $\leftarrow$ تلبینا
راه حل: یک پیشین احتمال روی ماتریس کوواریانس (مثل واریانس - ویکتور)
تقریب می کنی پس یک ماتریس $\mathbf{K}$ به کوواریانس افاغنه می شود $\leftarrow$ ماتریس
هموار $\mathbf{K}$ و باید از می صونه